

## 2. Analisis Funcional — DocumentIA MVP

Ultima actualizacion: 2026-03-31  
Proyecto: AI DocClassExt — SAREB

### 2.1 Descripcion del Problema de Negocio


SAREB (Sociedad de Gestion de Activos procedentes de la Reestructuracion Bancaria) gestiona una cartera de activos inmobiliarios que genera un volumen elevado de documentacion legal y tecnica: notas simples registrales, tasaciones, escrituras, certificados energeticos, contratos de arrendamiento, entre otros.

Situacion actual (antes de DocumentIA):

- La clasificacion documental es manual: un operador identifica el tipo de documento y lo archiva en el Gestor Documental Corporativo (GDC).
- La extraccion de datos clave (finca registral, titulares, cargas, valores de tasacion) se realiza manualmente o con plantillas rigidas.
- Los errores de clasificacion y extraccion generan reprocesos, retrasos y riesgos regulatorios.
- No existe validacion automatica de datos extraidos (NIF invalidos, fechas incoherentes, referencias catastrales erroneas).
- La trazabilidad end-to-end es limitada.


**Solucion DocumentIA:** Un pipeline automatizado de IA que recibe un documento PDF, lo clasifica, extrae datos estructurados, los valida, los enriquece con fuentes externas, los archiva en GDC y persiste resultados con auditoria completa. Todo accesible via API REST para integracion con sistemas existentes de SAREB.

### 2.2 Actores del Sistema



| Actor               | Tipo            | Descripcion                                                                                                                                                              |
|---------------------|-----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Sistema Cliente API | Sistema         | Cualquier sistema de SAREB que envíe documentos al pipeline via <code>POST /api/IngestDocument</code> . Puede ser un proceso batch, un portal web o un flujo RPA.        |
| Administrador       | Persona         | Miembro del equipo tecnico o de negocio que gestiona tipologias, modelos AI y plugins desde el portal Admin (Blazor) o directamente via API <code>/management/*</code> . |
| Negocio SAREB       | Persona         | Consumidor final de los datos extraidos y clasificados. No interactua directamente con DocumentIA; consume los resultados a traves de GDC, SQL o reportes.               |
| GDC SINTWS          | Sistema externo | Gestor Documental Corporativo de SAREB. Recibe documentos clasificados via SOAP.                                                                                         |
| Azure AI Services   | Sistema externo | Proveedores de IA: Document Intelligence, Content Understanding, OpenAI.                                                                                                 |
| Plugins externos    | Sistema externo | Servicios REST/SOAP para enriquecimiento (catastro, atlas, Excel de referencias).                                                                                        |

## 2.3 Casos de Uso Principales



### CU1: Ingestar Documento para Procesamiento

| Campo           | Detalle                                                                                                                                                                                                                       |
|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Actor principal | Sistema Cliente API                                                                                                                                                                                                           |
| Precondicion    | Debe informarse exactamente una fuente de documento: <code>documento.content.base64</code> (PDF en Base64) o <code>documento.objectIdGDC</code> (documento ya archivado en GDC). Function Key valida (si endpoint protegido). |
| Postcondicion   | Documento clasificado, datos extraidos, validados, enriquecidos, archivado en GDC, persistido en BD.                                                                                                                          |

#### Flujo normal:

1. Cliente envia `POST /api/IngestDocument` con documento en Base64 o `objectIdGDC` , e instrucciones opcionales.
2. Sistema genera `instanceId` y devuelve `statusQueryUri` para polling.
3. Orchestrator ejecuta pipeline: Normalizar → Verificar duplicado → Subir blob → Clasificar → Resolver tipología → Extraer → Prompt → Validar → ObtenerActivo → Integrar → Subir GDC → Persistir.
4. Cliente consulta `statusQueryUri` hasta obtener estado `Completed` .
5. Respuesta final incluye: datos extraidos, confianza global, estado calidad, auditoria.

#### Flujos alternativos:

| Condicion                                                         | Comportamiento                                                                                                                    |
|-------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|
| Entrada por <code>objectIdGDC</code> con checksum existente en BD | Pre-dedupe por MD5 (metadata GDC) y retorno temprano con última ejecución si <code>forceReprocess=false</code> .                  |
| Entrada por <code>objectIdGDC</code> sin checksum/duplicado en BD | Descarga documento desde GDC y continúa pipeline normal.                                                                          |
| Documento duplicado (SHA256 ya existe en BD)                      | Si <code>forceReprocess=false</code> : retorna resultado anterior cacheado con <code>ReutilizadaPorDuplicado=true</code> .        |
| ExpectedType informado                                            | Omite clasificacion (confianza=1.0), usa la tipologia indicada directamente.                                                      |
| Confianza clasificacion < umbral                                  | Estado final <code>BAJA_CONFIANZA_CLASIFICACION</code> . No extrae ni valida.                                                     |
| Tipologia no resoluble                                            | Estado final <code>ERROR</code> con mensaje "No se ha podido identificar la tipologia".                                           |
| Extraccion con baja completitud                                   | Activa fallback GPT-4o-mini para campos faltantes.                                                                                |
| Plugin critico (Priority=1) falla                                 | Detiene cadena de plugins. Datos parciales se preservan.                                                                          |
| AssetResolver habilitado y activo encontrado                      | <code>ObtenerActivoActivity</code> resuelve <code>IdActivo</code> desde <code>DM_POSICION_AAII_TB</code> antes de la integracion. |
| AssetResolver sin resultados                                      | Paso se completa sin <code>IdActivo</code> ; plugins posteriores pueden resolverlo.                                               |
| GDC timeout (> 120s)                                              | Marca <code>Timeout</code> en <code>SubirGDC</code> , continua a persistencia.                                                    |
| Excepcion no controlada                                           | Estado final <code>ERROR</code> con mensaje de excepcion. Persiste lo capturado hasta ese punto.                                  |

CU2: Consultar Estado de Procesamiento

| Campo                   | Detalle                                                                                                                                                                                      |
|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Actor principal         | Sistema Cliente API / Desktop                                                                                                                                                                |
| Flujo                   | <code>GET statusQueryUri</code> (Durable Functions built-in). Retorna <code>runtimeStatus</code> (Pending/Running/Completed/Failed) + <code>customStatus</code> con timeline de actividades. |
| customStatus en Running | <code>{ estado, actividadActual, actividadesTotales, actividadesCompletadas[], duracionTotalMs, actividades[{nombre, estado, duracionMs, fallbackActivado}] }</code>                         |

CU3: Gestionar Tipologias

| Campo             | Detalle                                                                                                                                                                        |
|-------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Actor principal   | Administrador                                                                                                                                                                  |
| Endpoints         | <code>GET/POST/PUT /management/tipologias</code> , <code>POST .../publicar</code> , <code>POST .../retirar</code> , <code>POST .../draft</code>                                |
| Ciclo de vida     | Draft → Published → Retired. Solo tipologias Published estan activas para clasificacion.                                                                                       |
| Datos gestionados | Codigo, nombre, version, umbrales, modelos asociados, prompt GPT y <code>ConfiguracionJson</code> persistido en BD. Los JSON fisicos son seed/referencia, no fuente operativa. |

CU4: Gestionar Modelos AI

| Campo           | Detalle                                                                                                                                                        |
|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Actor principal | Administrador                                                                                                                                                  |
| Endpoints       | <code>GET /management/modelos/{tipo}</code> , <code>POST /management/modelos</code> , <code>PUT .../modelos/{id}</code> , <code>DELETE .../modelos/{id}</code> |
| Tipos           | Clasificacion, Extraccion, Prompt, Layout                                                                                                                      |
| Datos           | Key unica, provider, modelo, <code>ConfiguracionJson</code> en la tabla <code>ModeloConfigs</code> , activo/inactivo.                                          |

CU5: Configurar Plugins por Tipologia

| Campo                  | Detalle                                                                                                                                |
|------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| <b>Actor principal</b> | Administrador                                                                                                                          |
| <b>Endpoints</b>       | GET/PUT /management/plugins-tipologias/{codigo} , POST .../publicar , POST .../retirar                                                 |
| <b>Datos</b>           | ConfiguracionJson en BD con array de plugins: pluginKey, pluginType (REST/SOAP/Custom), enabled, priority, configuration, retryPolicy. |

## CU6: Consultar Tipologias Publicadas

| Campo                  | Detalle                                                                                                                                                                                                                                                                                                                                                        |
|------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Actor principal</b> | Sistema Cliente / Desktop / Batch                                                                                                                                                                                                                                                                                                                              |
| <b>Endpoint</b>        | GET /api/tipologias (Anonymous)                                                                                                                                                                                                                                                                                                                                |
| <b>Respuesta</b>       | Lista de tipologias publicadas. Cada item: <code>identificador ( {codigo}@{version} )</code> , <code>nombre</code> y <code>extraction</code> (booleano = <code>ConfiguracionJson.Extraction.Enabled</code> ).                                                                                                                                                  |
| <b>Nota</b>            | El campo <code>extraction</code> permite a los consumidores filtrar tipologias segun si tienen extraccion habilitada. El batch de extraccion ( <code>DocumentIA.Batch</code> ) solo muestra las que tienen <code>extraction: true</code> . Retrocompatible: clientes antiguos (Desktop) que solo leen <code>identificador / nombre</code> no se ven afectados. |

## CU7: Obtener Activo desde Documento

| Campo                        | Detalle                                                                                                                                                                                                                                                                                           |
|------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Actor principal</b>       | Sistema (automatico dentro del pipeline)                                                                                                                                                                                                                                                          |
| <b>Precondicion</b>          | Documento extraido con datos que contienen IDUFIR o Referencia Catastral. AssetResolver habilitado en tipologia o instrucciones.                                                                                                                                                                  |
| <b>Postcondicion</b>         | Si se encuentra un activo unico, <code>IdActivo</code> queda resuelto y se propaga a Integracion y persistencia.                                                                                                                                                                                  |
| <b>Descripcion</b>           | La actividad <code>ObtenerActivoActivity</code> consulta la tabla <code>DM_POSICION_AAI_TB</code> del plugin AssetResolver usando los datos extraidos (IDUFIR y/o Referencia Catastral). Los campos de busqueda se resuelven por alias configurables (mapeo en tipologia o configuracion global). |
| <b>Precedencia</b>           | <code>instrucciones.assetResolver.enabled &gt; tipologia.assetResolver.enabled &gt; deshabilitado (default)</code>                                                                                                                                                                                |
| <b>Resultado</b>             | <code>detalleEjecucion.assetResolver</code> con activos encontrados, criterios usados, campos solicitados y duracion.                                                                                                                                                                             |
| <b>Si no hay match</b>       | <code>assetResolver.exitoso = false</code> , <code>activos = []</code> , pipeline continua sin <code>IdActivo</code> desde este paso.                                                                                                                                                             |
| <b>Si hay match multiple</b> | Se retornan todos los activos pero no se resuelve <code>IdActivo</code> automaticamente (requiere match unico).                                                                                                                                                                                   |

## 2.4 Reglas de Negocio Criticas

### RN1: Deduplicacion por SHA256

- Antes de procesar, se calcula SHA256 del documento y se busca en BD.
- Si existe y `forceReprocess=false` , se retorna el resultado anterior.
- Si existe y `forceReprocess=true` , se reprocesa completamente.
- `SkipDuplicateCheck=true` omite la verificacion (procesamiento incondicional).
- La **clave de deduplicacion** es `SHA256 + classificationOnly + nivelClasificacion` . Dos peticiones con el mismo SHA256 pero distinto `nivelClasificacion` se tratan como ejecuciones independientes y no se reutilizan entre si.

## RN2: Umbrales de Confianza Configurables

La confianza se evalua en cascada con prioridad:

Instrucciones de la peticion (request)  
→ Configuracion de la tipologia publicada en BD  
→ Configuracion global del servidor (appsettings)

| Umbral               | Significado                                                                     | Default                         |
|----------------------|---------------------------------------------------------------------------------|---------------------------------|
| clasifUmbralFallback | Confianza minima de DI para NO activar fallback GPT en clasificacion            | 0.6 (server) / 0.85 (tipologia) |
| extracUmbralFallback | Completitud minima de CU para NO activar fallback GPT en extraccion             | 0.5 (server) / 0.9 (tipologia)  |
| umbralOK             | Confianza global minima para estado calidad "OK"                                | 0.85                            |
| umbralRevision       | Confianza global minima para estado calidad "REVISION" (entre revision y error) | 0.70                            |

Los campos de una tipologia pueden declarar `avoidConfidence: true` . Estos campos quedan fuera del calculo del score de confianza de extraccion y de `CamposBajaConfianza` , pero siguen contando para completitud, campos requeridos y `DatosExtraidos` .  
`MetricasDebug.ConfianzaPorCampo` mantiene la confianza original de todos los campos, y `CamposExcluidosConfianza` lista los campos excluidos del score.

## RN3: Confianza Global

ConfianzaGlobal = MIN(ConfianzaClasificacion, ConfianzaExtraccion, ConfianzaValidacion)


| ConfianzaGlobal          | EstadoCalidad |
|--------------------------|---------------|
| >= umbralOK (0.85)       | OK            |
| >= umbralRevision (0.70) | REVISION      |
| < umbralRevision         | ERROR         |

## RN4: Severidades de Validacion

| Severidad | Impacto                                                                                                     |
|-----------|-------------------------------------------------------------------------------------------------------------|
| Error     | Reduce ConfianzaValidacion. Se reporta en Inconsistencias. Detiene validacion del campo (por optimizacion). |
| Warning   | Se reporta en Validaciones. No impide procesamiento.                                                        |
| Info      | Informativo. No impacta confianza.                                                                          |

Si hay errores de validacion, el estado final es `VALIDACION_CON_ERRORES` en lugar de `OK` .

## RN5: Ciclo de Vida de Tipologias



Solo las tipologías en estado `Published` son usadas por el pipeline de clasificación y están visibles en `GET /api/tipologias`.

#### RN6: Plugins por Prioridad

- Los plugins se ejecutan en orden ascendente de prioridad (`Priority=1` primero).
- Si un plugin con `Priority=1` (crítico) falla, se detiene la cadena completa.
- Plugins no críticos: error se loguea como warning, se continúa con el siguiente.

## RN7: Clasificacion Jerarquica GPT (nivelClasificacion)

Cuando se informa `instrucciones.classification.nivelClasificacion` ( "TDN1" o "TDN1/TDN2" ):

1. **D2 — Force provider GPT:** el sistema fuerza `classification.provider = "gpt"` automaticamente, independientemente de lo que se haya indicado en la peticion o configuracion de tipologia.
  2. **D1 — Clasificacion parcial ( `clasificacionParcial = true` ):**
    - Si la clasificacion GPT retorna un **codigo TDN1 conocido** del catalogo: se asigna `identificacion.tdn1` y el **pipeline continua normalmente** (extraccion, validacion, plugins). Solo se establece el nivel TDN1 detectado.
    - Si la clasificacion GPT retorna una **tipologia no mapeada al catalogo** ( `tipologia = "Desconocido"` ): el pipeline **se detiene**, extraccion y validacion se omiten, `resultado.estado = "OK"` , y `identificacion.propuestaTipologia` contiene la propuesta libre del modelo.  3. **D4 — Markdown pre-procesado:** si se informa `instrucciones.classification.markdown` , el paso `ExtraerMarkdownLayoutActivity` se omite y se usa ese texto directamente. Util en integraciones batch que ya tienen el markdown extraido.
  4. **D7 — Clave de deduplicacion extendida:** el campo `nivelClasificacion` forma parte de la clave de deduplicacion junto con `SHA256` y `classificationOnly` . Ver RN1.
  5. **Confianza dinamica self-reported:** GPT reporta su propia certeza sobre cada clasificacion mediante un campo `confianza` (0.0-1.0) en el JSON de respuesta. El sistema extrae este valor y lo usa como `ConfianzaClasificacion` final. Si GPT no reporta confianza, se aplica fallback a 0.9 para mantener compatibilidad con versiones anteriores. Esta confianza se refleja en:
    - `output.DetalleEjecucion.Clasificacion.Confianza`
    - Logs: `ConfianzaSelfReported` vs `ConfianzaFinal`
    - Calculo de `ConfianzaGlobal` (ver RN3)
- Cada plugin puede devolver `DatosEnriquecidos` que se mergean acumulativamente en `DatosFinales` .
  - Un plugin con `returnsIdActivo=true` puede resolver/sobreescribir el `IdActivo` del documento.

## RN7: Resolucion de Activo (AssetResolver)

- La actividad `ObtenerActivo` se ejecuta entre Validar e Integrar, solo si esta habilitada.
- Habilitacion por precedencia: `instrucciones.assetResolver.enabled ?? tipologia.assetResolver.enabled ?? false` .
- **Tres criterios de busqueda independientes**, cada uno habilitado/deshabilitado por configuracion:
  - **IDUFIR** ( `busquedaIdufirHabilitada` , default `true` ): busqueda exacta en `DM_POSICION_AAII_TB.ID_IDUFIR` .
  - **Referencia Catastral** ( `busquedaReferenciaCatastralHabilitada` , default `true` ): busqueda exacta en `ID_REF_CATAST` .
  - **Direccion** ( `busquedaDireccionHabilitada` , default `false` ): busqueda fuzzy con scoring en columnas de direccion.
- **Modo de combinacion** ( `modoCombinacionCriterios` ): `OR` (union, default) o `AND` (interseccion de resultados).
- Los alias de campos se resuelven por precedencia: mapeos de la tipologia > configuracion global ( `FieldAliases` ).
- Si un criterio esta deshabilitado, no se intenta detectar ni usar, incluso si hay aliases globales.
- Si se encuentra exactamente 1 activo, su `ID_ACTIVO_SAREB` se asigna como `IdActivo` del documento.
- Si se encuentran 0 o multiples activos, no se resuelve `IdActivo` en este paso (puede ser resuelto por plugins posteriores).

## 2.5 Glosario de Terminos del Dominio

| Termino                                    | Definicion                                                                                                                                                                                                                                                  |
|--------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Tipologia</b>                           | Tipo documental configurable (ej: nota-simple, tasacion, resumen-documental). Tiene codigo, version, umbrales y configuracion de extraccion/validacion/plugins.                                                                                             |
| <b>Nota Simple</b>                         | Extracto del Registro de la Propiedad que informa sobre la situacion juridica de una finca (titulares, cargas, dominio). Tipologia principal del MVP: <code>nota-simple@1.4</code> .                                                                        |
| <b>Tasacion</b>                            | Informe de valoracion de un inmueble realizado por una sociedad de tasacion.                                                                                                                                                                                |
| <b>Confianza</b>                           | Metrica [0.0-1.0] que indica el grado de certeza de la IA sobre su resultado. Se calcula por clasificacion, extraccion y validacion.                                                                                                                        |
| <b>ConfianzaAgregada / ConfianzaGlobal</b> | MIN(confianza clasificacion, confianza extraccion, confianza validacion).                                                                                                                                                                                   |
| <b>EstadoCalidad</b>                       | Clasificacion del resultado final: OK ( $\geq 0.85$ ), REVISION ( $\geq 0.70$ ), ERROR ( $< 0.70$ ). Umbrales configurables por tipologia.                                                                                                                  |
| <b>CorrelationId</b>                       | UUID que vincula todas las operaciones de una misma peticion para trazabilidad end-to-end. Auto-generado si no se informa.                                                                                                                                  |
| <b>IdActivo</b>                            | Identificador del activo inmobiliario de SAREB asociado al documento. Puede venir en la peticion o ser resuelto por un plugin de enriquecimiento.                                                                                                           |
| <b>IdGDC</b>                               | Identificador del objeto en el Gestor Documental Corporativo tras la subida exitosa.                                                                                                                                                                        |
| <b>Matricula</b>                           | Codigo de clasificacion GDC que define donde se archiva el documento (ej: <code>AI-01-NOTS-01</code> ).                                                                                                                                                     |
| <b>Finca Registral</b>                     | Numero de inscripcion de una finca en el Registro de la Propiedad. Campo clave en Notas Simples.                                                                                                                                                            |
| <b>IDUFIR / CRU</b>                        | Codigo Registral Unico de 14 digitos que identifica una finca de forma univoca a nivel nacional.                                                                                                                                                            |
| <b>Referencia Catastral</b>                | Codigo de 20 caracteres que identifica un inmueble en el Catastro. Validado por <code>CatastralReferenceValidator</code> .                                                                                                                                  |
| <b>NIF/NIE/CIF</b>                         | Documentos de identidad fiscal espanoles. Validados algoritmicamente por <code>NifValidator</code> .                                                                                                                                                        |
| <b>GDC SINTWS</b>                          | Servicio SOAP del Gestor Documental Corporativo de SAREB (host: <code>srbwidd03.sareb.srb:8090</code> ).                                                                                                                                                    |
| <b>Fallback</b>                            | Mecanismo automatico que redirige al proveedor alternativo (GPT) cuando el primario (DI/CU) tiene baja confianza o falla.                                                                                                                                   |
| <b>Plugin</b>                              | Componente de integracion extensible (REST, SOAP o DLL .NET custom) que enriquece datos extraidos con fuentes externas.                                                                                                                                     |
| <b>AssetResolver</b>                       | Plugin HTTP que consulta la tabla <code>DM_POSICION_AAII_TB</code> para resolver el activo inmobiliario (IdActivo). Soporta tres criterios: IDUFIR, Referencia Catastral y Direccion (fuzzy scoring). Criterios configurables con AND/OR.                   |
| <b>DM_POSICION_AAII_TB</b>                 | Tabla SQL Server con la posicion de activos AAII de SAREB (~160 columnas). PK compuesta: ( <code>ID_ACTIVO_SAREB</code> , <code>FCH_CIERRE_DT</code> ). Campos clave de busqueda: <code>ID_IDUFIR</code> (14 chars), <code>ID_REF_CATAST</code> (32 chars). |
| <b>ObtenerActivoActivity</b>               | Actividad del pipeline que invoca al AssetResolver via HTTP para resolver el activo asociado al documento. Se ejecuta entre Validar e Integrar.                                                                                                             |
| <b>Circuit Breaker</b>                     | Patron de resiliencia que abre el circuito tras N fallos consecutivos, impidiendo nuevas llamadas hasta que se restablezca el servicio.                                                                                                                     |

## 2.6 Requisitos Funcionales

| ID    | Requisito                                                                                      | Criterio de Aceptacion                                                                                                                                                                                                                             |
|-------|------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RF 01 | El sistema clasifica automaticamente el tipo documental de un PDF                              | Devuelve <code>TipologiaDetectada</code> con confianza $\geq 0.6$ . Soporta fallback a GPT si confianza DI baja.                                                                                                                                   |
| RF 02 | El sistema extrae campos estructurados de documentos clasificados                              | Devuelve <code>DatosExtraidos</code> como diccionario clave-valor. Campos alineados con configuracion de tipologia.                                                                                                                                |
| RF 03 | El sistema detecta documentos duplicados por SHA256                                            | Si SHA256 existe en BD y <code>forceReprocess=false</code> , retorna resultado cacheado sin reprocesar.                                                                                                                                            |
| RF 04 | El sistema valida datos extraidos contra reglas configurables                                  | Ejecuta <code>ValidationEngine</code> con reglas JSON por tipologia. Devuelve errores/warnings/info.                                                                                                                                               |
| RF 05 | El sistema soporta multiples tipologias con configuracion independiente                        | Cada tipologia tiene su propia configuracion de extraccion, validacion, plugins y umbrales.                                                                                                                                                        |
| RF 06 | El sistema sube documentos al GDC via SOAP                                                     | <code>SubirGDCActivity</code> envia documento al GDC con matricula y metadata. Soporta timeout de 120s.                                                                                                                                            |
| RF 07 | El sistema enriquece datos via plugins configurables                                           | <code>PluginFactory</code> crea REST/SOAP/Custom plugins. Ejecucion por prioridad con retry.                                                                                                                                                       |
| RF 08 | El sistema persiste resultados y auditoria en BD                                               | <code>PersistirActivity</code> guarda <code>DocumentoEntity</code> , <code>ResultadoProcesamientoEntity</code> , <code>DocumentoEjecucionEntity</code> , <code>AuditoriaEntity</code> .                                                            |
| RF 09 | El sistema expone progreso de procesamiento en tiempo real                                     | <code>customStatus</code> con timeline de actividades consultable via <code>statusQueryUri</code> .                                                                                                                                                |
| RF 10 | El sistema soporta gestion CRUD de tipologias via API                                          | Endpoints <code>/management/tipologias</code> con ciclo Draft→Published→Retired.                                                                                                                                                                   |
| RF 11 | El sistema soporta gestion de modelos AI (clasificacion, extraccion, prompt, layout)           | Endpoints <code>/management/modelos</code> con CRUD y activacion.                                                                                                                                                                                  |
| RF 12 | El sistema ejecuta prompts libres configurables por tipologia y resumen por defecto controlado | <code>PromptActivity</code> con OpenAI, configurable via <code>promptConfig</code> en tipologia JSON. El resumen ejecutivo por defecto se devuelve en <code>Resumen</code> ; el prompt propio/ad-hoc se mantiene en <code>ResultadoPrompt</code> . |
| RF 13 | El sistema soporta versionado de tipologias                                                    | Resolucion <code>nota-simple</code> → default version, <code>nota-simple@1.4</code> → version especifica.                                                                                                                                          |
| RF 14 | El sistema calcula hashes SHA256, MD5 y CRC32 para integridad                                  | <code>NormalizarActivity</code> calcula los tres hashes. SHA256 usado para deduplicacion, MD5 para GDC.                                                                                                                                            |
| RF 16 | El sistema resuelve el activo inmobiliario desde datos extraidos                               | <code>ObtenerActivoActivity</code> consulta <code>DM_POSICION_AAII_TB</code> via <code>AssetResolver</code> . Devuelve <code>IdActivo</code> si match unico. Habilitacion configurable por tipologia/instrucciones.                                |
| RF 17 | El sistema permite excluir campos del score de confianza de extraccion por tipologia           | <code>avoidConfidence: true</code> en un campo lo excluye del score y de <code>CamposBajaConfianza</code> , manteniendo completitud y trazabilidad en <code>ConfianzaPorCampo</code> .                                                             |

## 2.7 Requisitos No Funcionales

| ID     | Categoria      | Requisito                                                  | Criterio                                                                                                            |
|--------|----------------|------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| RNF 01 | Rendimiento    | Pipeline completo en < 120s para un documento tipico       | Medido por DuracionTotalMs en seguimiento. GDC timeout 120s. Tipico: 15-45s.                                        |
| RNF 02 | Disponibilidad | Function App con SLA >= 99.95%                             | Azure Consumption Plan SLA. Durable Functions tolerante a reinicios.                                                |
| RNF 03 | Escalabilidad  | Soportar procesamiento concurrente de multiples documentos | Durable Functions escala automaticamente. Sin estado compartido entre instancias.                                   |
| RNF 04 | Seguridad      | Autenticacion en todos los endpoints de gestion            | <code>AuthorizationLevel.Function</code> (x-functions-key). Managed Identity preparada.                             |
| RNF 05 | Seguridad      | Credenciales nunca en codigo fuente                        | API Keys en configuration/Key Vault. SSL bypass solo configurable explicitamente.                                   |
| RNF 06 | Auditabilidad  | Cada operacion registrada en tabla Auditoria               | PersistirActivity escribe AuditoriaEntity con accion, nivel, mensaje, timestamp.                                    |
| RNF 07 | Extensibilidad | Anadir nueva tipologia sin cambiar codigo                  | Registro/configuracion en BD via Admin portal o Admin API. JSON fisico solo como seed/plantilla. Sin recompilacion. |
| RNF 08 | Observabilidad | Telemetry en Application Insights                          | Structured logging + Application Insights SDK. Metricas custom por actividad.                                       |
| RNF 09 | Resiliencia    | Tolerancia a fallos en servicios externos                  | Circuit breaker + retry exponencial en plugins y GDC. Fallback IA automatico.                                       |
| RNF 10 | Mantenibilidad | Cobertura de tests unitarios en modulos criticos           | 33 clases de test. Validacion, plugins, configuracion cubiertos.                                                    |

## 2.8 Mapeo de User Stories

### Epics y User Stories

| Epic | Nombre                        | User Stories   |
|------|-------------------------------|----------------|
| EP1  | Ingesta y orquestacion        | HU1, HU2       |
| EP2  | Clasificacion y extraccion AI | HU3, HU4       |
| EP3  | Validacion y motor de reglas  | HU5, HU6       |
| EP4  | Persistencia y auditoria      | HU7            |
| EP5  | Configuracion y tipologias    | HU8, HU9, HU10 |
| EP6  | Observabilidad y pruebas      | HU11           |
| EP9  | GDC integracion completa      | —              |
| EP10 | Resolucion de Activo          | HU14           |

### Detalle de User Stories

| ID    | Título                        | Descripción                                                                                                                                                                      | Criterio de Aceptación                                                                                                                                                                                                                                       |
|-------|-------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| H U1  | Ingesta de documentos vía API | Como sistema cliente, quiero enviar un documento vía POST para que sea procesado automáticamente.                                                                                | Endpoint acepta JSON con <code>documento.content.base64</code> o <code>documento.objectIdGDC</code> , devuelve <code>instanceId</code> y <code>statusQueryUri</code> .                                                                                       |
| H U2  | Seguimiento en tiempo real    | Como usuario del Desktop, quiero ver el progreso del procesamiento con actividades en tiempo real.                                                                               | customStatus muestra timeline con estado/duración por actividad. Polling cada 2s.                                                                                                                                                                            |
| H U3  | Clasificación con fallback    | Como sistema, quiero que la clasificación use DI y si la confianza es baja, recurra a GPT.                                                                                       | Fallback automático cuando confianza < umbral. Flag <code>FallbackLLM=true</code> en resultado.                                                                                                                                                              |
| H U4  | Extracción multi-proveedor    | Como sistema, quiero extraer campos usando CU con fallback a GPT si la completitud es baja.                                                                                      | ConfigurableExtraerDataProvider enruta según config. Fallback automático.                                                                                                                                                                                    |
| H U5  | Validación por reglas         | Como negocio, quiero que los datos extraídos se validen contra reglas de NIF, fechas, rangos, etc.                                                                               | ValidationEngine con 11 tipos de regla. Severidades Error/Warning/Info.                                                                                                                                                                                      |
| H U6  | Configuración de reglas JSON  | Como administrador de tipologías, quiero definir reglas de validación en JSON sin cambiar código.                                                                                | Archivos <code>{tipologia}.validation.json</code> con campos, tipos de regla y severidades.                                                                                                                                                                  |
| H U7  | Persistencia completa         | Como sistema, quiero que cada procesamiento quede guardado en BD con auditoría.                                                                                                  | Documentos, resultados, ejecuciones, plugins y validaciones persistidos.                                                                                                                                                                                     |
| H U8  | Gestión de tipologías         | Como administrador de tipologías, quiero crear, editar, publicar y retirar tipologías desde un portal.                                                                           | CRUD + lifecycle Draft→Published→Retired vía API y Blazor Admin.                                                                                                                                                                                             |
| H U9  | Versionado de tipologías      | Como administrador de tipologías, quiero manejar múltiples versiones de una tipología simultáneamente.                                                                           | Resolución <code>familia@version</code> . Default version configurable.                                                                                                                                                                                      |
| H U10 | Configuración de plugins      | Como administrador de tipologías, quiero asignar y configurar plugins de integración por tipología.                                                                              | Endpoints <code>/management/plugins-tipologias</code> . JSON con priority, retry, enabled.                                                                                                                                                                   |
| H U11 | Observabilidad                | Como operador, quiero métricas y logs en Application Insights para diagnosticar problemas.                                                                                       | Structured logging, telemetría AI SDK, métricas por actividad en seguimiento.                                                                                                                                                                                |
| H U14 | Resolución de activo          | Como sistema, quiero resolver automáticamente el IdActivo del documento consultando la tabla <code>DM_POSICION_AAII_TB</code> usando IDUFIR, Referencia Catastral y/o Dirección. | <code>ObtenerActivoActivity</code> busca en AssetResolver con tres criterios configurables (habilitar/deshabilitar cada uno). Soporta AND/OR. Si match único, <code>IdActivo</code> se propaga. Ver <a href="#">ESPECIFICACION_PLUGIN_ASSETRESOLVER.md</a> . |

## 2.9 Restricciones del Sistema

| Restriccion        | Detalle                                                                                                                                                                                       |
|--------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| GDPR/LOPD          | Los documentos pueden contener datos personales (NIF, nombres, direcciones). Este requisito regulatorio se mantiene, pero su implementación funcional queda fuera del alcance del MVP actual. |
| Formatos aceptados | Solo PDF. Puede recibirse como Base64 sin saltos de línea (RFC 4648) o recuperarse desde GDC vía <code>documento.objectIdGDC</code> .                                                         |
| Tamaño maximo      | Limitado por el tamaño maximo de input de Durable Functions (~60 KB entity size en Storage). Documentos grandes pueden requerir blob-reference pattern (no implementado).                     |
| Timeouts           | GDC: 120s (hardcoded en orchestrator). Servicios AI: configurable por proveedor (DI: 120s, GPT: 30-60s, CU: configurable).                                                                    |
| Conectividad GDC   | Requiere acceso de red a <code>srbwidd03.sareb.srb:8090</code> . SSL bypass configurable para certificado CA corporativo no confiado en Linux.                                                |
| Region Azure       | Function App y mayoría de servicios en West Europe. Content Understanding en Sweden Central (unica region disponible con la funcionalidad requerida).                                         |
| Modelo Consumption | Function App en plan Consumption: cold start posible (~2-10s). Timeout maximo por ejecucion: 10 min (default) o 230s (HTTP trigger).                                                          |
| Idioma             | Documentos en espanol. Prompts GPT y reglas de validacion asumen idioma espanol.                                                                                                              |

## 2.10 Referencias

| Documento                      | Contenido                                  |
|--------------------------------|--------------------------------------------|
| 01_ARQUITECTURA_SISTEMA.md     | Arquitectura tecnica, ADRs, despliegue     |
| 03_DISENO_TECNICO_DETALLADO.md | Diagramas de flujo, secuencia, modelo ER   |
| CAUSISTICAS_NOTA_SIMPLE_1_4.md | Casuisticas especificas de Nota Simple 1.4 |
| CONFIANZA_AGREGADA.md          | Logica detallada de calculo de confianza   |
| TIPOLOGIAS_REFERENCIA.md       | Catalogo de referencia de tipologias       |