

Glosario de Términos — DocumentIA

Última actualización: 2026-06-10

Proyecto: AI DocClassExt — SAREB

Propósito: Referencia centralizada de conceptos, términos técnicos y acrónimos del sistema DocumentIA.

A. Términos Técnicos Centrales

Tipología

Clasificación canónica de un tipo de documento dentro del negocio de SAREB. Cada tipología posee un **código único** (ej: `NOTA_SIMPLE_REGISTRAL`), **nombre legible**, **versión**, **umbrales de confianza**, **modelos asociados** y **configuración JSON**.

Ejemplo: "Notas Simples Registrales v1.2", "Tasaciones Inmobiliarias v2.0", "Escrituras Públicas v1.0".

Ciclo de vida: Draft → Published → Retired. Solo tipologías Published están activas en pipeline de clasificación. Gestionadas vía API `/management/tipologias` .

Referencia: [docs/03_DISENO_TECNICO_DETALLADO.md - Gestionar Tipologias](#)

Clasificación

Proceso automatizado de identificación y etiquetado del tipo de documento (tipología) basado en contenido extraído del PDF. El orquestador ejecuta `ClasificarActivity` contra **proveedores configurables** en orden (flujo configurable + fallback global).

Retorna: `TipologiaDetectada` (código) + `Confianza` (float 0-1).

Referencia: [docs/03_DISENO_TECNICO_DETALLADO.md - ClasificarActivity](#)

Confianza

Métrica numérica (0.0 - 1.0) que cuantifica el grado de certeza de una decisión (clasificación, extracción, validación). Se agregan confianzas de múltiples proveedores y se comparan contra umbrales configurables.

Tipos:

- **Confianza de Clasificación:** Proporcionada por el modelo de clasificación (provider-specific).
- **Confianza Agregada:** Promedio ponderado de confianzas de múltiples providers según prioridad/weight.

Umbrales: Configurables por tipología. Si confianza < umbral, el estado resultante es `BAJA_CONFIANZA_CLASIFICACION` y la extracción se omite.

Provider / Plugin

Componente modular que proporciona capacidades especializadas (clasificación, extracción, validación, enriquecimiento).

Tipos de Provider:

- **Clasificación:** Azure Content Understanding, Document Intelligence, modelo custom.
- **Extracción:** Document Intelligence, Content Understanding, GPT-4o-mini fallback.
- **Validación:** Reglas JSON, patrones regex, lógica personalizada.
- **Enriquecimiento (Plugins):** AssetResolver, GDC, servicios REST/SOAP externos.

Configuración: Almacenada en `ConfiguracionJson` de la BD; activación por tipología.

Orquestación / Orchestrator

Durable Function (Microsoft.DurableTask) que coordina la ejecución secuencial de **14 actividades** del pipeline de procesamiento, con puntos de decisión, reintentos y manejo de fallos.

Clase principal: `DocumentProcessOrchestrator` (Durable Orchestration Function).

Entrada: `IngestDocumentRequest` (documento en Base64 o `objectIdGDC`).

Salida: `ContratoSalida` con resultado final + trazabilidad.

Timeline de actividades: Registrado en `customStatus` durante Running para visibilidad en tiempo real.

Activity Function

Función discreta en Durable Functions que ejecuta una unidad de trabajo (ej: normalizar PDF, verificar duplicado, clasificar, extraer datos, validar, integrar plugins).

Total en pipeline: 14 actividades.

Características: Determinística, idempotente (idealmente), con reintentos configurables.

Ejemplos: `NormalizarActivity`, `ClasificarActivity`, `ExtraerActivity`, `ValidarActivity`, `PersistirActivity`.

Extracción

Proceso de obtención de datos estructurados desde un documento procesado. Ejecuta `ExtraerActivity` contra proveedores configurables (Document Intelligence → Content Understanding → GPT-4o fallback).

Retorna: `DatosExtraidos` (Dictionary<string, object>) con campos tipología-específicos.

Diferencia con Clasificación: Clasificación = tipo de documento; Extracción = contenido del documento.

Hub / Orchestrator Hub

Punto de entrada HTTP (Function) que recibe requests de ingestión de documentos. Se comunica con Durable Functions runtime para iniciar instancias del orquestador.

Endpoint: `POST /api/IngestDocument`

Clase: `OrquestarDocumentoHttpFunction` (HTTP Trigger Function).

Retorna: `statusQueryUri` (URL para polling del estado).

Trazabilidad / Auditoría

Registro completo de decisiones, transformaciones y eventos durante el procesamiento de un documento. Incluye:

- Timeline de actividades ejecutadas con duración.
- Confianzas y umbrales en cada paso.
- Proveedores utilizados y resultados intermedios.
- Errores y fallbacks activados.

Persistencia: En tabla `EjecucionesDocumentos` (SQL Server) + logs en Application Insights.

ExecutionLog

Entidad de BD que almacena el historial de todas las ejecuciones de un documento, incluyendo estado final, datos extraídos, metadatos de ejecución y timestamps.

Tabla: `EjecucionesDocumentos` en BD central.

Propósito: Auditoría, deduplicación, análisis histórico.

Normalización

Primera actividad del pipeline (`NormalizarActivity`). Calcula propiedades canónicas del documento:

- **SHA256, MD5, CRC32:** Hashes para deduplicación.
- **Página count:** Número de páginas del PDF.
- **Metadatos:** Nombre, tamaño, timestamps.

Propósito: Preparar documento para verificación de duplicados y subsecuentes procesamiento.

Duplicado

Documento que ya ha sido procesado anteriormente (identificado por SHA256). Si `forceReprocess=false` , se retorna resultado cacheado con flag `ReutilizadaPorDuplicado=true` .

Verificación: Realizada por `VerificarDuplicadoActivity` consultando BD por SHA256 (índice único).

Resolver Tipología

Actividad (`ResolverTipologiaActivity`) que traduce un código de tipología detectada a su configuración completa desde BD. Resuelve familia@versión → `TipologiaConfig` (modelos, umbrales, plugins, prompt, reglas validación).

Entrada: Código tipología (ej: `NOTA_SIMPLE_REGISTRAL`).

Salida: `TipologiaConfig` object con todos los parámetros necesarios para extracción y validación.

Markdown Layout

Extracción de estructura y layout de documento en formato Markdown, preservando jerarquía visual (encabezados, listas, tablas).

Actividad: `ExtraerMarkdownLayoutActivity` (opcional, configurable por tipología).

Provider: Document Intelligence (Layout model).

Uso: Enriquecimiento de datos extraídos, comprensión de estructura documental.

Nota: Si `instrucciones.classification.markdown` se proporciona en input (D4), se inyecta directamente sin ejecutar activity.

Validación

Proceso de verificación de datos extraídos contra reglas tipología-específicas (formato, rango, patrones, lógica de negocio).

Motor: `ValidationEngine` + JSON rules (11 tipos de validadores).

Actividad: `ValidarActivity` .

Retorna: `ValidationReport` con campos válidos/inválidos, errores y warnings.

Referencia: docs/manuales/MANUAL_VALIDACIONES.md

AssetResolver

Plugin especializado que enriquece datos extraídos con información de activos desde tabla `DM_POSICION_AAII_TB` (o `DM_POSICION_AACC_TB`).

Actividad: `ObtenerActivoActivity` .

Búsqueda: Por IDUFIR, referencia catastral o dirección (configurable con AND/OR).

Retorna: `IdActivo` , `FCH_ALTA` , `FCH_BAJA` , `DES_SERVICER` , `IND_STATUS` y campos adicionales.

Referencia: [docs/especificaciones/ESPECIFICACION_PLUGIN_ASSETRESOLVER.md](#)

GDC / Gestor Documental Corporativo

Sistema externo de SAREB (`SINTWS`) que almacena y gestiona documentos clasificados. DocumentIA envía documentos procesados a GDC vía SOAP después de persistir resultados.

Actividad: `SubirGDCActivity` .

Protocolos: SOAP (`searchEntities` , `create`).

Timeout: 120 segundos; si expira, marca `Timeout` pero no bloquea persistencia.

PluginManager / Plugin Integration

Componente que ejecuta plugins de enriquecimiento en orden de prioridad. Cada plugin recibe datos enriquecidos + configuración, retorna resultado enriquecido.

Actividad: `IntegrarActivity` .

Orden: Configurado por `priority` (menor = más prioritario).

Fallo crítico: Si plugin con `Priority=1` falla, detiene cadena. Datos parciales se preservan.

Confianza Baja

Estado resultante cuando clasificación retorna confianza < umbral tipología. Marca documento como `BAJA_CONFIANZA_CLASIFICACION` , omite extracción y validación, persiste estado parcial para auditoría.

Blob / Azure Blob Storage

Almacenamiento en la nube (Azure Storage Account) donde se persisten documentos PDF originales después de normalización.

Container: `documents/` .

Actividad: `SubirBlobActivity` .

Propósito: Preservar documento original para auditoría y reprocesamiento.

Fallback

Mecanismo de recuperación cuando un proveedor falla o retorna resultados insatisfactorios. Clasificación: flujo configurable + fallback global. Extracción: CU → DI → GPT-4o-mini. Prompt: GPT-4o-mini por defecto.

Ejemplo: Si Document Intelligence no extrae campo crítico, GPT-4o-mini intenta extracción mediante prompt.

ConfiguracionJson

Campo JSON en tablas de BD (Tipologías, ModeloConfigs, TipologíasPlugins) que almacena configuración serializada de tipologías, modelos y plugins.

Propósito: Flexibilidad sin cambios de schema; fuente operativa de configuración.

expectedType

Parámetro opcional en `IngestDocumentRequest` que fuerza una tipología específica, omitiendo clasificación. Si informado, confianza se fija a 1.0.

Uso: Testing, casos especiales, pre-clasificación externa.

instanceId

Identificador único (UUID) generado por Durable Functions para cada ejecución del orquestador. Usado para polling de estado via `statusQueryUri`.

customStatus

Campo de la respuesta de Durable Functions que durante Running contiene timeline de actividades con duraciones, estado parcial, actividad actual y cualquier fallback activado. Permite visibilidad en tiempo real del procesamiento.

Formato: JSON estructura con `actividadesCompletadas[]`, `duracionTotalMs`, `actividades[]` detalle.

runtimeStatus

Estado global de la ejecución Durable Functions: `Pending`, `Running`, `Completed`, `Failed`, `Terminated`.

B. Acrónimos

B.1 Sareb / dominio de negocio

Acrónimo	Significado	Contexto
SAREB	Sociedad de Gestión de Activos procedentes de la Reestructuración Bancaria	Cliente y dominio de negocio
GDC	Gestor Documental Corporativo	Sistema documental externo de Sareb
SINTWS	Servicio web (SOAP) del GDC	Interfaz de integración con el GDC
NS	Nota Simple (Registral)	Tipología documental principal
IDUFIR	Identificador Único de Finca Registral	Identificador registral de la finca
NIF	Número de Identificación Fiscal	Identificador de persona/empresa
TDN1 / TDN2	Niveles de clasificación jerárquica del documento	Clasificación en una o dos fases

B.2 Azure / plataforma

Acrónimo	Significado	Contexto
DF	Durable Functions	Orquestador del pipeline (Azure Functions)
KV	Key Vault	Almacén de secretos y credenciales
MI	Managed Identity	Identidad gestionada para acceso a recursos
RBAC	Role-Based Access Control	Control de acceso por roles en Azure
RG	Resource Group	Grupo de recursos (SRBRGDOCSAIPROD)
KQL	Kusto Query Language	Consultas en Application Insights

B.3 IA / Content Understanding

Acrónimo	Significado	Contexto
CU	Azure Content Understanding	Proveedor de extracción/clasificación
DI	Azure Document Intelligence	Proveedor de extracción de layout/OCR
GPT	Generative Pre-trained Transformer	Modelo de Azure OpenAI (fallback de clasificación/extracción)
LLM	Large Language Model	Modelo de lenguaje (ruta GPT)
OCR	Optical Character Recognition	Reconocimiento de texto en el documento

B.4 Generales / técnicos

Acrónimo	Significado	Contexto
API	Application Programming Interface	Contratos HTTP REST
REST	Representational State Transfer	Protocolo de comunicación
SOAP	Simple Object Access Protocol	Protocolo del GDC y plugins legacy
JSON	JavaScript Object Notation	Formato de configuración/datos
SQL	Structured Query Language	Base de datos SQL Server
EF	Entity Framework Core	ORM de .NET
ORM	Object-Relational Mapping	Abstracción de base de datos
PDF	Portable Document Format	Formato de entrada de documentos
SHA256	Secure Hash Algorithm 256-bit	Hash de deduplicación
MD5	Message Digest 5	Hash complementario (deduplicación GDC)
CRC32	Cyclic Redundancy Check 32-bit	Checksum
HTTP	Hypertext Transfer Protocol	Protocolo de comunicación
BD / DB	Base de Datos / Database	SQL Server central
MVP	Minimum Viable Product	Etapas del proyecto

C. Conceptos Relacionados & Relaciones

Jerarquía de Configuración

Tipología (familia@version)

├ Modelos AI (clasificación, extracción, prompt, layout)

├ Umbrales Confianza

├ Reglas Validación (JSON)

├ Plugins por Prioridad

├ ┌ Plugin 1: AssetResolver

├ ┌ Plugin 2: Enriquecimiento REST

├ ┌ Plugin N: Validación custom

└ ConfiguraciónJson (flexible)

Flujo de Decisión en Clasificación

Documento recibido

- └─ ¿Duplicado (SHA256) + !forceReprocess? → Retorna cacheado
- └─ ¿ExpectedType informado? → Omite clasificación (confianza=1.0)
- └─ Clasificar: DefaultFlow + Global Fallback
 - └─ ¿Confianza < umbral? → BAJA_CONFIANZA_CLASIFICACION (parar)
 - └─ ¿Tipología resoluble? → Continúa extracción

Pipeline de Extracción (Fallback)

Documento normalizado

- Provider 1 (CU/DI primario)
 - └─ Éxito: Retorna datos
 - └─ Fallo/insuficiente: Continúa
- Provider 2 (CU/DI alternativo)
 - └─ Éxito: Retorna datos
 - └─ Fallo: Continúa
- GPT-4o-mini Fallback
 - └─ Último recurso (basado en Markdown + prompt)

Actividades Críticas vs Opcionales

Críticas (siempre ejecutadas):

- 1. Normalizar
- 2. Verificar Duplicado
- 3. Subir Blob
- 4. Clasificar
- 5. Resolver Tipología
- 6. Persistir

Condicionales (según configuración tipología):

- Extraer (si no baja confianza)
- Extraer Markdown Layout
- Prompt
- Validar
- ObtenerActivo (AssetResolver)
- IntegrarPlugins
- SubirGDC

D. Patrones & Buenas Prácticas

Patrones Recomendados

Patrón	Descripción	Beneficio
Cache Duplicados	Detectar SHA256 duplicados tempranamente, retornar resultado previo.	Ahorro CPU/latencia en reingestas.
Fallback Graceful	Clasificación con flujos + fallback; extracción con CU→DI→GPT.	Resiliencia ante fallos de providers.
Validación Temprana	Verificar tipología resoluble antes de extracción.	Evita procesamiento innecesario.
Trazabilidad Completa	Registrar actividad, duración, confianza, fallbacks en timeline.	Auditoría + debugging facilitado.
Plugins por Prioridad	Ejecutar plugins críticos primero, opcionales después.	Control de fallo, orden predecible.
ConfiguracionJson Flexible	Almacenar config en JSON BD en lugar de código.	Cambios sin redeploy.

Antipatrones a Evitar

Antipatrón	Problema	Solución
Reintentar Clasificación < Umbral	Desperdicia recursos sin incrementar confianza.	Marcar <code>BAJA_CONFIANZA_CLASIFICACION</code> y pausar.
Ignorar Fallback	Falla total si provider primario está down.	Implementar cascada de providers.
Omitir Deduplicación	Reprocesar documentos idénticos múltiples veces.	Verificar SHA256 tempranamente.
Config en Código Hardcoded	Cambios requieren redeploy, versioning complejo.	Usar ConfiguracionJson + admin API.
Plugins Sin Timeout	Bloquea pipeline indefinidamente.	Establecer timeouts generosos (120s GDC).
Omitir Trazabilidad	No hay evidencia de decisiones.	Registrar timeline completa.

E. Referencias Cruzadas

Documentación Relacionada

Documento	Propósito	Enlace
Diseño Técnico Detallado	Arquitectura pipeline, diagrama flujo, actividades.	03_DISENO_TECNICO_DETALLADO.md
Análisis Funcional	Casos de uso, actores, CU1-CU6.	02_ANALISIS_FUNCIONAL.md
Manual Validaciones	Especificación motor validación, 11 tipos.	docs/manuales/MANUAL_VALIDACIONES.md
Manual Plugins	Arquitectura plugins, integración REST/SOAP.	docs/manuales/MANUAL_PLUGINS.md
Especificación AssetResolver	Detalles búsqueda activos, criterios AND/OR.	docs/especificaciones/ESPECIFICACION_PLUGIN_ASSETRESOLVER.md
Fuente Verdad Configuración	Autoridad canónica BD config.	docs/referencias/FUENTE_VERDAD_CONFIGURACION.md
Plantilla Plugins JSON	Formato config plugins.	docs/contratos/PLANTILLA_PLUGINS_JSON.md
Checklists Despliegue	Validación pre-prod + prod.	docs/08_CHECKLISTS_DESPLIEGUE.md
API Documentation v1.4	Contratos REST endpoints.	docs/15_API_DOCUMENTATION_V1_4.md

Endpoints REST Principales

Caso de Uso	Endpoint	Método	Documentación
CU1: Ingestar Documento	<code>/api/IngestDocument</code>	POST	02_ANALISIS_FUNCIONAL.md - CU1
CU2: Consultar Estado	<code>statusQueryUri</code> (Durable)	GET	02_ANALISIS_FUNCIONAL.md - CU2
CU3: Gestionar Tipologías	<code>/management/tipologias/*</code>	GET/POST/PUT	02_ANALISIS_FUNCIONAL.md - CU3
CU4: Gestionar Modelos IA	<code>/management/modelos/*</code>	GET/POST/PUT/DELETE	02_ANALISIS_FUNCIONAL.md - CU4
CU5: Configurar Plugins	<code>/management/plugins-tipologias/*</code>	GET/PUT	02_ANALISIS_FUNCIONAL.md - CU5

Componentes Clave en Codebase

Componente	Ruta	Rol
Orchestrator	src/backend/DocumentIA.Functions/Orchestrators/DocumentProcessOrchestrator.cs	Orquestación principal
Activities	src/backend/DocumentIA.Functions/Activities/	14 activity functions
Tipología Config	src/backend/DocumentIA.Core/Models/TipologiaConfig.cs	Modelo configuración
Validation Engine	src/backend/DocumentIA.Core/Validation/ValidationEngine.cs	Motor validaciones
Plugin Manager	src/backend/DocumentIA.Core/Plugins/PluginManager.cs	Integración plugins
Asset Resolver Plugin	src/plugins/DocumentIA.AssetResolver/	Plugin búsqueda activos
Admin Portal	src/frontend/DocumentIA.Admin/	Gestión tipologías/modelos

Notas Finales

- Este glosario se mantiene como referencia viva. Cambios en conceptos o introducción de nuevos términos deben documentarse aquí.
- Para detalles profundos de implementación, consultar documentos especializados en la carpeta docs/ y comentarios en código.
- Las definiciones priorizan claridad sobre exhaustividad; para casos edge o detalles arquitectónicos, remitir a documentación técnica específica.
- Las URLs de referencias asumen estructura de carpetas de DocumentIA MVP; validar rutas antes de usar en otros contextos.

Glosario generado: 2026-06-10
Versión: 1.0