


3. Diseno Tecnico Detallado — DocumentIA MVP

Proyecto: AI DocClassExt — SAREB

Nota: Versión v1.4+ con ConfiguracionJson refactorizado. El campo `Tipologias.PromptGPT` está deprecado (ver [12_MIGRACION_PROMPTGPT_V1_4.md](#)); las columnas legacy asociadas se han retirado del schema.

3.1 Diagrama de Flujo del Pipeline

El pipeline de procesamiento esta orquestado por `DocumentProcessOrchestrator` (Durable Functions). Ejecuta 14 actividades en secuencia con multiples puntos de decision.



Detalle de las 14 Actividades

#	Actividad	Clase	Input principal	Output principal	Notas
1	Normalizar	NormalizarActivity	byte[] PDF	SHA256, MD5, CRC32, Paginas	Calculo de hashes e info PDF
2	VerificarDuplicado	VerificarDuplicadoActivity	SHA256	Resultado previo o null	Busca en BD por SHA256 (indice unico)
3	ObtenerUltimaEjecucion	ObtenerUltimaEjecucionActivity	SHA256	Ultima ejecucion o null	Solo si no es duplicado y no skipDuplicateCheck
4	SubirBlob	SubirBlobActivity	byte[] + nombre	URL blob	Container documents/
5	Clasificar	ClasificarActivity	byte[] PDF	TipologiaDetectada, Confianza	Pipeline configurable por flujo (resuelto desde Classification.Flows + Classification.DefaultFlow), secuencial hasta satisfactorio y fallback global final. PostConfigure en Program.cs carga diccionario Flows desde configuracion.
6	ResolverTipologia	ResolverTipologiaActivity	codigo tipologia	TipologiaConfig completa	Resuelve familia@version → config
7	Extraer	ExtraerActivity	byte[] + tipologia config	DatosExtraidos (Dictionary)	CU/DI/GPT segun config
8	ExtraerMarkdownLayout	ExtraerMarkdownLayoutActivity	byte[] PDF	Markdown texto	Layout extraction con DI. Se omite si instrucciones.classification.markdown viene informado (D4): en ese caso el markdown aportado se inyecta directamente en datosNormalizados["Markdown"] .
9	Prompt	PromptActivity	datos + markdown + prompt config	Datos prompt enriquecidos	GPT-4o-mini con prompt libre (opcional)
10	Validar	ValidarActivity	DatosExtraidos + reglas JSON	ValidationReport	11 tipos de validador
11	ObtenerActivo	ObtenerActivoActivity	DatosExtraidos + config AssetResolver	ResultadoAssetResolver	Busca activo por IDUFIR/RefCatastral/Direccion en DM_POSICION_AAI_TB. Criterios configurables con AND/OR. Ver ESPECIFICACION_PLUGIN_ASSETRESOLVER.md .
12	Integrar	IntegrarActivity	datos + tipologia + plugins config	DatosFinales + plugins results	Ejecucion por prioridad
13	SubirGDC	SubirGDCActivity	documento + metadata GDC	ObjectId GDC	SOAP (searchEntities + create) con timeout 120s
14	Persistir	PersistirActivity	ContratoSalida completo	void	BD + auditoria

3.1.1 Comportamiento del orquestador segun entrada y configuracion

El flujo del orquestador no depende solo del tipo de documento, sino tambien de la combinacion de entrada y configuracion activa. Este diagrama resume las ramas que cambian el comportamiento real.

Preflujo adicional cuando se usa `documento.objectIdGDC`

Cuando la entrada viene por referencia GDC (`objectIdGDC`), antes del pipeline estándar se ejecuta un preflujo con operaciones SOAP `get` :

1. `ObtenerMetadatosDocumentoGDCActivity` (lectura de metadatos sin contenido).
2. `VerificarDuplicadoPorMD5Activity` (deduplicación temprana por checksum MD5 en BD local).
3. `ObtenerDocumentoGDCActivity` (descarga de contenido Base64 para hidratar el documento).

En este modo se fuerza `SkipGDCUpload=true` para evitar re-subida del mismo documento origen.

Actualización PRD v2.1: Paso 2.7 (Preparación para clasificación)

Se incorpora una preparación explícita del PDF para clasificación entre `SubirBlobActivity` y `ClasificarActivity`.

Implementación:

- Activity: `PrepararDocumentoClasificacionActivity`
- Servicio: `PdfRecorteService`
- Contrato: `PrepararDocumentoClasificacionInput` / `PrepararDocumentoClasificacionResultado`

Comportamiento:

1. Si `ClassificationPreparation.Enabled=true`, se calcula `MaxPaginas` efectivo con precedencia `tipologia > familia > default`.
2. Se recorta el PDF para clasificación cuando el total de páginas excede `MaxPaginas`.
3. Se propagan metadatos a clasificación mediante `ClasificacionInput` :

- `DocumentoBase64Override`
- `CharsTextoNativo`
- `TotalPaginas`

4. Si la preparación falla, el orquestador continúa con documento completo (fallback seguro).

Alcance:

- Impacta la etapa de clasificación y el resumen inicial cuando ese resumen se obtiene en clasificación.
- En flujo completo (`classificationOnly=false`), antes de `Extraer / Prompt` se recompone `datosNormalizados["Markdown"]` con el documento completo cuando la clasificación trabajó con recorte.
- `ExtraerActivity` y `SubirGDCActivity` siguen usando el documento completo.

Rama `ClassificationOnly` (nuevo)

Cuando `instrucciones.classificationOnly=true`, tras `Clasificar` y `ResolverTipologia` se aplica una rama reducida:

- `Extraer`, `Validar` y `ObtenerActivo` no se ejecutan y quedan como `Skipped` en `detalleEjecucion.seguimiento`.
- `Prompt` se ejecuta solo si hay prompt propio/ad-hoc aplicable o si `instrucciones.forzarResumenPorDefecto=true` y no hubo una llamada GPT previa que produjera `Resumen`.
- `Integrar` solo se ejecuta si `instrucciones.executeIntegrarWhenClassificationOnly=true` y existe `trazabilidad.idActivo`.
- `SubirGDC` mantiene la prioridad de `SkipGDCUpload` y requiere `idActivo` resuelto/disponible.
- `Persistir` siempre se ejecuta.

Trazas operativas expuestas en salida:

- `detalleEjecucion.classificationOnly` : confirma si la ejecución quedó en rama reducida.
- `detalleEjecucion.recorteAplicado` y `detalleEjecucion.paginasIncluidas` : auditan el recorte real usado para clasificación.
- `detalleEjecucion.markdownGenerado` y `detalleEjecucion.origenMarkdown` : indican si se generó markdown y en qué etapa quedó fijado.
- `detalleEjecucion.modeloLLMUsado` : refleja el modelo LLM efectivo cuando hubo fallback/prompt.
- `detalleEjecucion.motivoErrorTipologia` : registra el motivo cuando la tipología no pudo resolverse.

Restricción de entrada:

- `classificationOnly=true` es incompatible con `expectedType` informado (validación en trigger HTTP, respuesta `400`).

Prompt por defecto y prompt de tipología

El sistema separa dos salidas de prompting para mantener compatibilidad y controlar coste de llamadas LLM:

- `DatosExtraidos["Resumen"]` : resumen ejecutivo generado con la configuracion global `PromptDefaults` .
- `DatosExtraidos["ResultadoPrompt"]` : salida del prompt propio de tipologia o del prompt ad-hoc de la peticion.

Reglas de ejecucion:

- Si la clasificacion o extraccion ya usa GPT, el orquestador solicita `Resumen` en esa misma llamada cuando es posible.
- En clasificacion jerarquica GPT con `nivelClasificacion="TDN1"` , la fase 1 puede devolver `resumen` y se propaga a `DatosExtraidos["Resumen"]` sin esperar a fase 2.
- Si la ruta DI/CU es satisfactoria y no llega a GPT, no se hace llamada adicional solo para resumen salvo que `instrucciones.forzarResumenPorDefecto=true` .
- Si `forzarResumenPorDefecto=true` y no existe `Resumen` , `PromptActivity` ejecuta una llamada dedicada.
- Si esa llamada dedicada coincide con un prompt propio/ad-hoc pendiente, ambos objetivos se combinan en una unica llamada y se devuelven `Resumen` y `ResultadoPrompt` por separado.
- Una tipologia con `promptConfig.enabled=true` pero `systemPrompt` y `userPromptTemplate` vacios no activa `ResultadoPrompt` ; requiere definicion real o prompt ad-hoc.
- Si el resumen procede de una clasificacion con recorte real (`paginasIncluidas < paginasDocumento`), se anade sufijo de transparencia: `* Resumen basado en las primeras {N} paginas del documento` .

Clasificación Jerárquica GPT (nivelClasificacion) — D1, D2, D4, D6, D7

Cuando se informa `instrucciones.classification.nivelClasificacion` :

D2 — Force provider GPT (`IngestAPITrigger.cs`):

- Si `nivelClasificacion` no está vacío, se aplica `ClassificationLevelResolver.ApplyTo()` para resolver el nivel.
- Tras el resolver, si el nivel fue explícito, se fuerza `classification.Provider = "gpt"` independientemente de lo indicado en la petición.

D4 — Markdown pre-procesado (`DocumentProcessOrchestrator.cs` , antes del paso 2.8):

- Si `entrada.Instrucciones.Classification.Markdown` no es null ni vacío, se inyecta en `datosNormalizados["Markdown"]` y se omite la llamada a `ExtraerMarkdownLayoutActivity` .

D1 — Clasificación parcial reestructurada (`DocumentProcessOrchestrator.cs` , bloque `ClasificacionParcial`):

- Si `clasificacion.ClasificacionParcial = true` :
 - Si `tipologiaParcial == null || "Desconocido"` → **tipología virtual**: `salida.Identificacion.PropuestaTipologia = propuestaLibre` , `salida.Identificacion.Tipologia = "Desconocido"` , pipeline detenido, estado `OK` .
 - Si `tipologiaParcial` es un código TDN1 conocido → **código conocido**: `salida.Identificacion.Tdn1 = tipologiaParcial` , el pipeline continúa normalmente (extracción, validación, plugins). Estado final determinado por el resto del pipeline.

D6 — PropuestaTipologia en salida (`ContratoSalida.cs`):

- Nueva propiedad `Identificacion.PropuestaTipologia` (string, inicializada a `string.Empty`). Solo se informa cuando hay tipología virtual.

D7 — NivelClasificacion en clave de deduplicación:

- `ContratoSalida.DetalleEjecucion.NivelClasificacion` (string?) — refleja el valor de la petición.
- `DocumentoEjecucionEntity.NivelClasificacion` (nvarchar(20) NULL) — migración `20260525151946_AddNivelClasificacionToEjecuciones` .
- `ObtenerUltimaEjecucionDuplicadoActivity` incluye `NivelClasificacion` en el filtro LINQ in-memory.
- `PersistirActivity` persiste el valor en la entidad BD.

Deduplicación:

- La reutilización de ejecuciones previas se confronta por `SHA256 + ClassificationOnly + NivelClasificacion` para evitar mezclar procesos completos con procesos de solo clasificación, y para distinguir ejecuciones con distinto nivel jerárquico GPT.

Limit pages en ClassificationOnly:

- Si `instrucciones.maxPagesForClassificationOnly > 0`, la orquestación aplica recorte defensivo del PDF a las primeras N páginas justo antes de `Clasificar`.
- El documento original completo se mantiene para integridad, blob y trazabilidad; el recorte afecta solo al payload utilizado en clasificación.
- En flujo no `classificationOnly`, tras clasificar con recorte se regenera markdown del documento completo antes de extracción/prompt para evitar contaminar pasos posteriores con contexto parcial.
- Si el resumen se genera durante la clasificación recortada, se marca explícitamente como parcial con el sufijo de transparencia indicado arriba.
- Se registran métricas operativas: páginas originales, páginas usadas, límite configurado y si el recorte fue aplicado.

Adicionalmente, cuando `documento.name` llega vacío y se resuelve desde GDC durante este preflujo, el nombre se sincroniza en `salida.Identificacion.Documento` antes de persistir. Como defensa final, `PersistirActivity` aplica fallback determinista si el nombre siguiera vacío para cumplir la restricción `NOT NULL` de `Documentos.NombreArchivo`.

Anexo integrado: detalle operativo de Activities

El contenido operativo del antiguo `docs/not in use/MANUAL_ACTIVITIES_AZURE_FUNCTIONS.md` queda integrado en este documento canónico.

Resumen de comportamiento por activity:

- `NormalizarActivity`: hidrata/decodifica documento y calcula integridad (SHA256 , MD5 , CRC32) y metadatos de páginas.
- `VerificarDuplicadoActivity`: consulta duplicidad por SHA256 ; con `forceReprocess=false` permite retorno temprano de ejecución previa.
- `SubirBlobActivity`: persiste binario en blob (`documents/`) para trazabilidad operativa.
- `ClasificarActivity`: resuelve un flujo configurable de providers y los ejecuta en orden hasta resultado satisfactorio; si no hay resultado, aplica fallback global final si está activo. Fallback chain: `RuleBasedTdnClassifier` → `DocumentIntelligenceProvider` → `FoundryTdnRescueClassifier` → `GptClasificarDataProvider` (two-phase).
- `GptClasificarDataProvider`: implementa clasificación jerárquica de dos fases:
 - **Phase 1 (TDN1 Family Selection)**: Consulta prompts enriquecidos con todas las familias TDN1 disponibles. Envía al LLM: catálogo TDN1 con formato "- CODIGO_TDN1: Descripcion". Espera respuesta JSON: `{"tdn1": "CODIGO" | null, "propuesta": "...", "confianza": 0.0-1.0}`. Cache por petición, 5 min TTL vía `IMemoryCache`.
 - **Phase 2 (TDN2 Specific Typology)**: Una vez resuelta familia TDN1, consulta catálogo enriquecido de tipologías para esa familia. Catálogo contiene: `- TIPOLOGIA_CODIGO [TDN2_CODE: TDN2_NAME] gptdescripcion` donde `TipologiaNombre` y `gptdescripcion` provienen de `ConfiguracionJson` (poblados desde BD). Envía al LLM: instrucciones mejoradas con contexto SAREB sector, ejemplos de formato fallback, límite 200 caracteres. Espera: `{"tdn2": "CODIGO_TDN2", "confianza": 0.0-1.0}`.
 - **Self-Reported Confidence**: GPT reporta su certeza sobre la clasificación mediante campo `confianza` (0.0 = incierto, 1.0 = muy seguro). El parser extrae el valor, aplica `Math.Clamp(0.0, 1.0)` automático, y usa fallback a 0.9 si el campo está ausente. Logging detallado: `ConfianzaSelfReported` vs `ConfianzaFinal`.
 - **Catalog Enrichment**: Cada tipología publicada en la familia aporta: `tipologiacodigo` (ESCR-06), `tipologiaNombre` (Escritura: venta), `tdn2` (ESCR-06), `gptdescripcion` (texto enriquecido con descripción principal, contexto descriptivo, criterio de clasificación automática).
 - **Model Resolution**: Modelo LLM resuelto por petición desde `instrucciones.classification.model` (si viene explícito y válido). `auto` /vacío usa fallback del registro (`useAsFallback=true`). Cliente de chat creado dinámicamente por petición para evitar lock-in de deployment.
 - **Fallback Mapping**: `ResolveTipologiaByTdn2()` mapea TDN2 code a tipología final (ej., ESCR-06 → tipología con `ResolvedTdn2='ESCR-06'`).
- `ClassificationTipologiaPromptBuilder`: construye catálogos dinámicos. `BuildTdn1Catalog()` devuelve todas las familias TDN1 publicadas. `BuildTdn2CatalogByFamilia(tdn1Code)` consulta `ITipologiaRepository` directamente, filtra por `ResolvedTdn1 = familia`, retorna todas las tipologías `published+activas` con `ConfiguracionJson` poblado (incluyendo `tipologiaNombre` [nuevo campo] + `gptdescripcion` campos). El campo `Nombre` en `TdnCatalogItem` se resuelve desde `TipologiaConfig.TipologiaNombre` en tiempo de consulta, enriqueciendo los catálogos con nombre legible de tipología para GPT. Respeta cache 5-min TTL.
- `ResolverTipologiaActivity`: resuelve configuración efectiva por familia/version.
- `ExtraerActivity`: ejecuta extracción principal y fallback cuando aplica.
- `ValidarActivity`: ejecuta motor de reglas y produce reporte de validación.
- `ObtenerActivoActivity`: resuelve activo vía `AssetResolver` según criterios configurados.
- `IntegrarActivity`: aplica plugins por prioridad y consolida `DatosFinales`.
- `SubirGDCActivity`: gestiona deduplicación previa (`searchEntities`) y subida (`create`) con timeout de 120s en orquestación.
- `PersistirActivity`: persiste resultado integral y auditoría.

Estados funcionales de cierre del pipeline:

- OK
- OK (*clasificación parcial — tipología virtual*): cuando `nivelClasificacion` activo y tipología no mapeada al catálogo. `identificacion.tipologia = "Desconocido"`, `identificacion.propuestaTipologia` informado. Pipeline detenido antes de extracción.
- NO_CLASIFICADO : clasificación parcial con código TDN1 conocido pero tipología TDN1/TDN2 no resuelta. Pipeline continúa con tipología parcial.
- VALIDACION_CON_ERRORES
- DUPLICADO
- BAJA_CONFIANZA_CLASIFICACION
- ERROR

3.1.2 Vinculación de flujos de clasificación — Estructura de configuración

Binding de Configuration en Program.cs

La configuración de flujos se define en `appsettings.json` como una estructura anidada compleja:

```
"Classification": {
  "DefaultFlow": "hybrid-rules-gpt-di",
  "UseGlobalFallback": true,
  "GlobalFallbackProvider": "gpt",
  "Flows": {
    "hybrid-rules-gpt-di": { "Providers": ["rules", "gpt", "di"] },
    "hybrid-rules-di-gpt": { "Providers": ["rules", "di", "gpt"] },
    "hybrid-tdn": { "Providers": ["hybrid-tdn"] },
    "di": { "Providers": ["di"] },
    "gpt": { "Providers": ["gpt"] }
  }
}
```

Problema conocido: .NET ConfigurationBuilder no deserializa automáticamente estructuras anidadas complejas como `Dictionary<string, ClassificationFlowSettings>` desde JSON. Por ello, en `Program.cs` se implementa un patrón `PostConfigure` explícito:

```
services.Configure<ClassificationRoutingSettings>(context.Configuration.GetSection("Classification"));

// Manual binding para diccionario Flows (limitación de .NET config binding con estructuras JSON complejas)
services.PostConfigure<ClassificationRoutingSettings>(settings =>
{
    var flowsSection = context.Configuration.GetSection("Classification:Flows");
    if (flowsSection.Exists())
    {
        foreach (var flowSection in flowsSection.GetChildren())
        {
            var flowName = flowSection.Key;
            var flowSettings = new ClassificationFlowSettings();
            flowSection.Bind(flowSettings);
            settings.Flows[flowName] = flowSettings;
        }
    }
});
```

Impacto: Sin este `PostConfigure`, el diccionario `Flows` quedaria vacío en runtime, causando que `ConfigurableClasificarDataProvider` no encontrara flujos nombrados y fallara con `NotSupportedException`.

Sincronización local.settings.json: Para desarrollo local, asegurar que `local.settings.json` incluya la misma estructura de `Classification:Flows` que `appsettings.json` (Variables de entorno en formato plano). Ejemplo:


```
"Classification:Flows:hybrid-rules-di-gpt:Providers:0": "rules",
"Classification:Flows:hybrid-rules-di-gpt:Providers:1": "di",
"Classification:Flows:hybrid-rules-di-gpt:Providers:2": "gpt"
```


Resolución de flujo en tiempo de ejecución

En `ConfigurableClasificarDataProvider.ResolveFlowProviders()` (línea 164):

1. Si `instrucciones.classification.flujo` viene informado explícitamente, se busca en `_routingSettings.Flows`.
2. Si la clave existe, se devuelve la secuencia configurada de providers.
3. Si no existe, se devuelve `[flowName]` directamente (fallback: intenta ese nombre como single provider).
4. Si en `ExecuteProviderAsync` no hay case para ese nombre, falla con `NotSupportedException`.

Esta estructura garantiza backward-compatibility: configuraciones legacy con un único provider siguen funcionando.

3.2 Diagrama de Secuencia End-to-End



3.3 Estructura de tipología v1.2 (gdc/classification)

Desde mayo 2026, la configuración JSON de tipologías adopta bloques jerárquicos para metadatos de clasificación y GDC.

Estructura canónica:

```
{
  "tipologiaId": "nota-simple",
  "tipologiaNombre": "Nota simple",
  "version": "1.4",
  "gdc": {
    "skipUpload": false,
    "matricula": "AI-01-NOTS-01",
    "tipoDocumento": "NOTS",
    "subtipoDocumento": "NOTS01",
    "serie": "AI09"
  },
  "classification": {
    "tdn1": "...",
    "tdn2": "...",
    "gptDescripcion": "...",
    "enableRules": true
  },
  "classificationConfig": {
    "examplePhrases": [],
    "disambiguationHints": []
  }
}
```


Compatibilidad backward:

- El backend mantiene fallback por propiedades resueltas (`Resolved*`) para leer tanto el formato v1.2 como el legacy de raíz (`gdcTipoDocumento` , `tdn1` , `gptDescripcion` , etc.).
- En edición/creación se persiste formato v1.2 y, temporalmente, también campos legacy redundantes para no romper consumidores previos.

Fuente de configuración:


- Producción opera exclusivamente contra BBDD (`Tipologias.ConfiguracionJson`).
- Se elimina la ruta legacy de lectura por ficheros para resolver/cargar tipologías en runtime.

3.3 Diagrama de Secuencia — Motor de Validación




3.4 Diagrama de Clases — Subsistemas Principales


3.4.1 Contratos API




3.4.2 Interfaces de Proveedores




3.4.3 Sistema de Plugins




3.4.4 Motor de Validacion



3.4.5 Subsistema AssetResolver



3.5 Modelo Entidad-Relacion



Indices Configurados en OnModelCreating

Entidad	Indice	Tipo
DocumentoEntity	SHA256	Unique
DocumentoEntity	CorrelationId	Non-unique
DocumentoEntity	Estado	Non-unique
TipologiaEntity	Codigo	Unique
ModeloConfigEntity	Key	Unique
PluginTipologiaConfigEntity	TipologiaCodigo	Unique
DocumentoEjecucionEntity	EjecucionGuid	Unique
DocumentoEjecucionEntity	FechaEjecucion	Non-unique
PluginEjecucionEntity	(EjecucionId, PluginKey)	Compuesto
ValidacionResultadoEntity	(EjecucionId, Campo)	Compuesto

3.6 Motor de Reglas de Validacion

3.6.1 Arquitectura

El motor sigue el patron **Strategy**: cada tipo de regla implementa `IValidationRule` con un `RuleType` string discriminator. Las reglas se registran en `ValidationEngine` por tipo y se resuelven dinamicamente al ejecutar la validacion.

3.6.2 Tipos de Regla

RuleType	Clase	Parametros	Ejemplo
required	RequiredFieldValidator	—	Campo obligatorio, no vacio
regex	RegexValidator	pattern	"pattern": "^\\d{14}\$" para IDUFIR
range	RangeValidator	min , max	Importes 0-999999999
dateFormat	DateFormatValidator	format	"format": "dd/MM/yyyy"
length	LengthValidator	minLength , maxLength	NIF: 9-9 caracteres
nif	NifValidator	—	Validacion algoritmica NIF/NIE/CIF espanol
enum	EnumValidator	values[]	["Plena", "Nuda", "Usufructo"]
catastralReference	CatastralReferenceValidator	—	20 chars, formato catastral espanol
address	AddressValidator	—	Estructura basica de direccion
boolean	BooleanValidator	—	true/false/si/no
array	ArrayValidator	minItems , maxItems , itemRules[]	Arrays de titulares

3.6.3 Esquema de Configuracion JSON


```

{
  "tipologiaId": "nota.simple.1_4",
  "version": "1.4",
  "extractionConfig": {
    "expectedFields": [
      "FincaRegistral", "IDUFIR_CRU", "Direccion",
      "ReferenciaCatastral", "FechaDocumento"
    ]
  },
  "confidenceConfig": {
    "umbralOK": 0.85,
    "umbralRevision": 0.70
  },
  "fields": {
    "FincaRegistral": {
      "rules": [
        { "type": "required", "severity": "Error", "message": "Finca registral es obligatoria" },
        { "type": "regex", "severity": "Warning", "params": { "pattern": "^\\d+$" }, "message": "Formato numerico esperado" }
      ]
    },
    "IDUFIR_CRU": {
      "rules": [
        { "type": "required", "severity": "Warning" },
        { "type": "regex", "severity": "Error", "params": { "pattern": "^\\d{14}$" }, "message": "IDUFIR debe tener 14 digitos" }
      ]
    },
    "Titulares": {
      "rules": [
        { "type": "required", "severity": "Error" },
        { "type": "array", "severity": "Error", "params": { "minItems": 1 } }
      ]
    },
    "NIF_Titular": {
      "rules": [
        { "type": "nif", "severity": "Error", "message": "NIF/NIE/CIF invalido" }
      ]
    },
    "ReferenciaCatastral": {
      "rules": [
        { "type": "catastralReference", "severity": "Warning" }
      ]
    },
    "FechaDocumento": {
      "rules": [
        { "type": "required", "severity": "Warning" },
        { "type": "dateFormat", "severity": "Error", "params": { "format": "dd/MM/yyyy" } }
      ]
    }
  }
}

```

3.6.4 Calculo de Confianza de Validacion


erroresCount = campos con al menos una regla severity=Error que falla
totalRequired = total de campos con al menos una regla severity=Error configurada

$$\text{ConfianzaValidacion} = 1.0 - (\text{erroresCount} / \text{totalRequired})$$

Si totalRequired = 0 (sin reglas Error), ConfianzaValidacion = 1.0 .

3.7 Sistema de Plugins

3.7.1 Ciclo de Vida



3.7.2 Resiliencia (ResilientPlugin)

Retry con backoff exponencial:
delay = InitialDelayMs * 2^(attempt - 1)
Ejemplo: 500ms → 1000ms → 2000ms → 4000ms

Circuit Breaker:

- ConsecutiveFailures >= 5 → Estado OPEN
- OPEN durante 5 minutos → Estado HALF_OPEN
- HALF_OPEN: 1 intento → exito = CLOSED, fallo = OPEN

3.7.3 Esquema Configuracion Plugins JSON

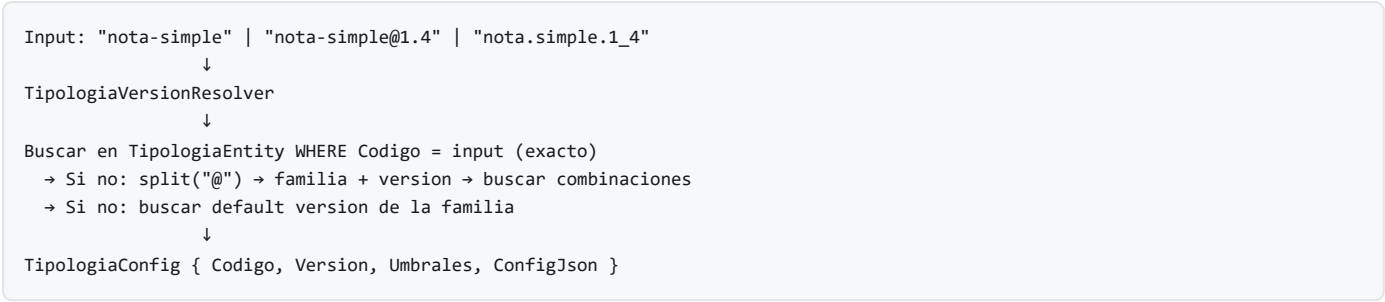
```
{
  "tipologiaCodigo": "nota.simple.1_4",
  "plugins": [
    {
      "pluginKey": "refCatExcel",
      "pluginType": "REST",
      "enabled": true,
      "priority": 1,
      "configuration": {
        "baseUrl": "https://api.ejemplo.com/catastro",
        "method": "POST",
        "headers": { "Authorization": "Bearer <TOKEN>" },
        "bodyTemplate": "{ \"referencia\": \"{ReferenciaCatastral}\" }",
        "responseMapping": {
          "idActivo": "$.result.idActivo",
          "direccionEnriquecida": "$.result.direccion"
        },
        "returnsIdActivo": true
      },
      "retryPolicy": {
        "maxRetries": 3,
        "initialDelayMs": 500
      }
    }
  ]
}
```

3.7.4 Tipos de Plugin

Tipo	Clase	Comunicacion	Uso tipico
REST	RestPlugin	HTTP/HTTPS (JSON)	APIs externas (catastro, atlas, enriquecimiento)
SOAP	SoapPlugin	HTTP/HTTPS (XML/SOAP)	Servicios corporativos legacy
Custom	CustomPlugin	DLL .NET cargada en proceso	Logica de negocio especifica (transformaciones, Excel)

3.8 Configuracion Multi-Tipologia

3.8.1 Resolucion de Tipologia



3.8.2 Archivos de Configuración por Tipología

Los archivos JSON en `config/tipologias/` son únicamente **fuentes de seed**: al arrancar la Function App, `ConfigurationSeedService` los lee y los inserta en BD si no existen. En tiempo de ejecución, **toda la configuración se lee exclusivamente desde base de datos**.

Archivo (solo seed)	Propósito	Tabla BD en runtime
<code>{codigo}.validation.json</code>	Reglas de validación por campo	<code>Tipologias.ConfiguracionJson</code>
<code>{codigo}.plugins.json</code>	Plugins de integración	<code>PluginTipologiaConfigs.ConfiguracionJson</code>
<code>config/extraction/models.json</code>	Modelos de extracción	<code>ModeloConfigs</code> (tipo = Extraccion)
<code>config/classification/models.json</code>	Modelos de clasificación	<code>ModeloConfigs</code> (tipo = Clasificacion)
<code>config/prompt/models.json</code>	Modelos de prompt	<code>ModeloConfigs</code> (tipo = Prompt)
<code>config/layout/models.json</code>	Modelos de layout markdown	<code>ModeloConfigs</code> (tipo = Layout)

Nunca editar los JSON de `config/` para cambiar el comportamiento en producción. Para modificar tipologías, modelos o plugins existentes, usar `DocumentIA.Admin` o los endpoints de la Admin API y publicar el cambio en BD. Los archivos JSON siguen siendo útiles como respaldo, plantilla o re-seed en un entorno nuevo, pero pueden estar desactualizados y no deben borrarse sin confirmación explícita.

3.8.3 Ciclo de Vida Draft → Published → Retired

Accion	Endpoint	Efecto
Crear	<code>POST /management/tipologias</code>	Estado = Draft
Editar	<code>PUT /management/tipologias/{id}</code>	Solo en Draft
Publicar	<code>POST /management/tipologias/{id}/publicar</code>	Draft → Published. Visible en pipeline.
Retirar	<code>POST /management/tipologias/{id}/retirar</code>	Published → Retired. Invisible en pipeline.
Reactivar	<code>POST /management/tipologias/{id}/draft</code>	Retired/Published → Draft

3.9 Manejo de Errores en Durable Functions

3.9.1 Patron EjecutarPasoNegocio

Todas las actividades se invocan via el wrapper `EjecutarPasoNegocio<T>()` del orchestrator:

```
// Pseudocodigo del patron
async Task<T> EjecutarPasoNegocio<T>(string nombre, Func<Task<T>> accion)
{
    MarcarInicioActividad(nombre);
    PublicarEstado(nombre, "Running");
    try
    {
        var resultado = await accion();
        MarcarFinActividad(nombre, "Completed");
        return resultado;
    }
    catch (Exception ex)
    {
        MarcarFinActividad(nombre, "Failed", ex.Message);
        throw; // re-throw para que el orchestrator gestione
    }
}
```

3.9.2 Early Exits (Salidas Anticipadas)

Condicion	Actividad	Estado final	Se persiste?
Documento duplicado, lforceReprocess	VerificarDuplicado	DUPLICADO (reutilizado)	No (ya existe)
Confianza clasificacion < umbral	Clasificar	BAJA_CONFIANZA_CLASIFICACION	Si (parcial)
Tipologia no resuelta	ResolverTipologia	ERROR	Si (parcial)

3.9.3 Timeout GDC

```
// Patron timeout en orchestrator
var gdcTask = context.CallActivityAsync<ResultadoGDC>("SubirGDC", input);
var timeoutTask = context.CreateTimer(context.CurrentUtcDateTime.AddSeconds(120), CancellationToken.None);

var winner = await Task.WhenAny(gdcTask, timeoutTask);
if (winner == timeoutTask)
{
    // Marca timeout, continua a Persistir
    resultadoGDC = new ResultadoGDC { Exitoso = false, Mensaje = "Timeout" };
}
```

3.9.4 Degradacion Graceful

Fallo	Comportamiento
AI Service no disponible	Fallback a proveedor alternativo (DI → GPT, CU → GPT)
Plugin no critico falla	Log warning, continuar con siguiente plugin
Plugin critico (P=1) falla	Detener cadena plugins, datos parciales se preservan
GDC timeout/error	Marca error en GDC, continua a persistencia
BD no disponible	Exception no capturada → runtimeStatus = Failed

3.10 Proteccion de Datos y Seguridad


3.10.1 Estado Actual (MVP)

Aspecto	Implementacion
Autenticacion API	<code>AuthorizationLevel.Function</code> (x-functions-key)
Credenciales AI	Configuration (local) / Key Vault (Azure)
Credenciales GDC	Basic Auth via configuration
SSL GDC	Bypass configurable (<code>DisableSslValidation</code>) para CA interna
Datos en transito	HTTPS (Functions + AI Services + Blob)
Datos en reposo BD	TDE (Azure SQL) / sin cifrado (Docker local)
Datos en reposo Blob	SSE con Microsoft-managed keys
Logs	Structured logging (sin implementación específica de masking PII en MVP)

3.10.2 Protección de datos y GDPR

La protección de datos y GDPR queda fuera del alcance del MVP por decisión de producto, por lo que no se considera funcionalidad pendiente. Si se retoma en el futuro, deberá redefinirse el alcance técnico como una nueva iniciativa.

3.11 Diagrama de Estados del Documento



3.12 Contratos API Completos

3.12.1 POST /api/IngestDocument — Request

```
{
  "instrucciones": {
    "expectedType": "",
    "skipDuplicateCheck": false,
    "forceReprocess": false,
    "skipGDCUpload": null,
    "classification": {
      "provider": "auto",
      "model": "auto",
      "umbral": null,
      "umbralCompleitud": null,
      "umbralConfianza": null
    },
    "extraction": {
      "provider": "auto",
      "model": "auto",
      "umbral": null,
      "umbralCompleitud": 0.9,
      "umbralConfianza": null
    },
    "assetResolver": {
      "enabled": true,
      "camposBusqueda": {
        "idufir": "FileName_NewIDUFIR",
        "referenciaCatastral": null
      },
      "camposSolicitados": ["#ALL#"]
    }
  },
  "documento": {
    "name": "nota_simple_finca_12345.pdf",
    "objectIdGDC": null,
    "content": {
      "base64": "JVBERi0xLjcKMSAw..."
    }
  },
  "trazabilidad": {
    "correlationId": "a1b2c3d4-0000-0000-0000-000000000000",
    "submittedBy": "sistema-batch-sareb",
    "idActivo": "ACT-2026-00123"
  }
}
```

Reglas de validación del trigger:

- `documento.objectIdGDC` y `documento.content.base64` son mutuamente excluyentes.
- Debe informarse exactamente una fuente de documento.
- Si se usa `documento.objectIdGDC`, el backend fuerza `instrucciones.skipGDCUpload = true`.

3.12.2 POST /api/IngestDocument — Response 202

```
{
  "instanceId": "abc123def456ghi789",
  "statusQueryUri": "https://srbappprodocai.azurewebsites.net/runtime/webhooks/durabletask/instances/abc123def456ghi789?code=<system-key>",
  "correlationId": "a1b2c3d4-0000-0000-0000-000000000000"
}
```

3.12.3 GET statusQueryUri — Running

```

{
  "name": "DocumentProcessOrchestrator",
  "instanceId": "abc123def456ghi789",
  "runtimeStatus": "Running",
  "customStatus": {
    "version": "1.0",
    "estado": "Running",
    "actividadActual": "Extraer",
    "actividadesTotales": 12,
    "actividadesCompletadas": ["Normalizar", "VerificarDuplicado", "SubirBlob", "Clasificar", "ResolverTipologia"],
    "duracionTotalMs": 4200,
    "actividades": [
      { "nombre": "Normalizar", "estado": "Completed", "duracionMs": 120, "fallbackActivado": false },
      { "nombre": "VerificarDuplicado", "estado": "Completed", "duracionMs": 85, "fallbackActivado": false },
      { "nombre": "SubirBlob", "estado": "Completed", "duracionMs": 340, "fallbackActivado": false },
      { "nombre": "Clasificar", "estado": "Completed", "duracionMs": 2800, "fallbackActivado": true, "fallbackRazon": "Confianza
DI 0.45 < umbral 0.85" },
      { "nombre": "ResolverTipologia", "estado": "Completed", "duracionMs": 15, "fallbackActivado": false },
      { "nombre": "Extraer", "estado": "Running", "duracionMs": 0, "fallbackActivado": false }
    ]
  },
  "createdTime": "2026-03-27T10:00:00Z",
  "lastUpdatedTime": "2026-03-27T10:00:04Z"
}

```

3.12.4 GET statusQueryUri — Completed (Exito)


```

{
  "runtimeStatus": "Completed",
  "output": {
    "identificacion": {
      "documento": "nota_simple_finca_12345.pdf",
      "guid": "f47ac10b-58cc-4372-a567-0e02b2c3d479",
      "tipologia": "nota.simple.1_4",
      "tipologiaFamilia": "nota-simple",
      "tipologiaVersion": "1.4",
      "fechaProceso": "2026-03-27T10:00:12Z",
      "paginas": 5
    },
    "integridad": {
      "crc32": "a1b2c3d4",
      "sha256": "e3b0c44298fc1c149afb4c8996fb92427ae41e4649b934ca495991b7852b855",
      "md5": "d41d8cd98f00b204e9800998ecf8427e",
      "rutaBlobStorage": "documents/nota_simple_finca_12345.pdf",
      "gestorDocumental": "GDC-OBJ-12345",
      "idActivo": "ACT-2026-00456",
      "idActivoEntrada": "ACT-2026-00123",
      "idActivoCambiado": true
    },
    "datosExtraidos": {
      "FincaRegistral": "12345",
      "IDUFIR_CRU": "28077000012345",
      "Direccion": "Calle Mayor 1, 28001 Madrid",
      "ReferenciaCatastral": "9872023VH5797S0001WX",
      "FechaDocumento": "15/01/2026",
      "Titulares": [
        {
          "Nombre": "GARCIA LOPEZ, MARIA",
          "NIF": "12345678Z",
          "Participacion": "100%",
          "TipoDominio": "Plena"
        }
      ],
      "Cargas": [
        {
          "Tipo": "Hipoteca",
          "Acreedor": "BANCO EJEMPLO SA",
          "Importe": 150000.00
        }
      ]
    },
    "detalleEjecucion": {
      "runTipologia": "nota.simple.1_4",
      "clasificacion": {
        "modelo": "srbdiprodocai-classifier-v1",
        "confianza": 0.92,
        "confianzaDI": 0.45,
        "confianzaGPT": 0.92,
        "proveedorClasif": "GPT4oMini",
        "fallbackLLM": true,
        "fallbackRazon": "Confianza DI 0.45 < umbral 0.85",
        "tipologiaDetectada": "nota-simple"
      },
      "extraccion": {
        "modelo": "nota-simple-cu-v1",
        "confianzaExtraccion": 0.91,
        "proveedorExtrac": "AzureContentUnderstanding",
        "modelKeyEfectivo": "nota.simple.1_4.azure-cu.sweden",
        "endpointEfectivo": "https://upe48-mm2avmdm-swedencentral.services.ai.azure.com/",
        "processingLocationEfectiva": "swedencentral",
        "layoutEnabled": false,
        "fallbackUsado": false,
        "confianzaPorCampo": {
          "FincaRegistral": 0.98,
          "IDUFIR_CRU": 0.95,
          "Direccion": 0.87,

```

```

    "ReferenciaCatastral": 0.91,
    "FechaDocumento": 0.93
  },
  "camposConDuda": [],
  "tiemposMs": {
    "prepare": 45,
    "limiterWaitMs": 120,
    "analysis": 3200,
    "parse": 18,
    "attempts": 1
  }
},
"postproceso": {
  "normalizaciones": ["FechaDocumento normalizada a dd/MM/yyyy"],
  "validaciones": ["FincaRegistral: OK", "IDUFIR_CRU: OK", "NIF_Titular: OK"],
  "inconsistencias": [],
  "confianzaValidacion": 1.0
},
"integracion": {
  "tipologia": "nota.simple.1_4",
  "estado": "OK",
  "mensaje": "Integracion completada",
  "plugins": [
    {
      "pluginKey": "refCatExcel",
      "priority": 1,
      "success": true,
      "mensaje": "IdActivo resuelto",
      "statusCode": 200,
      "durationMs": 450,
      "datosEnriquecidos": { "idActivo": "ACT-2026-00456" }
    }
  ],
  "datosFinales": {
    "FincaRegistral": "12345",
    "idActivo": "ACT-2026-00456"
  },
  "idActivoEntrada": "ACT-2026-00123",
  "idActivoResuelto": "ACT-2026-00456",
  "idActivoCambiado": true
},
"assetResolver": {
  "ejecutado": true,
  "exitoso": true,
  "activosEncontrados": 1,
  "criteriosUsados": {
    "idufir": "28077000012345",
    "referenciaCatastral": "9872023VH5797S0001WX"
  }
},
"activos": [
  {
    "idActivo": "ACT-2026-00456",
    "fchCierre": "2026-01-31T00:00:00Z",
    "camposSolicitados": {
      "ID_ACTIVO_SAREB": "ACT-2026-00456",
      "FCH_CIERRE": "2026-01-31T00:00:00Z",
      "ID_IDUFIR": "28077000012345",
      "ID_REF_CATAST": "9872023VH5797S0001WX"
    }
  }
],
"camposConError": [],
"mensaje": "1 activo(s) encontrado(s).",
"duracionMs": 180,
"error": null
},
"gdc": {
  "exitoso": true,
  "objectId": "GDC-OBJ-12345",
  "mensaje": "Documento creado en GDC",

```

```

    "intentos": 1,
    "duracionMs": 1200,
    "errorDetalle": "",
    "yaExistia": false
  },
  "seguimiento": {
    "version": "1.0",
    "estado": "Completed",
    "actividadActual": "",
    "actividadesTotales": 12,
    "actividadesCompletadas": [
      "Normalizar", "VerificarDuplicado", "SubirBlob",
      "Clasificar", "ResolverTipologia", "Extraer",
      "Validar", "ObtenerActivo", "Integrar", "SubirGDC", "Persistir"
    ],
    "duracionTotalMs": 8500,
    "actividades": [
      { "nombre": "Normalizar", "estado": "Completed", "duracionMs": 120, "fallbackActivado": false },
      { "nombre": "Clasificar", "estado": "Completed", "duracionMs": 2800, "fallbackActivado": true, "fallbackRazon":
"Confianza DI 0.45 < umbral 0.85" },
      { "nombre": "Extraer", "estado": "Completed", "duracionMs": 3200, "fallbackActivado": false },
      { "nombre": "Validar", "estado": "Completed", "duracionMs": 45, "fallbackActivado": false },
      { "nombre": "ObtenerActivo", "estado": "Completed", "duracionMs": 180, "fallbackActivado": false },
      { "nombre": "Integrar", "estado": "Completed", "duracionMs": 450, "fallbackActivado": false },
      { "nombre": "SubirGDC", "estado": "Completed", "duracionMs": 1200, "fallbackActivado": false },
      { "nombre": "Persistir", "estado": "Completed", "duracionMs": 85, "fallbackActivado": false }
    ]
  },
  "prompt": null
},
"resultado": {
  "estado": "OK",
  "mensajeError": null,
  "confianzaGlobal": 0.91,
  "estadoCalidad": "OK",
  "confianzaClasificacion": 0.92,
  "confianzaExtraccion": 0.91,
  "confianzaValidacion": 1.0,
  "reutilizadaPorDuplicado": false,
  "mensajeReutilizacion": null
}
}
}

```

3.12.5 Management Endpoints

Metodo	Endpoint	Descripcion	Auth
GET	/api/tipologias	Tipologias publicadas (identificador , nombre , extraction)	Anonymous
GET	/management/tipologias	Todas las tipologias	Function
POST	/management/tipologias	Crear tipologia	Function
PUT	/management/tipologias/{id}	Actualizar tipologia	Function
POST	/management/tipologias/{id}/publicar	Publicar	Function
POST	/management/tipologias/{id}/retirar	Retirar	Function
POST	/management/tipologias/{id}/draft	Volver a Draft	Function
GET	/management/modelos/{tipo}	Listar modelos (Clasificacion/Extraccion/Prompt)	Function
POST	/management/modelos	Crear modelo	Function
PUT	/management/modelos/{id}	Actualizar modelo	Function
DELETE	/management/modelos/{id}	Eliminar modelo	Function
GET	/management/plugins-tipologias/{codigo}	Config plugins de tipologia	Function
PUT	/management/plugins-tipologias/{codigo}	Actualizar config plugins	Function
POST	/management/plugins-tipologias/{codigo}/publicar	Publicar config plugins	Function
POST	/management/plugins-tipologias/{codigo}/retirar	Retirar config plugins	Function

3.13 Referencias

Documento	Contenido
01_ARQUITECTURA_SISTEMA.md	Arquitectura, ADRs, patrones
CONTRATO_API_HTTP.md	Contrato API detallado (original)
CONFIANZA_AGREGADA.md	Logica de confianza
TIPOLOGIAS_REFERENCIA.md	Catalogo de tipologias