

Confianza Agregada — Análisis Técnico y Funcional

1. Propósito

El sistema asigna una **puntuación de confianza numérica (0–1)** a cada ejecución de procesamiento documental, descompuesta en tres etapas del pipeline: clasificación, extracción y validación. A partir de esas tres puntuaciones se calcula una **confianza global** y un **estado de calidad** ("OK", "REVISION", "ERROR") que permiten a los consumidores tomar decisiones automatizadas o de revisión humana sin necesidad de inspeccionar el detalle interno.

2. Visión funcional

2.1 ¿Qué mide cada etapa?

Etapas	Pregunta que responde	Fuente
Clasificación	¿Con qué certeza se ha identificado el tipo de documento?	Confianza nativa del modelo (DI o GPT self-report)
Extracción	¿Con qué completitud y fiabilidad se han obtenido los datos?	Ratio de campos cubiertos + confianza de campo (CU) o confianza self-report (GPT)
Validación	¿Cuántas reglas de negocio se han superado?	1 – errores / reglas_requeridas

2.2 Confianza global

La confianza global es el **mínimo de las tres etapas**. Un solo eslabón débil lastra el resultado completo, forzando revisión humana si alguna etapa falla.

ConfianzaGlobal = MIN(ConfianzaClasificacion, ConfianzaExtraccion, ConfianzaValidacion)

Si la tipología tiene extracción deshabilitada (`extraction.enabled = false`), la confianza de extracción se omite del cálculo.


2.3 Estado de calidad

Estado	Condición	Interpretación
OK	<code>ConfianzaGlobal ≥ 0.85</code>	Procesamiento automático sin revisión
REVISION	<code>0.70 ≤ ConfianzaGlobal < 0.85</code>	Requiere revisión humana
ERROR	<code>ConfianzaGlobal < 0.70</code>	Alta probabilidad de dato incorrecto o fallido

Los umbrales son configurables por tipología (ver §5). Los defaults `0.85` y `0.70` representan los criterios consensuados para el MVP.

`EstadoCalidad` es un campo **independiente** de `Estado`. `Estado` refleja el resultado del proceso (OK, VALIDACION_CON_ERRORES, ERROR, DUPLICADO...). `EstadoCalidad` refleja la fiabilidad de los datos obtenidos.

3. Pipeline y proveedores



4. Cálculo detallado por etapa

4.1 Clasificación — `ConfidenceCalculator.ClasifFinal`

```

si fallbackUsado:
    confianza = CLAMP(ConfianzaGPT ?? ConfianzaDI ?? 0.5, 0, 1)
si no:
    confianza = CLAMP(ConfianzaDI ?? 0.0, 0, 1)
  
```

- **Azure Document Intelligence** devuelve `documents[0].confidence` directamente.
- **GPT 4o-mini** devuelve un campo `"confianza"` en el JSON de respuesta (0–1). Si no lo incluye, se usa `0.5` como fallback neutro.
- `ConfigurableClasificarDataProvider` propaga `ConfianzaDI` al resultado GPT cuando éste toma el control (para trazabilidad: se sabe la confianza que provocó el fallback).

4.2 Extracción CU — `ConfidenceCalculator.ExtracCU`

Fórmula (3 componentes ponderados):

```

ConfianzaExtrac =
  w_campos    × AvgConf
+ w_req      × RatioRequeridos
+ w_warnings × (1 - RatioWarnings)
  
```

Variable	Descripción	Valor default del peso
AvgConf	Promedio de <code>fields[*].confidence</code> del response CU. Si CU no devuelve confianzas, se usa <code>camposPresentes / camposTotales</code>	<code>w_campos = 0.5</code>
RatioRequeridos	<code>camposRequeridosPresentes / camposRequeridos</code>	<code>w_requeridos = 0.3</code>
1 - RatioWarnings	Penalización por warnings. <code>RatioWarnings = min(1, warnings / camposTotales)</code>	<code>w_warnings = 0.2</code>

Métricas de debug disponibles en `DetalleEjecucion.Extraccion.MetricasDebug` (no persistidas en BBDD):

- `PromedioConfianza` — componente `avgConf` calculado
- `RatioRequeridos` — componente `ratioReq`
- `CamposConConfianza` — número de campos con confianza individual de CU
- `CamposTotales` — total de campos de la tipología

4.3 Extracción GPT — `confianza_extraccion` auto-reportada

El modelo GPT incluye en su respuesta JSON el campo `confianza_extraccion` (0.0–1.0), siguiendo el mismo patrón que clasificación usa con `confianza`. El system prompt solicita explícitamente ese campo:

```
'confianza_extraccion' (número entre 0.0 y 1.0 que refleja tu confianza global en la extracción)
```

La asignación final sigue la regla:

```
ConfianzaExtrac = CLAMP(confianzaExtraccionGpt ?? confianzaCalculada, 0, 1)
```

- `confianzaExtraccionGpt` : valor `confianza_extraccion` del JSON de respuesta. Si el modelo lo devuelve, se usa directamente.
- `confianzaCalculada` : resultado de `ExtracCU(fieldConfs, campos, requeridos, warnings, cfg)`, idéntico al cálculo de CU. Se usa como fallback si el modelo no incluye el campo o la respuesta está mal formada.

Cuando el modelo GPT reporta `confianza_extraccion`, se usa ese valor; en su ausencia se aplica como fallback el valor calculado al estilo CU (`confianzaCalculada`). El helper `ConfidenceCalculator.ExtracGPT` conserva un valor por defecto de `0.6` para los casos en que se invoca sin confianza self-report (ver tabla de la sección 8). GPT no devuelve confianzas por campo individuales; éstas siguen siendo solicitadas en `confianza_por_campo` y se propagan a `CamposBajaConfianza`.

4.4 Validación — `ValidarActivity`

```
si no hay errores:    ConfianzaValid = 1.0
si hay errores:      ConfianzaValid = CLAMP(1 - ErrorCount / max(1, TotalChecked), 0, 1)
```

Donde:

- `ErrorCount` = número de resultados con severidad `Error`
- `TotalChecked` = **total de reglas evaluadas** (las que pasaron + las que fallaron), contado en `ValidationEngine`

Los `Warning` **no** penalizan el numerador (`ErrorCount`). Aparecen en `Validaciones` del output pero no reducen la confianza. La confianza es proporcional al ratio de errores sobre el total de reglas configuradas para esa tipología.

Ejemplo: 20 reglas, 1 falla con Error:

```
ConfianzaValid = 1 - 1/20 = 0.95 → EstadoCalidad = "OK"
```

Ejemplo real (NS 2691): 28 reglas evaluadas, 2 errores de campo:

```
ConfianzaValid = 1 - 2/28 ≈ 0.93
```

Nota sobre ConfidenceCalculator.Validacion : existe como método auxiliar con la misma fórmula ($1 - \text{errores}/\text{totalReglas}$), pero la fuente de verdad en producción es `ValidarActivity` , que calcula directamente sobre el `ValidationReport` .

5. Configuración por tipología

5.1 Jerarquía de umbrales de fallback

Los umbrales que determinan cuándo se activa el fallback GPT siguen una cadena de prioridad. En clasificación hay un único umbral. En extracción hay **dos criterios independientes**:

- **Compleitud**: ratio de campos esperados (según la tipología) presentes en `DatosExtraidos` .
- **Confianza**: valor de `ConfianzaExtraccion` devuelto por CU.

Si **cualquiera** de los dos criterios no supera su umbral, se activa el fallback GPT.

La cadena de resolución para **cada criterio de extracción** (de mayor a menor prioridad) es:

petición HTTP (específico/legado) → tipología (específico/legado) → modelo/servidor

Nivel	Campo clasificación	Campo extracción (compleitud)	Campo extracción (confianza)
1 — Petición	<code>instrucciones.classification.umbra</code>	<code>instrucciones.extraction.umbraCompleitud ?? instrucciones.extraction.umbra</code>	<code>instrucciones.extraction.umbraConfianza ?? instrucciones.extraction.umbra</code>
2 — Tipología	<code>confidenceConfig.classifUmbraFallback</code>	<code>confidenceConfig.extracUmbraFallbackCompleitud ?? confidenceConfig.extracUmbraFallback</code>	<code>confidenceConfig.extracUmbraFallbackConfianza ?? confidenceConfig.extracUmbraFallback</code>
3 — Modelo/Se rvidor	<code>Classification:GptFallback:FallbackThreshold</code>	<code>Extraction:GptFallback:MinFieldsRatio</code>	<code>Extraction:GptFallback:MinFieldsRatio</code>

Regla de compatibilidad: en cada capa, el umbral legado (`umbra / extracUmbraFallback`) solo se usa cuando el específico del criterio está en `null` .

El orquestador resuelve el umbral efectivo antes de invocar cada actividad:

```
// Clasificación (tipología no conocida todavía – solo niveles 1 y 4)
var umbralClasifFallback = entrada.Instrucciones.Classification.Umbra
?? _gptClasifSettings.FallbackThreshold;

// Clasificación – check BAJA_CONFIANZA (tipología ya resuelta – cadena completa)
var umbralBajaConfianza = entrada.Instrucciones.Classification.Umbra
?? tipologiaResuelta.ConfidenceConfig?.ClasifUmbraFallback
?? _gptClasifSettings.FallbackThreshold;

// Extracción – umbral legado (se pasa como UmbraFallbackEfectivo, nivel 3)
var umbralExtracFallback = entrada.Instrucciones.Extraction.Umbra
?? tipologiaResuelta.ConfidenceConfig?.ExtracUmbraFallback
?? _gptExtracSettings.MinFieldsRatio;

// Extracción – capa petición (específico si existe; si no, legado de la misma capa)
var umbralExtracCompleitudRequest = entrada.Instrucciones.Extraction.UmbraCompleitud
?? entrada.Instrucciones.Extraction.Umbra;
var umbralExtracConfianzaRequest = entrada.Instrucciones.Extraction.UmbraConfianza
?? entrada.Instrucciones.Extraction.Umbra;
```

Dentro de `ConfigurableExtraerDataProvider.EsResultadoCuSuficiente` , la resolución final de cada criterio es:

```
// Prioridad por capas: petición > tipología > modelo/servidor
umbralCompleitud = umbralFallbackCompleitudRequest // nivel 1
?? confidenceConfig?.ExtracUmbralFallbackCompleitud // nivel 2
?? umbralLegado // legado tipología o modelo
?? _fallbackSettings.MinFieldsRatio; // último recurso

umbralConfianza = umbralFallbackConfianzaRequest // nivel 1
?? confidenceConfig?.ExtracUmbralFallbackConfianza // nivel 2
?? umbralLegado // legado tipología o modelo
?? _fallbackSettings.MinFieldsRatio; // último recurso

return ratioCompleitud >= umbralCompleitud && confianzaCu >= umbralConfianza;
```

El nivel de tipología para clasificación se usa en el check `BAJA_CONFIANZA_CLASIFICACION` pero no en el umbral de DI→GPT previo a la resolución de tipología, donde solo se usan los niveles 1 y 4.

5.2 Bloque `confidenceConfig`

Cada fichero `*.validation.json` puede incluir un bloque `confidenceConfig` opcional. Si no está, se usan los defaults:

```
"confidenceConfig": {
  "clasifUmbralFallback": 0.85,
  "extracUmbralFallback": 0.9,
  "extracUmbralFallbackCompleitud": 0.9,
  "extracUmbralFallbackConfianza": 0.9,
  "extracWeightCampos": 0.5,
  "extracWeightRequeridos": 0.3,
  "extracWeightWarnings": 0.2,
  "umbralOK": 0.85,
  "umbralRevision": 0.70
}
```

Parámetro	Descripción	Default
<code>clasifUmbralFallback</code>	Umbral de confianza DI para activar fallback GPT en clasificación, y también para el check <code>BAJA_CONFIANZA_CLASIFICACION</code> (cuando la petición no especifica umbral).	0.85
<code>extracUmbralFallback</code>	Umbral legado : aplica a completitud y confianza si los campos específicos no están informados en la tipología ni en la petición. Mantiene retrocompatibilidad.	null
<code>extracUmbralFallbackCompleitud</code>	Ratio mín. de campos esperados presentes (nivel tipología). Nivel 2 en la jerarquía de completitud. <code>null</code> = usar legado o global.	null
<code>extracUmbralFallbackConfianza</code>	Confianza CU mínima para no activar fallback (nivel tipología). Nivel 2 en la jerarquía de confianza. <code>null</code> = usar legado o global.	null
<code>extracWeightCampos</code>	Peso del promedio de confianzas de campo CU	0.5
<code>extracWeightRequeridos</code>	Peso del ratio de campos requeridos presentes	0.3
<code>extracWeightWarnings</code>	Peso de la penalización por warnings	0.2
<code>umbralOK</code>	$\text{ConfianzaGlobal} \geq \text{umbral} \rightarrow \text{EstadoCalidad} = \text{"OK"}$	0.85
<code>umbralRevision</code>	$\text{ConfianzaGlobal} \geq \text{umbral} \rightarrow \text{EstadoCalidad} = \text{"REVISION"}$	0.70

La suma `extracWeightCampos + extracWeightRequeridos + extracWeightWarnings` debe ser 1.0. Si no, el resultado queda fuera del rango esperado (aunque se aplica `CLAMP` final).

6. Contrato de salida — campos expuestos

6.1 Resultado principal (Resultado)

```
{
  "Estado": "VALIDACION_CON_ERRORES",
  "ConfianzaGlobal": 0.333,
  "EstadoCalidad": "ERROR",
  "ConfianzaClasificacion": 0.874,
  "ConfianzaExtraccion": 0.889,
  "ConfianzaValidacion": 0.333
}
```

6.2 Detalle de clasificación (DetalleEjecucion.Clasificacion)

```
{
  "Modelo": "DocumentAICC_v0",
  "Confianza": 0.874,
  "ConfianzaDI": 0.874,
  "ConfianzaGPT": 0,
  "ProveedorClasif": "DocumentIntelligence",
  "FallbackLLM": false
}
```

6.3 Detalle de extracción (DetalleEjecucion.Extraccion)

```
{
  "Modelo": "CU_NS_1.4_2",
  "ConfianzaExtraccion": 0.889,
  "ProveedorExtrac": "AzureContentUnderstanding",
  "FallbackUsado": false
}
```

6.4 Postproceso (DetalleEjecucion.Postproceso)

```
{
  "Normalizaciones": ["Aplicadas 3 reglas de validacion", "Confianza de validacion: 33 %"],
  "Validaciones": ["[Warning] CuotaParticipacion: ..."],
  "Inconsistencias": ["[ERROR] Anejos: ...", "Total de errores: 2"],
  "ConfianzaValidacion": 0.333
}
```

7. Arquitectura del código

7.1 Ficheros involucrados

Fichero	Capa	Rol
DocumentIA.Core/Services/ConfidenceCalculator.cs	Core	Cálculos puros, sin DI. Único punto de verdad matemático
DocumentIA.Core/Models/ContratoSalida.cs	Core	Campos nuevos en ResultadoFinal, ResultadoClasificacion, ResultadoExtraccion, InformacionPostproceso
DocumentIA.Core/Models/ExtraccionModels.cs	Core	ConfianzaExtraccion, ProveedorExtrac, MetricasDebug en ExtraccionResultado
DocumentIA.Core/Models/ContratoEntrada.cs	Core	ConfiguracionIA.Umbral, UmbralCompleitud, UmbralConfianza → double? (null = no especificado, usar jerarquía)
DocumentIA.Core/Models/ClasificacionModels.cs	Core	UmbralFallbackEfectivo double? en ClasificacionInput
DocumentIA.Core/Models/ExtraccionModels.cs	Core	UmbralFallbackEfectivo, UmbralFallbackEfectivoCompleitud, UmbralFallbackEfectivoConfianza double? en ExtraccionInput
DocumentIA.Core/Configuracion/TipologiaValidationConfig.cs	Core	Clase ConfidenceConfig + propiedad en TipologiaValidationConfig + ExtracUmbralFallback, ExtracUmbralFallbackCompleitud, ExtracUmbralFallbackConfianza double?
DocumentIA.Core/Configuracion/ITipologiaVersionResolver.cs	Core	ConfidenceConfig en ResolvedTipologia record
DocumentIA.Core/Configuracion/TipologiaVersionResolver.cs	Core	Propagación de ConfidenceConfig al resolver
DocumentIA.Functions/Services/AzureDocumentIntelligenceClasificarProvider.cs	Funciones	Extrae y asigna ConfianzaDI, ProveedorClasif
DocumentIA.Functions/Services/GptClasificarDataProvider.cs	Funciones	Extrae confianza del JSON GPT, asigna ConfianzaGPT, ProveedorClasif
DocumentIA.Functions/Services/ConfigurableClasificarDataProvider.cs	Funciones	Propaga ConfianzaDI cuando ejecuta fallback GPT
DocumentIA.Functions/Services/AzureContentUnderstandingProvider.cs	Funciones	TryExtractFieldConfidences() + cálculo ExtracCU() + MetricasDebug
DocumentIA.Functions/Services/GptFallbackExtraerDataProvider.cs	Funciones	Pide confianza_extraccion al modelo en el prompt; BuildFallbackMetricas devuelve (double, ConfidenceMetricasExtraccion); ConfianzaExtraccion = confianzaExtraccionGpt ?? confianzaCalculada; BuildFieldList incluye hints de validación por campo (enum, regex, fecha, rango, dirección)
DocumentIA.Functions/Orchestrators/DocumentProcessOrchestrator.cs	Funciones	Resuelve jerarquía de umbrales (petición→tipología→config) en 3 puntos; agrega Global(), asigna EstadoCalidad, descompone campos en contrato
DocumentIA.Functions/config/tipologias/*.validation.json	Config	Bloque confidenceConfig con defaults explícitos
DocumentIA.Tests.Unit/Services/ConfidenceCalculatorTests.cs	Tests	24 tests unitarios cubriendo todos los métodos y casos límite

7.2 Principios de diseño

- **ConfidenceCalculator** es **estático y puro**: sin dependencias de DI, testeable de forma directa, sin efectos laterales.
- **Datos de confianza fluyen de actividad a orquestador**: cada provider rellena sus campos propios; el orquestador agrega al final, evitando acoplamiento entre actividades.
- **EstadoCalidad** $\neq$ **Estado**: **Estado** es el resultado del proceso (pudo completarse o no). **EstadoCalidad** es la fiabilidad de los datos, independiente del éxito del proceso.
- **Sin migración de BBDD**: **ConfianzaGlobal** ya estaba en la entidad. Los campos de descomposición se exponen solo en el JSON de salida.

8. Tests unitarios

Localización: `src/backend/DocumentIA.Tests.Unit/Services/ConfidenceCalculatorTests.cs`

Grupo	Tests
ClasifFinal	Sin fallback usa DI; con fallback usa GPT; ambos null devuelve 0.5; fallback con null GPT usa DI
ExtracCU	Confianzas perfectas $\rightarrow$ 1.0; sin fieldConfs usa ratio campos; muchos warnings bajan score; campos requeridos ausentes bajan score; pesos custom aplicados
ExtracGPT	Null $\rightarrow$ 0.6; valor dado $\rightarrow$ ese valor; valor $> 1 \rightarrow$ clamped a 1
Validacion	0 errores $\rightarrow$ 1.0; todos errores $\rightarrow$ 0.0; 0 reglas $\rightarrow$ 1.0
Global	Todos altos $\rightarrow$ mínimo; validación es cuello de botella; extracción null se omite
EstadoCalidad	$\geq 0.85 \rightarrow$ OK; $[0.70, 0.85) \rightarrow$ REVISION; $< 0.70 \rightarrow$ ERROR; null config usa defaults

Ejecutar:

```
dotnet test --filter "FullyQualifiedName~ConfidenceCalculator" \
  src/backend/DocumentIA.Tests.Unit/DocumentIA.Tests.Unit.csproj
```

9. Ejemplo real de ejecución (NS 1.4)

Documento: `2691_NS_2691.pdf` (Nota Simple)

Etap	Proveedor	Confianza
Clasificación	DocumentIntelligence	0.874
Extracción	AzureContentUnderstanding	0.889
Validación	Motor de reglas (2 errores de 3)	0.333
Global	MIN(0.874, 0.889, 0.333)	0.333
EstadoCalidad	$0.333 < 0.70$	ERROR

Interpretación: la clasificación y extracción son buenas, pero 2 campos requeridos fallan validación. El documento necesita revisión manual antes de integrarse.