

Monitoreo y Alertas — Configuración REAL

Estado: Verificado en código (2026-06-10)
Fuente: `src/backend/DocumentIA.Functions/` + `azure-pipelines*.yaml`
Producción: SRBRGDOCSAIPROD

Resumen Ejecutivo

Application Insights

- Component:** `srbappiprodocai`
- Connection String (Variable):** `InstrumentationKey=<INSTRUMENTATION_KEY>;IngestionEndpoint=https://westeurope-5.in.applicationinsights.azure.com/;LiveEndpoint=https://westeurope.livediagnostics.monitor.azure.com/;ApplicationId=<APPLICATION_ID>`
- Estado:** Habilitado en producción
- Sampling:** Habilitado (20 events/sec, excludes "Request" type)
- Live Metrics:** Habilitado

Eventos Telemetría Registrados

Evento	Propiedad Clave	Métrica	Origen
<code>DocumentProcessed</code>	Tipologia, EstadoFinal, UseFallbackLLM, NombreDocumento	DuracionTotalMs, DuracionExtraccionMs, DuracionClasificacionMs	<code>PersistirActivity.cs</code>
<code>CU.CircuitOpen</code>	tipologia, modelKey, reason, failureThreshold	openUntilUtc	<code>AzureContentUnderstandingProvider.cs</code>
<code>CU.CircuitClosed</code>	tipologia, modelKey, reason	-	<code>AzureContentUnderstandingProvider.cs</code>
<code>CU.CircuitFailover</code>	tipologia, primaryModelKey, fallbackModelKey	-	<code>AzureContentUnderstandingProvider.cs</code>
<code>CU.CircuitRejected</code>	tipologia, modelKey	-	<code>AzureContentUnderstandingProvider.cs</code>
<code>CU.TransientError</code>	attempt, statusCode, tipologia	-	<code>AzureContentUnderstandingProvider.cs</code>
<code>CU.HardTimeout</code>	tipologia, modelKey, attempt, hardTimeoutSeconds	-	<code>AzureContentUnderstandingProvider.cs</code>
<code>Prompt.Trace</code>	provider, operation, tipologia, modelKey, deployment, systemPromptSha256, userPromptSha256	systemPromptLength, userPromptLength	<code>PromptTraceTelemetryService.cs</code>
<code>BlobCleanupCycle</code>	source	blobs_procesados, blobs_eliminados, blobs_error, bytes_liberados	<code>BlobCleanupTimerTrigger.cs</code>

Métricas Reales Registradas

1. CU (Content Understanding) — Subfases

CU.PrepareMs	→ tiempo preparación request (ms)
CU.LimiterWaitMs	→ tiempo espera en queue local (ms)
CU.AnalysisMs	→ tiempo análisis en Azure CU (ms)
CU.ParseMs	→ tiempo parsing resultado (ms)
CU.Attempts	→ número intentos (con retries)

Propiedades asociadas: Tipologia , ModelKey

Umbral interpretados del código:

- Si CU.LimiterWaitMs > 10 segundos → backpressure local (cola saturada)
- Si CU.AnalysisMs > 60 segundos → Azure CU lento o saturado
- Si CU.Attempts ≥ 4 → múltiples retries (revisar timeout o disponibilidad CU)

2. Duraciones por Actividad de Orquestación

DocumentIA.Duracion.Total	→ ms totales documento
DocumentIA.Duracion.Clasificacion	→ ms clasificación
DocumentIA.Duracion.Extraccion	→ ms extracción
DocumentIA.Duracion.Validacion	→ ms validación
DocumentIA.Duracion.GDC	→ ms integración GDC
DocumentIA.Duracion.Integracion	→ ms post-procesamiento
DocumentIA.Duracion.Persistencia	→ ms guardado BD

Propiedades asociadas: Tipologia

Contexto: Registradas al finalizar cada documento en PersistirActivity.cs

3. Limpieza de Blobs

```

BlobCleanupCycle (evento)
├ blobs_procesados → cantidad revisadas
├ blobs_eliminados → cantidad eliminadas
├ blobs_no_encontrados → fallos de acceso
├ blobs_error → excepciones durante eliminación
└ bytes_liberados → espacio liberado

```

Programación: Timer trigger CRON = "0 0 3 * * *" (3 AM UTC diario)

4. Prompts (Tracing Opcional)

```

Prompt.Trace (evento)
├ provider → "gpt" | "di" | ...
├ operation → "extraction" | "classification" | ...
├ tipologia → tipología documento
├ modelKey → modelo específico
├ deployment → deployment OpenAI (ej: "gpt-4o-mini")
├ systemPromptSha256 → hash sistema (privacidad)
├ userPromptSha256 → hash usuario (privacidad)
├ systemPromptSnippet → (si IncludePromptText=true) primeros 20KB
└ userPromptSnippet → (si IncludePromptText=true) primeros 20KB

```

Status en producción:

- PromptTracing_Enabled = true
- PromptTracing_IncludePromptText = true (no privacidad restringida)
- PromptTracing_MaxPromptTextChars = 20000 caracteres

Configuración de Logging

host.json (Durable Functions)

```
{
  "logging": {
    "applicationInsights": {
      "samplingSettings": {
        "isEnabled": true,
        "maxTelemetryItemsPerSecond": 20,
        "excludedTypes": "Request"
      },
      "enableLiveMetricsFilters": true
    },
    "logLevel": {
      "default": "Warning",
      "Host.Results": "Information",
      "Function": "Information",
      "Host.Aggregator": "Warning",
      "Microsoft.Azure.Functions.Worker": "Warning",
      "Microsoft.DurableTask": "Warning"
    }
  }
}
```

Efectos:

- Logging de resultados = `Information` (errores + completados)
- Logging de función = `Information` (todo)
- Microsoft logs = `Warning` (solo errores serios)
- Durable Tasks = `Warning` (no verbose)
- Sampling = 20 events/sec (algunos eventos pueden omitirse en picos)

Alertas Implementadas EN CÓDIGO

Circuit Breaker — Azure Content Understanding

```
// Configuración en producción (pipeline):
Extraction__AzureContentUnderstanding__EnableCircuitBreaker = true
Extraction__AzureContentUnderstanding__CircuitBreakerFailureThreshold = 5
Extraction__AzureContentUnderstanding__CircuitBreakerOpenSeconds = 45
```

Comportamiento:

1. Si 5 requests consecutivos a CU fallan → circuit abierto
2. Durante 45 segundos, rechaza nuevos requests (rápida respuesta sin timeout)
3. Emite evento `CU.CircuitOpen` con razón y timestamp apertura
4. Al timeout expirar, reintenta automáticamente (evento `CU.CircuitClosed`)

Causa raíz posible:

- Azure CU endpoint down o rate-limited
- Network connectivity issues
- Timeout de 90 segundos excedido

Retry Policy — Azure Content Understanding

```
// Configuración en producción:
Extraction__AzureContentUnderstanding__MaxRetries = 3
Extraction__AzureContentUnderstanding__InitialRetryDelayMs = 500
```

Patrón: Exponential backoff (500ms → 1000ms → 2000ms)

Evento registrado: `CU.TransientError` con:

- `attempt` = número de intento (1, 2, 3)
- `statusCode` = HTTP status si aplica
- `tipologia` = tipo documento

Hard Timeout — Azure Content Understanding

```
// Configuración en producción:
Extraction__AzureContentUnderstanding__HardTimeoutSeconds = 90
```

Comportamiento:

- Si CU tarda > 90 segundos → cancela request y falla actividad
- Emite evento `CU.HardTimeout` con:
 - `tipologia`, `modelKey`, `attempt`, `hardTimeoutSeconds`

Típicamente causa: CU saturado, API lento o red inestable

Circuit Breaker — GDC (Document Management System)

```
// Configuración en código (GdcSettings.cs):
CircuitBreakerFailures = 5
CircuitBreakerDurationMs = 30000 (30 seg)
ExponentialBackoff = true
```

Evento: Implícito en `ResilientPlugin.cs` (sin `TrackEvent` explícito, solo logs)

Razón: GDC es legacy SOAP sobre HTTP Basic Auth + SSL bypass — muy propenso a fallos

Workbooks y Consultas KQL Validadas

Workbook Existente

Ruta: `docs/observabilidad/workbooks/documentia-cu-performance.workbook.json`

Dashboards implementados:

1. **Resumen CU (últimas 24h)** → eventos, promedio, P95, máximo por métrica
2. **P95 por subfase** → timechart de preparación, espera, análisis, parse
3. **Diagnóstico rápido** → compara espera vs análisis para identificar cuello de botella
4. **Top operaciones esperando** → lista docID con mayor `LimiterWaitMs`

Estado: Queries validadas, schema comprobado

Script de Exportación

Ruta: `scripts/reports/export-cu-performance-insights.ps1`

Uso:

```
# Exporta reportes de CU últimas 24h
.\export-cu-performance-insights.ps1 `
  -SubscriptionId "... " `
  -ResourceGroup "SRBRGDOCSAIPROD" `
  -AppInsightsName "srbappiprodocai" `
  -OutputDir ".\artifacts\reports\cu-performance"

# Rango específico
.\export-cu-performance-insights.ps1 `
  -SubscriptionId "... " `
  -ResourceGroup "SRBRGDOCSAIPROD" `
  -StartTime "2026-06-09T08:00:00Z" `
  -EndTime "2026-06-09T20:00:00Z"
```

Salidas: JSON + CSV con 4 queries pre-construidas

Alertas NO Implementadas en Azure Monitor

Estado: Confirmado — No hay alert rules en portal

Por qué:

- Pipeline manual (no CI/CD automático) → sin triggering
- No hay runbook de auto-remediation
- Monitoreo es ad-hoc via workbooks + queries manuales
- SLA no definido (user menciona "ahora no falla nada")

Recomendación: Implementar alertas si:

1. Definen SLAs (ej: P95 CU < 30s, disponibilidad > 99%)
2. Requieren escalation automática
3. Necesitan notificaciones Slack/email

Cómo Acceder a Monitoreo Real

1. Azure Portal → Application Insights

Recurso: srbappiprodocai
Ruta: Portal → "SRBRGDOCSAIPROD" RG → "Application Insights srbappiprodocai"

Secciones útiles:

- **Performance** → Duraciones P95/P99, dependencias
- **Failures** → Errores por tipo, stack traces
- **Logs** → KQL queries custom
- **Live Metrics** → Dashboards en vivo

2. Workbook Integrado

Acceso: Azure Portal → Application Insights "srbappiprodocai"
→ "Workbooks" → Crear desde "Documentia CU Performance" (si importado)

3. Queries Manuales KQL

```
// Últimas 24h – eventos CU
customMetrics
| where timestamp > ago(24h)
| where name startswith "CU."
| summarize eventos=count(), avg_ms=round(avg(value), 1), p95_ms=round(percentile(value, 95), 1) by name
| order by name asc

// Circuit breaker status
customEvents
| where timestamp > ago(24h)
| where name in ("CU.CircuitOpen", "CU.CircuitClosed")
| project timestamp, name, tostring(customDimensions["reason"]), tostring(customDimensions["openUntilUtc"])
| order by timestamp desc
```

4. Script PowerShell

```
# Exporta reportes con queries pre-construidas
cd C:\temp\MVP\documento-ia-clasificacion-mvp
.\scripts\reports\export-cu-performance-insights.ps1 `
  -SubscriptionId "YOUR_SUBSCRIPTION_ID" `
  -ResourceGroup "SRBRGDOCSAIPROD" `
  -AppInsightsName "srbappiprodocai"
```

Configuración por App (Referencia Rápida)

Functions App (srbappiprodocai)

Setting	Valor	Propósito
APPLICATIONINSIGHTS_CONNECTION_STRING	InstrumentationKey=<INSTRUMENTATION_KEY>;...	Conexión AppInsights
Extraction__AzureContentUnderstanding__MaxConcurrentCalls	4	Limiter local (no queue)
Extraction__AzureContentUnderstanding__HardTimeoutSeconds	90	Timeout máximo CU
Extraction__AzureContentUnderstanding__EnableCircuitBreaker	true	Protección ante fallos
Extraction__AzureContentUnderstanding__CircuitBreakerFailureThreshold	5	Fallos antes de abrir circuito
Extraction__AzureContentUnderstanding__CircuitBreakerOpenSeconds	45	Duración abierto
PromptTracing__Enabled	true	Registrar prompts a AppInsights
PromptTracing__IncludePromptText	true	Incluir full prompt (no hash solo)
PromptTracing__MaxPromptTextChars	20000	Truncar si > 20KB

Cómo Diagnosticar Problemas

Problema: CU lento (P95 > 60 seg)

```
customMetrics
| where timestamp > ago(1h)
| where name == "CU.AnalysisMs"
| summarize max_ms=max(value), p95_ms=percentile(value, 95), count=count() by toString(customDimensions["Tipologia"])
| order by p95_ms desc
```

Acciones:

- ¿Es toda tipología lenta o una específica?
- Si específica → revisar tamaño promedio documento
- Si todas → contactar Azure CU support

Problema: Circuit breaker abierto

```
customEvents
| where timestamp > ago(24h)
| where name == "CU.CircuitOpen"
| project timestamp, reason=toString(customDimensions["reason"]), tipologia=toString(customDimensions["tipologia"])
| order by timestamp desc
```

Acciones:

- Verificar status Azure CU endpoint
- Revisar network connectivity desde Functions
- Si persistente > 2h → escalar a Azure support

Problema: Blobs no se limpian

```
customEvents
| where timestamp > ago(24h)
| where name == "BlobCleanupCycle"
| project timestamp,
    procesados=todint(customMeasurements["blobs_procesados"]),
    eliminados=todint(customMeasurements["blobs_eliminados"]),
    errores=todint(customMeasurements["blobs_error"])
| order by timestamp desc
```

Acciones:

- Si `errores > 0` → revisar Key Vault access permissions
- Si `procesados == 0` → revisar CRON schedule (3 AM UTC)
- Si datos obsoletos (> 3 días) → revisión manual

Escalation

Sin alertas automáticas hoy → escalation manual requerido:

1. **P1 (Crítico):** CU circuit abierto > 30 min → contactar Azure CU support
2. **P2 (Alto):** P95 CU > 120 seg → revisar workbook + diagnosticar tipología
3. **P3 (Medio):** Blob cleanup errors → revisar permisos KeyVault
4. **P4 (Bajo):** Latencia GDC > 30 seg → revisar legacy system status

Archivos Relacionados

Archivo	Propósito
src/backend/DocumentIA.Functions/Services/ApplicationInsightsTelemetryService.cs	Wrapper TelemetryClient (TrackEvent, TrackMetric)
src/backend/DocumentIA.Functions/Services/PromptTraceTelemetryService.cs	Registra prompts con privacidad (SHA256 + truncate)
src/backend/DocumentIA.Functions/host.json	Logging config AppInsights (sampling, levels)
src/backend/DocumentIA.Functions/appsettings.json	Local dev config (override en pipeline)
docs/observabilidad/workbooks/documentia-cu-performance.workbook.json	Dashboard interactivo AppInsights
scripts/reports/export-cu-performance-insights.ps1	Script exporta KQL queries a CSV/JSON
azure-pipelines.yml / azure-pipelines-functions.yml	Config resiliencia (circuit breaker, retries, timeout)

Validación

- Events CU.* verificados en AzureContentUnderstandingProvider.cs
- Metrics DocumentIA.Duracion.* verificados en PersistirActivity.cs
- Event Prompt.Trace verificado en PromptTraceTelemetryService.cs
- Circuit breaker thresholds verificados en pipeline YAML
- Workbook queries verificadas en JSON schema
- Connection string verificada en set-app-settings.ps1

Última verificación: 2026-06-10 (código fuente)