

Guía de Clasificación de Documentos — DocumentIA

Proyecto: AI DocClassExt — SAREB

Audiencia: Usuarios técnicos, usuarios de negocio, integradores de sistemas

Tabla de Contenidos

- 1. Resumen Ejecutivo (Visión de Negocio)
- 2. Conceptos Fundamentales
- 3. Flujos de Clasificación
 - 3.1 Flujo Completo (Ingest + Classify + Extract + Validate)
 - 3.2 Flujo Solo Clasificación (Classification Only)
- 4. Modos de Clasificación
 - 4.1 Clasificación Automática (Azure DI)
 - 4.2 Clasificación Forzada (ExpectedType)
 - 4.3 Fallback GPT
 - 4.4 Clasificación Mock (Desarrollo/Test)
- 5. Tipologías Soportadas
- 6. Sistema de Confianza
- 7. Configuración de Clasificación
- 8. Referencia de la API
- 9. Ejemplos Prácticos Completos
- 10. Casuísticas y Comportamientos Posibles
- 11. Errores Frecuentes y Soluciones
- 12. Añadir una Nueva Tipología

1. Resumen Ejecutivo (Visión de Negocio)

¿Qué hace DocumentIA?

DocumentIA es un sistema inteligente que **lee, identifica y clasifica documentos inmobiliarios automáticamente**. Cuando le envías un documento (PDF, imagen), el sistema determina qué tipo de documento es —sin que tengas que decírselo— y extrae los datos más relevantes de su contenido.

¿Por qué es útil?

Sin DocumentIA	Con DocumentIA
Un operario lee cada documento y anota manualmente el tipo	El sistema detecta el tipo en segundos
Entrada de datos manual propensa a errores	Extracción automática con validación de negocio
Tiempo de proceso: minutos por documento	Tiempo de proceso: 5–30 segundos por documento
Sin trazabilidad ni auditoría automática	Registro completo de cada decisión y su nivel de confianza

¿Cómo funciona a grandes rasgos?

Tú envías un PDF → DocumentIA lo "lee" → Identifica el tipo de documento
→ Extrae los datos → Valida los datos → Te devuelve el resultado estructurado

¿Qué tipos de documentos reconoce?

Tipo de Documento	Nombre Técnico	Descripción
Nota Simple	nota-simple	Documento oficial del Registro de la Propiedad que certifica la situación jurídica de una finca
Tasación	tasacion	Informe técnico que certifica el valor de mercado de un inmueble
Resumen Documental	resumen-documental	Cualquier documento para el que se quiere un resumen automático
IBI	IBI	Recibo del Impuesto sobre Bienes Inmuebles
TDN	tdn.clasificacion	Clasificación jerárquica de documentos jurídicos e inmobiliarios (notariales, escrituras, sentencias)

¿Qué resultado me devuelve?

Tras el procesamiento, recibirás:

- **Tipo de documento** identificado y con qué nivel de certeza
- **Datos extraídos** del documento (campos estructurados)
- **Estado de calidad:** OK , REVISION o ERROR
- **Puntuación de confianza** (0–1) descompuesta por etapa
- Un **resumen ejecutivo** del documento (cuando está configurado)

Nivel de confianza para usuarios de negocio

Indicador	Qué significa	Acción recomendada
OK (≥ 0.85)	El sistema tiene alta certeza sobre el documento y sus datos	Procesamiento automático sin revisión
REVISION (0.70–0.85)	El sistema tiene dudas; los datos pueden ser correctos pero conviene revisar	Revisión humana recomendada
ERROR (< 0.70)	Alta probabilidad de que algo no sea correcto	Revisión humana obligatoria
NO_CLASIFICADO	El sistema no pudo identificar el tipo de documento	Intervención manual necesaria

2. Conceptos Fundamentales

2.1 Tipología

Una **tipología** representa un tipo de documento con su configuración asociada: campos a extraer, reglas de validación, proveedores de IA, y umbrales de confianza.

Una misma tipología puede tener múltiples **versiones** (ej: nota-simple v1.0 , v1.3 , v1.4). Siempre hay una versión marcada como isDefault: true que es la que se usa por defecto.

```
Familia: "nota-simple"
├── versión 1.0 (legacy)
├── versión 1.2 (legacy)
├── versión 1.3 (legacy)
└── versión 1.4 ← DEFAULT (activa)
```

2.2 ExpectedType

Parámetro opcional de la petición. Si lo informas, el sistema **omite la clasificación automática** y usa ese tipo directamente (confianza = 1.0). Útil cuando el sistema origen ya sabe qué tipo de documento es.

```
"instrucciones": {
  "expectedType": "nota-simple" // Fuerza la tipología sin clasificación IA
}
```

2.3 Confianza

Puntuación numérica de 0 a 1 que indica cuánta certeza tiene el sistema en cada etapa:

- **Confianza de clasificación:** ¿qué seguro estoy de que este es el tipo de documento correcto?
- **Confianza de extracción:** ¿qué completos y fiables son los datos que he extraído?
- **Confianza de validación:** ¿cuántas reglas de negocio ha superado el documento?
- **Confianza global:** el mínimo de las tres anteriores (el eslabón más débil)

2.4 Estado vs. Estado de Calidad

Son dos campos independientes en el resultado:

Campo	Descripción	Valores posibles
Estado	Resultado del proceso (éxito o tipo de fallo)	OK , VALIDACION_CON_ERRORES , ERROR , DUPLICADO , NO_CLASIFICADO
EstadoCalidad	Fiabilidad de los datos obtenidos	OK , REVISION , ERROR

Un documento puede terminar en Estado=OK pero EstadoCalidad=REVISION (proceso completado, pero con confianza media que requiere revisión humana).

2.5 Flujo Asíncrono

El procesamiento es siempre asíncrono:

1. **POST** a /api/IngestDocument → respuesta inmediata 202 Accepted con instanceId
2. **GET** a la URL de estado → verificar si está Running o Completed
3. **Leer resultado** del campo output cuando runtimeStatus = "Completed"

```
POST /api/IngestDocument
↳ 202 { instanceId: "abc123" }

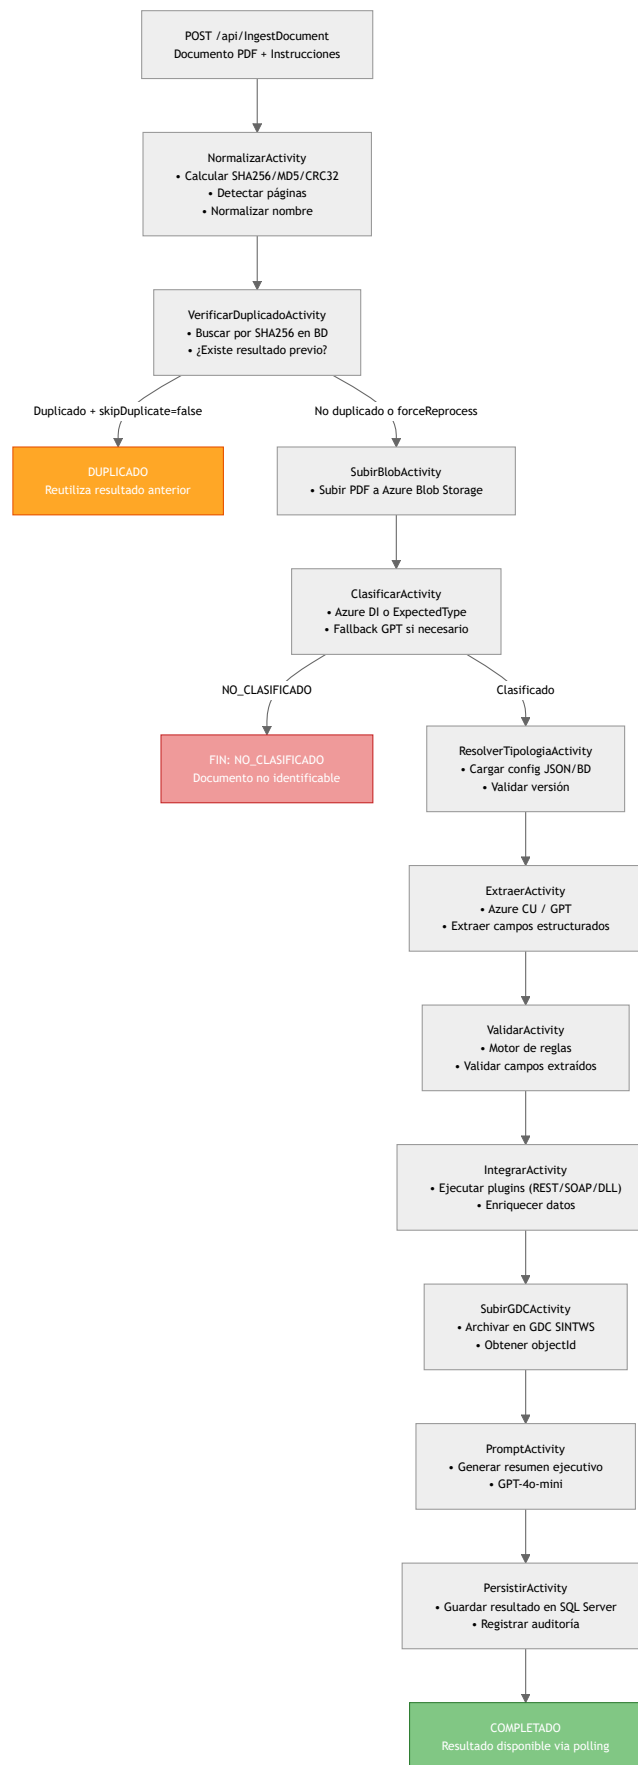
GET /runtime/.../instances/abc123
↳ { runtimeStatus: "Running", customStatus: { actividad: "Extraer" } }

GET /runtime/.../instances/abc123 (unos segundos después)
↳ { runtimeStatus: "Completed", output: { resultado: { estado: "OK" } } }
```

3. Flujos de Clasificación

3.1 Flujo Completo

El flujo completo incluye todas las etapas del pipeline: normalización, detección de duplicados, subida a blob, clasificación, extracción, validación, integración con plugins, subida al GDC y persistencia en base de datos.



Actividades del flujo completo y su propósito

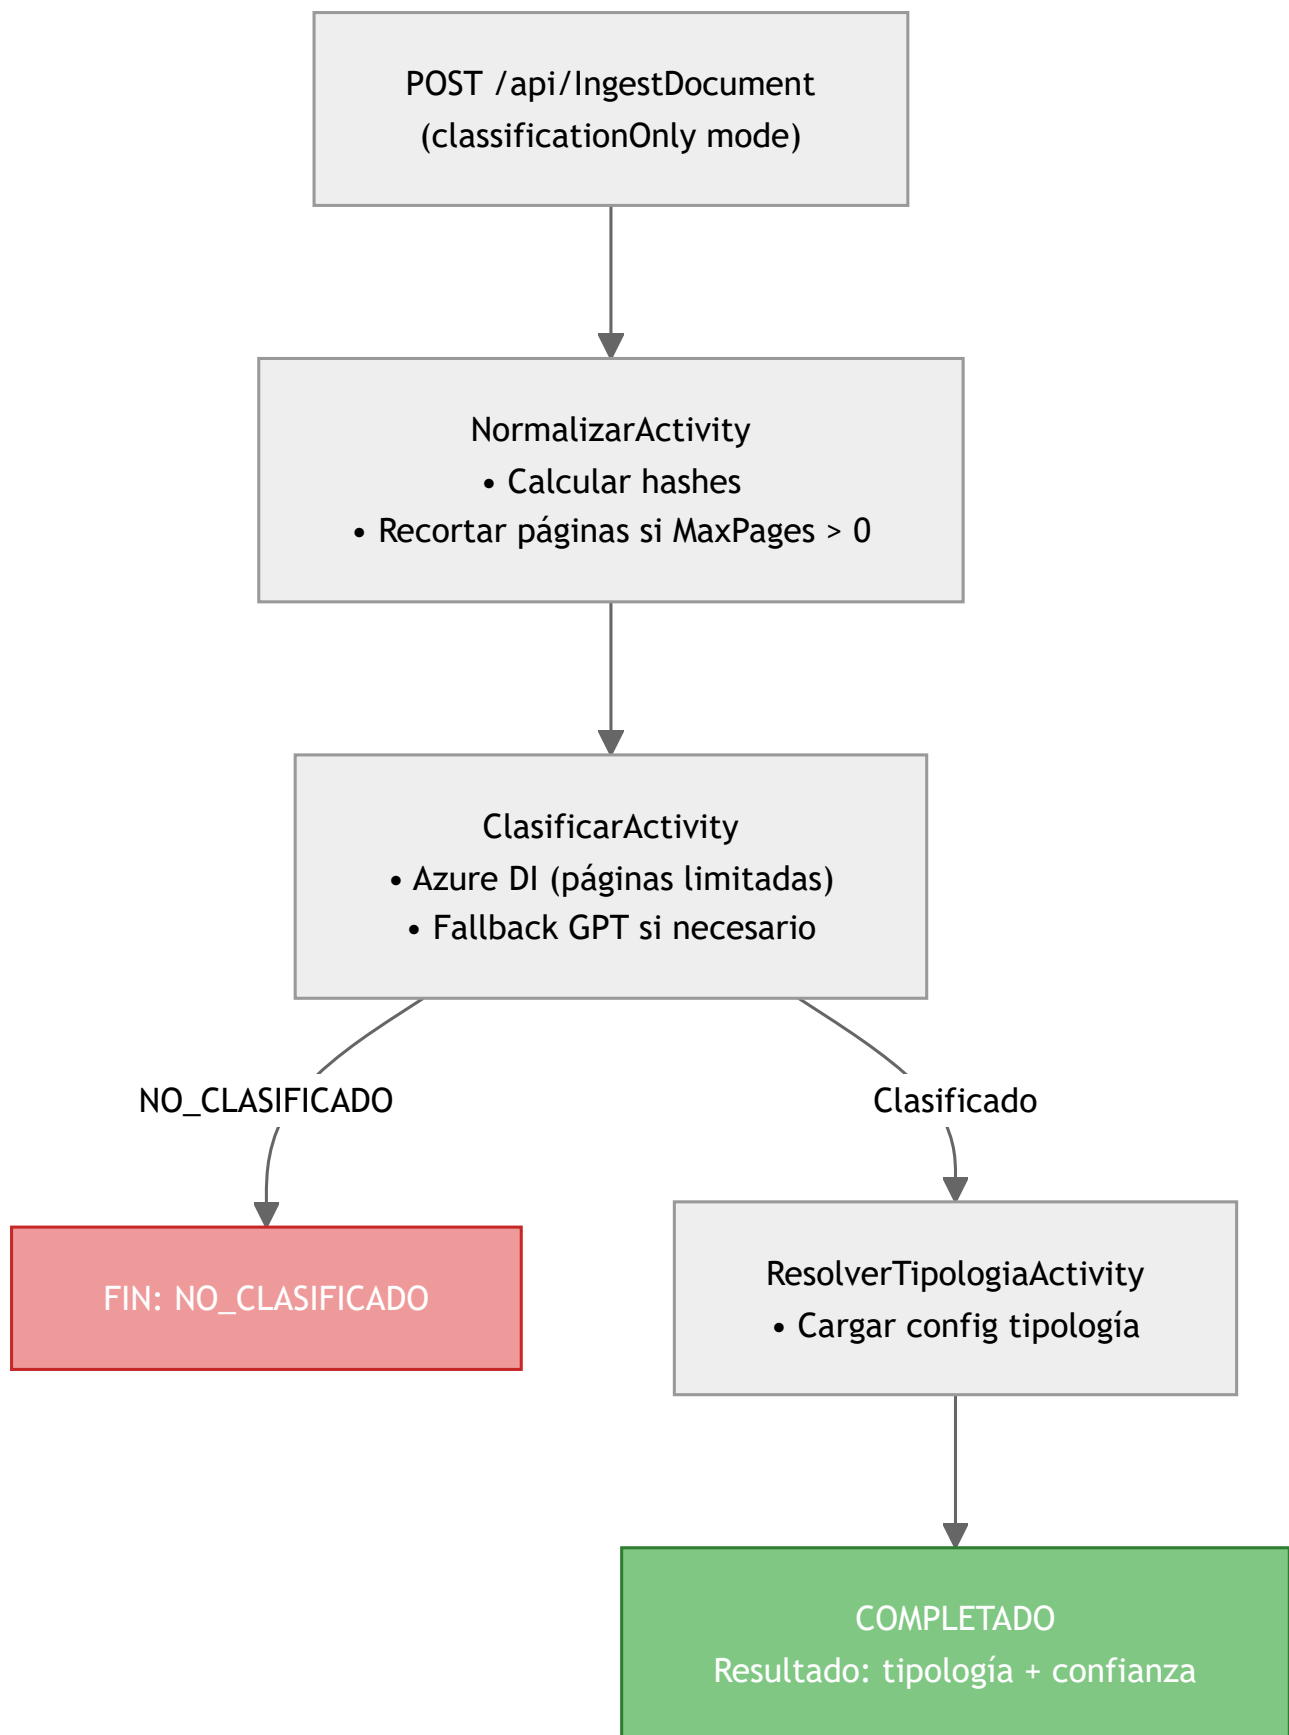
Actividad	Propósito	Tiempo estimado
NormalizarActivity	Calcula hashes (SHA256, MD5, CRC32), detecta páginas, normaliza el nombre del fichero	< 1 s
VerificarDuplicadoActivity	Detecta si el documento ya fue procesado (por SHA256)	< 1 s
SubirBlobActivity	Sube el PDF a Azure Blob Storage para trazabilidad y procesamiento posterior	1–3 s
ClasificarActivity	Identifica el tipo de documento mediante Azure DI o GPT	3–15 s
ResolverTipologiaActivity	Carga la configuración de la tipología detectada	< 1 s
ExtraerActivity	Extrae campos estructurados del documento (Azure CU o GPT)	5–20 s
ValidarActivity	Valida los campos extraídos contra las reglas de negocio	< 1 s
IntegrarActivity	Ejecuta plugins de enriquecimiento (REST/SOAP/DLL)	1–10 s
SubirGDCActivity	Archiva el documento en el GDC corporativo (SINTWS SOAP)	2–8 s
PromptActivity	Genera un resumen ejecutivo del documento usando LLM	3–8 s
PersistirActivity	Persiste el resultado completo en SQL Server	< 1 s

Tiempo total estimado: 15–60 segundos (variable según tamaño del documento y latencia de servicios externos).

3.2 Flujo Solo Clasificación

El flujo de **solo clasificación** es un modo optimizado que detiene el pipeline tras identificar el tipo de documento, sin ejecutar extracción, validación, plugins ni persistencia completa.

Cuándo usar: Cuando solo necesitas saber qué tipo de documento es, sin procesar su contenido ni integrar con sistemas externos.



Activar el modo solo clasificación

Se activa mediante el parámetro `instrucciones.classificationOnly` (o el script dedicado) con la instrucción de no ejecutar extracción:

```

{
  "instrucciones": {
    "skipDuplicateCheck": true,
    "classification": {
      "provider": "auto",
      "model": "auto",
      "umbral": 0.50
    },
    "extraction": {
      "provider": "mock"
    }
  },
  "documento": {
    "name": "documento_desconocido.pdf",
    "content": { "base64": "<BASE64>" }
  }
}

```


Diferencias entre flujo completo y solo clasificación

Característica	Flujo Completo	Solo Clasificación
Actividades ejecutadas	Todas (11 actividades)	3-4 actividades
Extracción de datos	Sí	No
Validación de campos	Sí	No
Plugins de enriquecimiento	Sí	No
Subida a GDC	Sí (si configurado)	No
Persistencia en BD	Completa	Mínima (solo clasificación)
Tiempo estimado	15-60 s	4-18 s
Coste estimado (tokens IA)	Alto	Bajo
Ideal para	Procesamiento definitivo	Pre-clasificación, enrutamiento, validación masiva

4. Modos de Clasificación

4.1 Clasificación Automática (Azure DI)

El modo por defecto. El sistema envía el documento a **Azure AI Document Intelligence** (modelo custom `DocumentAICC_v0`) que devuelve una tipología y una puntuación de confianza.



Configuración del modelo de clasificación:

```
// config/classification/models.json
{
  "Models": [
    {
      "Key": "default.azure-di",
      "Provider": "azure-document-intelligence",
      "ClassifierId": "DocumentAICC_v0",
      "ApiVersion": "2024-11-30",
      "IsDefault": true,
      "UseAsFallback": false,
      "TimeoutSeconds": 120
    },
    {
      "Key": "classification.gpt4o-mini-fallback",
      "Provider": "azure-openai",
      "IsDefault": false,
      "UseAsFallback": true,
      "DeploymentName": "gpt-4o-mini",
      "TimeoutSeconds": 30,
      "MaxTokens": 150
    }
  ]
}
```

Umbral de confianza configurable por petición:

```
"instrucciones": {
  "classification": {
    "provider": "auto",
    "model": "auto",
    "umbral": 0.85 // ← Se puede ajustar por petición (0.0 - 1.0)
  }
}
```

Umbral	Comportamiento
0.85 (default)	Fallback GPT si DI < 0.85
0.50	Acepta clasificaciones DI con confianza ≥ 0.50, fallback solo si < 0.50
1.0	Siempre fallback GPT (DI nunca supera 1.0)
0.0	Nunca fallback (acepta cualquier confianza DI, excepto RESTO)

4.2 Clasificación Forzada (ExpectedType)


Cuando el sistema de origen ya conoce el tipo de documento, puede informar `expectedType` para **saltarse la clasificación automática**. El sistema usa directamente esa tipología con `confianza = 1.0` y el modelo registrado como `"expectedtype-input"`.

```
// Ejemplo: forzar clasificación como Nota Simple v1.4
{
  "instrucciones": {
    "expectedType": "nota-simple",
    "skipDuplicateCheck": false
  }
}
```

Formatos válidos para `expectedType` :

Formato	Ejemplo	Resultado
Nombre de familia	"nota-simple"	Usa la versión <code>isDefault: true</code> (actualmente v1.4)
Familia@versión	"nota-simple@1.3"	Usa exactamente la versión 1.3
Clave técnica	"nota.simple.1_3"	Usa la clave técnica directa

Comportamiento con `expectedType` informado:



Nota: Si el `expectedType` no existe en el registro de tipologías, el proceso termina en `ERROR` con `KeyNotFoundException`.

4.3 Fallback GPT

Cuando Azure DI no puede clasificar con suficiente confianza, el sistema activa automáticamente el **fallback GPT** (modelo `gpt-4o-mini`).

Tipologías incluidas en el prompt GPT

El sistema construye dinámicamente la lista de tipologías que ofrece al LLM a partir de la tabla `Tipologias` en base de datos. Se incluyen **todas las tipologías con estado `Published` y activas que tengan un `tipologiaId` válido**, usando el campo `gptDescripcion` como descripción semántica (si está vacío, se usa `tipologiaNombre` como fallback).

Comportamiento de caché: el prompt se regenera desde BD como máximo cada 5 minutos (IMemoryCache TTL). Si se publica o modifica una tipología, el cambio se refleja en el siguiente ciclo.

Campo JSON	Uso en el prompt
<code>tipologiaId</code>	Identificador que el LLM debe devolver
<code>gptDescripcion</code>	Descripción semántica optimizada para el LLM
<code>tipologiaNombre</code>	Fallback si <code>gptDescripcion</code> está vacío

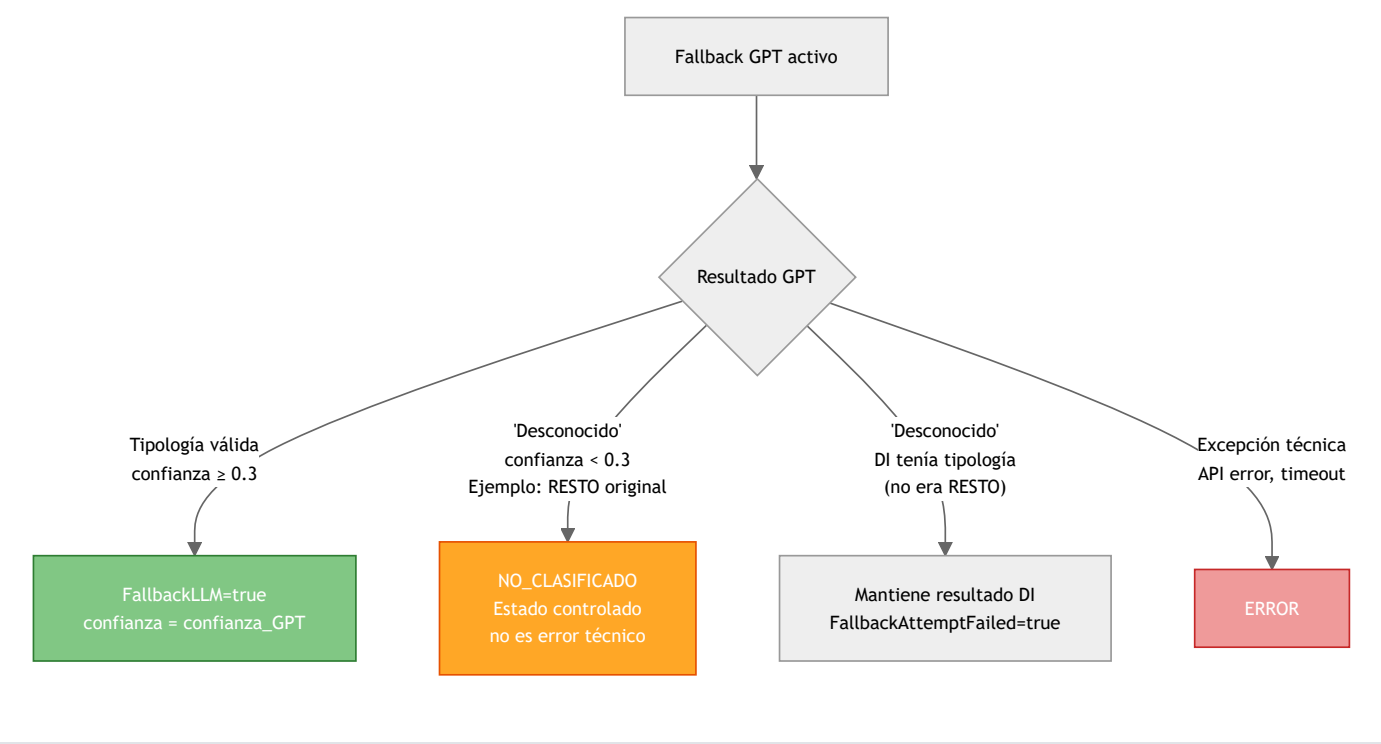
Las tipologías con el mismo `tipologiaId` (distintas versiones de la misma familia) aparecen **una sola vez** en el prompt — se usa la primera encontrada para evitar duplicados.

Condiciones que activan el fallback

Condición	FallbackRazon en el resultado	¿Fallback obligatorio?
DI devuelve <code>RESTO</code>	<code>resto_classification:{confianza}</code>	Sí siempre
DI con <code>confianza < umbral</code>	<code>low_confidence:{confianza}</code>	Sí si <code>< umbral</code>
Error/timeout de la API de DI	<code>exception:{mensaje}</code>	Sí si hay resultado DI parcial

Qué ocurre si el fallback también falla

Situación del fallback GPT	Resultado final
GPT devuelve tipología con confianza ≥ 0.3	Clasificado (con <code>FallbackLLM=true</code>)
GPT devuelve "Desconocido" o confianza < 0.3 (RESTO)	<code>NO_CLASIFICADO</code> (fin controlado)
GPT devuelve "Desconocido" pero DI tenía resultado $<$ umbral	El proceso mantiene el resultado DI (no termina en error)
GPT lanza excepción técnica	<code>ERROR</code>



4.4 Clasificación Mock (Desarrollo/Test)

En entornos de desarrollo, se puede usar el proveedor `mock` que devuelve siempre una tipología predefinida sin llamar a ningún servicio externo.

```
"instrucciones": {
  "classification": {
    "provider": "mock",
    "model": "auto"
  }
}
```

Útil para: tests unitarios, desarrollo local sin conectividad a Azure, validación de flujos de extracción sin depender de la clasificación.

5. Tipologías Soportadas

5.1 Inventario completo

Estado BD: 15 tipologías Published+Activa (mayo 2026). 14 tienen `gptDescripcion` configurada y participan en el fallback GPT.

Tipologías de extracción y prompt (motor clásico)

Familia	Clave técnica	GDC	Extracción	Prompt	Skip GDC	gptDescripcion
nota-simple (v1.4, default)	nota.simple.1_4	NOTS/NOTS01	Azure CU	gpt4o-mini	No	Sí
nota-simple (v1.0, legacy)	nota.simple	NOTS/NOTS01	Ninguna	No	No	Sí
tasacion	tasacion	—	Ninguna	No	Sí	Sí
resumen-documental	resumen.documental	—	Mock	vision	Sí	Sí
IBI (v1.1, DB-backed)	IBI_1.1	—	Azure OpenAI	No	Sí	Sí
general-prompting	general-prompting	—	—	Sí	Sí	No

Tipologías TDN de clasificación jurídica (motor Hybrid)

Estas tipologías son clasificadas por el motor `HybridTdnClasificarProvider` (reglas → DI → rescate LLM). No tienen extracción de campos ni subida a GDC.

Código BD	tipologiaId	Familia TDN	Descripción resumida	gptDescripcion
ESCR-01	escr.titularidad.otro	Escrituras	Cancelación hipoteca, carta de pago	Sí
ESCR-06	escr.titularidad.otro	Escrituras	Dación en pago, adjudicación	Sí
ESCR-10	escr.compraventa	Escrituras	Compraventa inmobiliaria	Sí
ESCR-26	escr.titularidad.otro	Escrituras	Titularidad residual (dominio, propiedad)	Sí
ESCR-29	escr.titularidad.otro	Escrituras	Titularidad acreditada contractual/notarial	Sí
DOCN-06	docn.complementario	Documentos notariales	Acta/escritura complementaria o subsanación	Sí
SERE-24	sere.ejecucion	Sentencias/Resoluciones	Ejecución hipotecaria judicial	Sí
SERE-25	sere.cancelacion	Sentencias/Resoluciones	Mandamiento cancelación cargas	Sí
SERE-26	sere.adjudicacion	Sentencias/Resoluciones	Testimonio judicial de adjudicación	Sí

5.2 Nota Simple (v1.4 — default)

Descripción: Nota simple registral española. Documento oficial del Registro de la Propiedad que certifica la situación jurídica de una finca: titular dominical, cargas, hipotecas, servidumbres y gravámenes.

Campos extraídos:

Campo	Obligatorio	Tipo	Regla de validación	Severidad
FincaRegistral	Sí	string	minLength=1, maxLength=30	Error
RegistroPropiedad	No	string	minLength=3, maxLength=120	Error
MunicipioRegistro	No	string	maxLength=80	Warning
IDUFIR_CRU	No	string	regex <code>^[0-9]{14}\$</code>	Warning
Registrador	No	string	minLength=3, maxLength=120	Error
FechaDocumento	Sí	date	formatos <code>dd/MM/yyyy</code> / <code>yyyy-MM-dd</code> , no futura	Error
NumeroAsientoPresentacion	No	string	maxLength=40	Warning
Direccion	No	string	address (min=6, max=160, número+municipio+provincia)	Warning
ReferenciaCatastral	No	string	catastral	Warning
CodigoPostal	No	string	regex <code>^[0-9]{5}\$</code>	Warning
Provincia	No	string	maxLength=50	Warning
Municipio	No	string	—	Warning

Configuración de confianza:

```
"confidenceConfig": {
  "clasifUmbralFallback": 0.85,
  "extracUmbralFallback": 0.9,
  "extracWeightCampos": 0.5,
  "extracWeightRequeridos": 0.3,
  "extracWeightWarnings": 0.2,
  "umbralOK": 0.85,
  "umbralRevision": 0.70
}
```

Plugins activos (v1.4):

Plugin	Tipo	URL	Propósito	Prioridad
refCatExcel	REST	<code>http://localhost:8082/enriquecer</code>	Enriquecimiento por referencia catastral	1 (crítico)

5.3 Tasación (v1.0)

Descripción: Informe de tasación inmobiliaria. Certifica el valor de mercado de un inmueble.

Campos extraídos:

Campo	Obligatorio	Tipo	Regla	Severidad
ValorTasado	Sí	decimal	rango [1.000 – 2.000.000]	Error
FechaDocumento	Sí	date	formatos <code>dd/MM/yyyy</code> / <code>yyyy-MM-dd</code> , no futura	Error
Direccion	No	string	address (min=6, max=160)	—
NIF	No	string	nif	Warning
ReferenciaCatastral	No	string	catastral	Warning

La tasación **no sube al GDC** (`skipGDCUpload: true`) y **no tiene extracción configurada** en la versión actual (los datos se reciben directamente o se procesan en otro sistema).

5.4 Resumen Documental (v1.0)

Descripción: Tipología genérica para documentos de los que solo se quiere un resumen. No valida campos específicos.

- No tiene campos de validación (array vacío).
- Extracción: `disabled` (provider mock).
- Prompt activado con modo `vision` (envía imagen del documento al LLM).
- No sube al GDC.

5.5 IBI (v1.0 — DB-backed)

Descripción: Recibo del Impuesto sobre Bienes Inmuebles emitido por el ayuntamiento.

Esta tipología está almacenada en base de datos, no en ficheros JSON en disco. Usa `extraction.provider = "azure-openai"` → extracción directa con GPT.

Campos extraídos:

Campo	Obligatorio	Tipo	Regla
<code>FechaDocumento</code>	Sí	date	formatos <code>dd/MM/yyyy</code> / <code>yyyy-MM-dd</code> , no futura
<code>Direccion</code>	No	string	address (min=6, max=160)
<code>NIF</code>	No	string	nif
<code>ReferenciaCatastral</code>	No	string	catastral

5.6 TDN Clasificación (v1.0)

Descripción: Clasificación jerárquica de documentos jurídicos e inmobiliarios. Organiza documentos en tres niveles: TDN1 → TDN2 → Matrícula.

Familias TDN1 soportadas:

Código TDN1	Nombre	Ejemplos de subtipo
<code>DOCN</code>	Documentos notariales	<code>cambio-titularidad-sareb</code>
<code>ESCR</code>	Escrituras	<code>compraventa</code> , <code>dacion</code> , <code>cancelacion-hipotecaria</code> , <code>prestamo-originario</code>
<code>SERE</code>	Sentencias y resoluciones judiciales	<code>subasta-adjudicacion-auto</code> , <code>subasta-cancelacion-cargas</code>

- Sin extracción de campos (solo clasificación jerárquica).
- Sin prompt.
- No sube al GDC (`skipGDCUpload: true`).
- Policy de clasificación avanzada con control de páginas y umbrales por ambigüedad.


6. Sistema de Confianza

6.1 Cálculo de la confianza global

La confianza global es el **mínimo de las tres etapas**:

$$ConfianzaGlobal = \min(ConfianzaClasif, ConfianzaExtrac, ConfianzaValidación)$$

Si la extracción está deshabilitada para la tipología, se omite del cálculo.



6.2 Umbrales de calidad

Estado	Rango de confianza	Descripción
OK	≥ 0.85	Procesamiento automático sin revisión humana
REVISION	0.70 – 0.84	Revisión humana recomendada
ERROR	< 0.70	Alta probabilidad de dato incorrecto

6.3 Fórmula de confianza de clasificación

Si se usó fallback GPT:
 $\text{confianza} = \text{CLAMP}(\text{confianza_GPT} ?? \text{confianza_DI} ?? 0.5, 0, 1)$

Si no se usó fallback:
 $\text{confianza} = \text{CLAMP}(\text{confianza_DI} ?? 0.0, 0, 1)$

6.4 Fórmula de confianza de extracción (Azure CU)

$$\text{ConfianzaExtrac} = w_{\text{campos}} \cdot \text{AvgConf} + w_{\text{req}} \cdot \text{RatioRequeridos} + w_{\text{warn}} \cdot (1 - \text{RatioWarnings})$$

Variable	Descripción	Peso default (nota-simple 1.4)
AvgConf	Promedio de confianza individual de campos según CU	$w_{\text{campos}} = 0.50$
RatioRequeridos	Campos obligatorios presentes / total obligatorios	$w_{\text{req}} = 0.30$
$1 - \text{RatioWarnings}$	Penalización por warnings de validación	$w_{\text{warn}} = 0.20$

Ejemplo de cálculo:

```

AvgConf = 0.90 (Azure CU informa 90% confianza media)
RatioRequeridos = 1.0 (todos los campos obligatorios presentes)
RatioWarnings = 0.10 (10% de campos con warning)

ConfianzaExtrac = 0.50×0.90 + 0.30×1.0 + 0.20×(1-0.10)
                = 0.45 + 0.30 + 0.18
                = 0.93

```

6.5 Fórmula de confianza de validación

$$\text{ConfianzaValidación} = 1 - \frac{\text{errores}}{\text{reglasRequeridas}}$$

Ejemplo: 2 errores sobre 10 reglas requeridas
 ConfianzaValidación = 1 - (2/10) = 0.80 → EstadoCalidad: REVISION

7. Configuración de Clasificación

7.1 Jerarquía de configuración

La configuración se aplica en orden de prioridad descendente:

```

Petición HTTP (instrucciones)
  ↓ Si no informado
Configuración de tipología (validation.json)
  ↓ Si no informado
Configuración global del servidor (appsettings.json)
  ↓ Si no informado
Valores por defecto del sistema

```

7.2 Parámetros configurables por petición

```

{
  "instrucciones": {
    "expectedType": "nota-simple",           // Forzar tipología (omite clasificación IA)
    "skipDuplicateCheck": false,             // Omitir verificación de duplicados
    "forceReprocess": false,                // Forzar reproceso aunque sea duplicado
    "skipGDCUpload": null,                  // null=respeta config tipología, true/false=forzar
    "classification": {
      "provider": "auto",                    // auto|azure-document-intelligence|mock
      "model": "auto",                       // auto (usar modelo default configurado)
      "umbral": 0.85                         // Umbral fallback (0.0-1.0)
    },
    "extraction": {
      "provider": "auto",                    // auto|azure-content-understanding|azure-openai|mock
      "model": "auto",                       // Clave del modelo en ModeloConfigs
      "umbral": 0.80                         // Umbral mínimo de campos para aceptar extracción
    },
    "prompt": {
      "systemPrompt": "Eres un experto...", // Override del system prompt de la tipología
      "userPromptTemplate": "Resumen: {{CONTENT}}",
      "modelKey": "default.gpt4o-mini",
      "temperature": 0.0,                    // 0.0-2.0
      "maxTokens": 1200,                     // 100-4000
      "contentMode": "markdown"              // markdown|vision
    }
  }
}

```

7.3 Estructura de un fichero de validación de tipología

```
// config/tipologias/<familia>.<version>.validation.json
{
  "tipologiaId": "nota-simple",
  "tipologiaNombre": "Nota Simple",
  "version": "1.4",
  "isDefault": true,          // true = versión por defecto de la familia (para resolución de ExpectedType)
  "skipGDCUpload": false,
  "gptDescripcion": "Nota simple registral española...", // descripción semántica para prompt fallback GPT

  // Configuración de extracción IA
  "extraction": {
    "enabled": true,
    "provider": "azure-content-understanding",
    "modelKey": "nota.simple.1_4.azure-cu",
    "autoMapUnmappedFields": true,
    "fieldMappings": []
  },

  // Configuración de prompt/resumen
  "promptConfig": {
    "enabled": true,
    "modelKey": "default.gpt4o-mini",
    "systemPrompt": "Eres un analista documental...",
    "userPromptTemplate": "Genera un resumen ejecutivo...\n\nContenido:\n{contenido}",
    "maxTokens": 1600,
    "temperature": 0,
    "contentMode": "markdown"
  },

  // Umbrales de confianza
  "confidenceConfig": {
    "clasifUmbralFallback": 0.85,
    "extracUmbralFallback": 0.9,
    "extracWeightCampos": 0.5,
    "extracWeightRequeridos": 0.3,
    "extracWeightWarnings": 0.2,
    "umbralOK": 0.85,
    "umbralRevision": 0.70
  },

  // Campos a validar tras la extracción
  "fields": [
    {
      "name": "FincaRegistral",
      "type": "string",
      "required": true,
      "rules": [
        { "ruleType": "minLength", "severity": "Error", "parameters": { "value": 1 } },
        { "ruleType": "maxLength", "severity": "Error", "parameters": { "value": 30 } }
      ]
    }
    // ... más campos
  ]
}
```

7.4 Estructura de un fichero de plugins


```
// config/tipologias/<familia>.<version>.plugins.json
{
  "tipologiaId": "nota-simple",
  "plugins": [
    {
      "pluginKey": "refCatExcel",
      "pluginType": "rest",          // rest|soap|custom
      "enabled": true,
      "priority": 1,                 // 1 = crítico (fallo termina proceso)
      "returnsIdActivo": true,       // ¿El plugin devuelve idActivo?
      "configuration": {
        "baseUrl": "http://localhost:8082",
        "endpoint": "/enriquecer",
        "method": "POST",
        "authType": "None"
      }
    }
  ]
}
```

Prioridad de plugin: Si el plugin con `priority=1` falla, el proceso termina en `ERROR` sin llegar a `PersistirActivity`. Plugins con prioridad `> 1` son no críticos.

7.5 Tipos de reglas de validación disponibles

Tipo de regla	Descripción	Ejemplo de parámetros
<code>minLength</code>	Longitud mínima del texto	<code>{ "value": 1 }</code>
<code>maxLength</code>	Longitud máxima del texto	<code>{ "value": 120 }</code>
<code>date</code>	Validación de fecha	<code>{ "formats": ["dd/MM/yyyy"], "allowFuture": false }</code>
<code>regex</code>	Expresión regular	<code>{ "pattern": "^([0-9]{14})\$" }</code>
<code>range</code>	Rango numérico	<code>{ "min": 1000, "max": 2000000 }</code>
<code>nif</code>	Validación de NIF/NIE/CIF español	<i>(sin parámetros adicionales)</i>
<code>catastral</code>	Validación de referencia catastral	<i>(sin parámetros adicionales)</i>
<code>address</code>	Validación de dirección postal	<code>{ "minLength": 6, "maxLength": 160, "requireStreetNumber": true }</code>

8. Referencia de la API

8.1 Endpoint principal

```
POST /api/IngestDocument
Content-Type: application/json
x-functions-key: <function-key> (producción)
```

URL base:

- Local: `http://localhost:7071`
- Azure: `https://srbappprodoci.azurewebsites.net`

8.2 Estructura completa de la petición

```

{
  "instrucciones": {
    "expectedType": "string | null",
    "skipDuplicateCheck": false,
    "forceReprocess": false,
    "skipGDCUpload": null,
    "classification": {
      "provider": "auto",
      "model": "auto",
      "umbral": 0.85
    },
    "extraction": {
      "provider": "auto",
      "model": "auto",
      "umbral": 0.80
    },
    "prompt": {
      "systemPrompt": "string | null",
      "userPromptTemplate": "string | null",
      "modelKey": "string | null",
      "temperature": 0.0,
      "maxTokens": 1200,
      "contentMode": "markdown | vision"
    },
    "assetResolver": {
      "enabled": null,
      "camposBusqueda": {
        "idufir": "string | null",
        "referenciaCatastral": "string | null"
      },
      "camposSolicitados": ["ID_ACTIVO_SAREB"]
    }
  },
  "documento": {
    "name": "mi_documento.pdf",
    "objectIdGDC": null,
    "content": {
      "base64": "<PDF_EN_BASE64>"
    }
  },
  "trazabilidad": {
    "correlationId": "uuid-o-string-personalizado",
    "submittedBy": "sistema-origen",
    "idActivo": "ID_ACTIVO_OPCIONAL"
  }
}

```

Regla importante: `documento.objectIdGDC` y `documento.content.base64` son mutuamente excluyentes. Debes usar uno u otro.

8.3 Respuesta del endpoint (202 Accepted)

```

{
  "instanceId": "abc123def456ghi789",
  "statusQueryUri": "https://host/runtime/webhooks/durabletask/instances/abc123def456ghi789",
  "correlationId": "mi-correlation-id"
}

```

8.4 Estructura del resultado final (Completed)

```

{
  "runtimeStatus": "Completed",
  "output": {
    "identificacion": {
      "documento": "nota_simple_123.pdf",
      "guid": "xxxxxxxx-xxxx-xxxx-xxxx-xxxxxxxxxxxx",
      "tipologia": "nota.simple.1_4",
      "tipologiaFamilia": "nota-simple",
      "tipologiaVersion": "1.4",
      "fechaProceso": "2026-05-19T10:00:10Z",
      "paginas": 5
    },
    "integridad": {
      "crc32": "a1b2c3d4",
      "sha256": "abcdef0123456789...",
      "md5": "fedcba9876543210...",
      "rutaBlobStorage": "documents/nota_simple_123.pdf",
      "gestorDocumental": "GDC",
      "idActivo": "ACTIVO-001",
      "idActivoEntrada": null,
      "idActivoCambiado": false
    },
    "datosExtraidos": {
      "FincaRegistral": "12345",
      "RegistroPropiedad": "REGISTRO DE LA PROPIEDAD DE CHIVA 1",
      "FechaDocumento": "2026-01-15",
      "IDUFIR_CRU": "12345678901234",
      "Direccion": "Calle Mayor 1, 46370 Chiva, Valencia",
      "ReferenciaCatastral": "1234567AB0000A0001ZZ",
      "CodigoPostal": "46370",
      "Provincia": "Valencia",
      "Municipio": "Chiva",
      "PromptResult": "(1) Objetivo: certifica situación jurídica de finca...\n(2) Datos clave: ..."
    },
    "resultado": {
      "estado": "OK",
      "mensajeError": null,
      "confianzaGlobal": 0.92,
      "estadoCalidad": "OK",
      "confianzaClasificacion": 0.95,
      "confianzaExtraccion": 0.91,
      "confianzaValidacion": 0.92,
      "reutilizadaPorDuplicado": false
    },
    "detalleEjecucion": {
      "instanceId": "abc123def456...",
      "clasificacion": {
        "tipologiaDetectada": "nota.simple.1_4",
        "clasificador": "DocumentAICC_v0",
        "confianza": 0.95,
        "fallbackLLM": false,
        "fallbackRazon": null,
        "pagesProcessed": 3
      },
      "extraccion": {
        "proveedor": "azure-content-understanding",
        "camposExtraidos": 10,
        "camposTotales": 12,
        "metricas": {
          "promedioConfianza": 0.93,
          "ratioRequeridos": 1.0
        }
      },
      "validacion": {
        "errores": 0,
        "warnings": 2,
        "totalReglas": 12
      }
    }
  }
}

```

```
}  
}
```

8.5 Estados posibles del campo resultado.estado

Estado	Descripción
OK	Procesamiento completado correctamente
VALIDACION_CON_ERRORES	Completado pero con errores de validación de campos
ERROR	Error técnico en alguna actividad del pipeline
DUPLICADO	Documento ya procesado; se reutiliza el resultado anterior
NO_CLASIFICADO	No se pudo identificar el tipo de documento

9. Ejemplos Prácticos Completos

Ejemplo 1: Flujo mínimo — Clasificación automática

El caso más simple: enviar un documento sin configuración adicional para que el sistema lo clasifique y procese automáticamente.

```
# PowerShell – Flujo mínimo  
$pdf = [IO.File]::ReadAllBytes("C:\docs\nota_simple.pdf")  
$b64 = [Convert]::ToBase64String($pdf)  
  
$body = @{  
    documento = @{  
        name = "nota_simple.pdf"  
        content = @{ base64 = $b64 }  
    }  
    trazabilidad = @{  
        correlationId = [guid]::NewGuid().ToString()  
        submittedBy = "mi-sistema"  
    }  
} | ConvertTo-Json -Depth 5  
  
$r = Invoke-RestMethod -Method POST `   
    -Uri "http://localhost:7071/api/IngestDocument" `   
    -ContentType "application/json" `   
    -Body $body  
  
Write-Host "InstanceId: $($r.instanceId)"
```

```
# curl – Flujo mínimo  
BASE64=$(base64 -w0 nota_simple.pdf)  
curl -X POST http://localhost:7071/api/IngestDocument \   
    -H "Content-Type: application/json" \   
    -d "{  
        \"documento\": {  
            \"name\": \"nota_simple.pdf\",  
            \"content\": { \"base64\": \"${BASE64}\" }  
        },  
        \"trazabilidad\": {  
            \"correlationId\": \"$(uuidgen)\",  
            \"submittedBy\": \"mi-sistema\"  
        }  
    }"
```

Ejemplo 2: Clasificación forzada por tipo conocido

Cuando el sistema origen ya sabe qué tipo de documento es:

```
{
  "instrucciones": {
    "expectedType": "nota-simple",
    "skipDuplicateCheck": false
  },
  "documento": {
    "name": "NS_30000876.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "BATCH-2026-0519-001",
    "submittedBy": "sistema-batch",
    "idActivo": "354937"
  }
}
```

Resultado esperado:

```
{
  "resultado": {
    "estado": "OK",
    "confianzaClasificacion": 1.0
  },
  "detalleEjecucion": {
    "clasificacion": {
      "clasificador": "expectedtype-input",
      "fallbackLLM": false,
      "confianza": 1.0
    }
  }
}
```

Ejemplo 3: Clasificación automática con umbral bajo (modo permisivo)

Para documentos donde se acepta clasificar aunque la confianza de DI sea baja:

```
{
  "instrucciones": {
    "skipDuplicateCheck": true,
    "forceReprocess": true,
    "classification": {
      "provider": "auto",
      "model": "auto",
      "umbral": 0.50
    }
  },
  "documento": {
    "name": "documento_dudoso.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "TEST-LOW-CONF-001",
    "submittedBy": "validacion.calidad"
  }
}
```

Ejemplo 4: Clasificación con fallback GPT explícito

Cuando se quiere forzar siempre el fallback a GPT (útil para tipos difíciles o documentos escaneados):

```
{
  "instrucciones": {
    "classification": {
      "provider": "auto",
      "model": "auto",
      "umbral": 1.0
    }
  },
  "documento": {
    "name": "documento_escaneado.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "FORCE-GPT-001",
    "submittedBy": "qa-team"
  }
}
```

Al establecer `umbral=1.0`, ningún resultado de Azure DI superará el umbral (DI max = 1.0 en teoría, pero rara vez lo alcanza), forzando el fallback GPT.

Ejemplo 5: Clasificación con versión específica de tipología

```
{
  "instrucciones": {
    "expectedType": "nota-simple@1.3"
  },
  "documento": {
    "name": "nota_simple_legacy.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "LEGACY-1.3-001",
    "submittedBy": "sistema-legacy"
  }
}
```

Ejemplo 6: Solo clasificación (sin extracción ni validación)

Para enrutamiento de documentos o pre-clasificación masiva:

```
{
  "instrucciones": {
    "skipDuplicateCheck": true,
    "classification": {
      "provider": "auto",
      "umbral": 0.50
    },
    "extraction": {
      "provider": "mock"
    },
    "skipGDCUpload": true
  },
  "documento": {
    "name": "doc_sin_procesar.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "CLASSIFY-ONLY-2026-001",
    "submittedBy": "router.documentos"
  }
}
```

Ejemplo 7: Con prompt ad-hoc personalizado

Ejecutar un prompt propio sin necesitar configurar la tipología:

```
{
  "instrucciones": {
    "expectedType": "nota-simple",
    "prompt": {
      "systemPrompt": "Eres un experto en documentos inmobiliarios españoles. Responde en español, sin inventar datos.",
      "userPromptTemplate": "Del siguiente documento, extrae en formato JSON los campos: NIF del titular, nombre completo del titular, y fecha de expedición.\n\nDocumento:\n{{CONTENT}}",
      "modelKey": "default.gpt4o-mini",
      "temperature": 0.0,
      "maxTokens": 500,
      "contentMode": "markdown"
    }
  },
  "documento": {
    "name": "nota_simple_consulta.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "PROMPT-ADHOC-001",
    "submittedBy": "analista.juridico"
  }
}
```

El resultado en `datosExtraidos["PromptResult"]` :

```
{
  "NIF": "12345678A",
  "NombreTitular": "Juan García Martínez",
  "FechaExpedicion": "15/01/2026"
}
```

Ejemplo 8: Documento ya archivado en GDC (por objectId)

Procesar un documento que ya existe en el Gestor Documental sin necesidad de enviarlo en base64:

```
{
  "instrucciones": {
    "expectedType": "nota-simple"
  },
  "documento": {
    "name": "nota_simple_ya_archivada.pdf",
    "objectIdGDC": "GDC-OBJ-ID-12345678"
  },
  "trazabilidad": {
    "correlationId": "GDC-EXISTING-001",
    "submittedBy": "sistema-gestion-activos",
    "idActivo": "ACT-98765"
  }
}
```

Cuando se usa `objectIdGDC`, el sistema automáticamente establece `skipGDCUpload = true` (no se vuelve a subir al GDC).

Ejemplo 9: Reprocesar un duplicado

Si el documento ya fue procesado pero necesitas forzar un nuevo procesamiento:

```
{
  "instrucciones": {
    "skipDuplicateCheck": false,
    "forceReprocess": true
  },
  "documento": {
    "name": "nota_simple_actualizada.pdf",
    "content": { "base64": "<MISMO_BASE64_QUE_ANTES>" }
  },
  "trazabilidad": {
    "correlationId": "REPROCESS-001",
    "submittedBy": "admin.sistema"
  }
}
```

Ejemplo 10: Con AssetResolver para enriquecer datos de activo

Buscar el activo por IDUFIR o referencia catastral:

```
{
  "instrucciones": {
    "expectedType": "nota-simple",
    "assetResolver": {
      "enabled": true,
      "camposBusqueda": {
        "idufir": "12345678901234"
      },
      "camposSolicitados": ["ID_ACTIVO_SAREB", "DESCRIPCION_ACTIVO"]
    }
  },
  "documento": {
    "name": "nota_simple_busqueda.pdf",
    "content": { "base64": "<BASE64>" }
  },
  "trazabilidad": {
    "correlationId": "ASSET-RESOLVER-001",
    "submittedBy": "sistema-activos"
  }
}
```


Ejemplo 11: Procesamiento en lote (script PowerShell)

Clasificar todos los PDFs de una carpeta:

```
# Clasificación masiva de documentos
param(
    [string]$InputFolder = "C:\docs\pendientes",
    [string]$Endpoint = "http://localhost:7071/api/IngestDocument"
)

$pdfs = Get-ChildItem -Path $InputFolder -Filter "*.pdf"
$resultados = @()

foreach ($pdf in $pdfs) {
    Write-Host "Procesando: $($pdf.Name)" -ForegroundColor Cyan

    $bytes = [IO.File]::ReadAllBytes($pdf.FullName)
    $b64 = [Convert]::ToBase64String($bytes)

    $body = @{
        instrucciones = @{
            skipDuplicateCheck = $false
            classification = @{ provider = "auto"; umbral = 0.85 }
        }
        documento = @{
            name = $pdf.Name
            content = @{ base64 = $b64 }
        }
        trazabilidad = @{
            correlationId = "BATCH-$(($pdf.BaseName)-$(Get-Date -Format 'yyyyMMddHHmmss'))"
            submittedBy = "proceso.lote"
        }
    } | ConvertTo-Json -Depth 10

    try {
        $resp = Invoke-RestMethod -Method POST -Uri $Endpoint `
            -ContentType "application/json" -Body $body

        # Esperar resultado (polling)
        $maxRetries = 60; $retry = 0
        do {
            Start-Sleep -Seconds 2
            $status = Invoke-RestMethod -Method GET -Uri $resp.statusQueryUri
            $retry++
        } while ($status.runtimeStatus -eq "Running" -and $retry -lt $maxRetries)

        $resultado = [PSCustomObject]@{
            Archivo = $pdf.Name
            Tipologia = $status.output.identificacion.tipologiaFamilia
            Estado = $status.output.resultado.estado
            Confianza = $status.output.resultado.confianzaGlobal
            Calidad = $status.output.resultado.estadoCalidad
        }
        $resultados += $resultado
        Write-Host " $($resultado.Tipologia) | $($resultado.Estado) | Conf=$(($resultado.Confianza))" -ForegroundColor Green
    }
    catch {
        Write-Host " Error: $_" -ForegroundColor Red
        $resultados += [PSCustomObject]@{ Archivo = $pdf.Name; Estado = "ERROR"; Error = $_ }
    }
}

# Mostrar resumen
$resultados | Format-Table -AutoSize
$resultados | Export-Csv -Path "resultado_lote_$(Get-Date -Format 'yyyyMMdd').csv" -Encoding UTF8 -NoTypeInformation
```

Ejemplo 12: Polling con seguimiento de progreso

```
function Wait-DocumentIA {
    param(
        [string]$StatusUri,
        [int]$MaxRetries = 90,
        [int]$PollDelaySeconds = 2
    )

    for ($i = 0; $i -lt $MaxRetries; $i++) {
        $status = Invoke-RestMethod -Method GET -Uri $StatusUri

        if ($status.runtimeStatus -eq "Running" -and $status.customStatus) {
            $cs = $status.customStatus
            Write-Host "  Actividad: $($cs.actividad) | Completadas: $($cs.completadas -join ' → ') | $($cs.duracionMs)ms"
        }
        elseif ($status.runtimeStatus -eq "Completed") {
            $out = $status.output
            $r = $out.resultado
            Write-Host ""
            Write-Host "COMPLETADO en $($out.detalleEjecucion.duracionMs)ms" -ForegroundColor Green
            Write-Host "  Tipología   : $($out.identificacion.tipologiaFamilia) v$($out.identificacion.tipologiaVersion)"
            Write-Host "  Estado      : $($r.estado)"
            Write-Host "  Calidad     : $($r.estadoCalidad) (confianza: $($r.confianzaGlobal))"
            Write-Host "  FallbackLLM: $($out.detalleEjecucion.clasificacion.fallbackLLM)"
            return $status
        }
        elseif ($status.runtimeStatus -in @("Failed", "Terminated")) {
            Write-Host "FALLIDO: $($status.output)" -ForegroundColor Red
            return $status
        }
    }

    Start-Sleep -Seconds $PollDelaySeconds
}

Write-Host "Timeout esperando resultado" -ForegroundColor Yellow
return $null
}
```

Ejemplo 13: Verificar salud del sistema antes de procesar

```
$health = Invoke-RestMethod -Method POST -Uri "http://localhost:7071/api/healthcheck"
if ($health.status -ne "healthy") {
    Write-Warning "Sistema no disponible: $($health.status)"
    # Detalle por componente
    $health.components.PSObject.Properties | ForEach-Object {
        Write-Host "$($_.Name): $($_.Value.status) - $($_.Value.message)"
    }
} else {
    Write-Host "Sistema listo "
}
```


10. Casuísticas y Comportamientos Posibles

10.1 Matriz completa de resultados (Nota Simple 1.4)

#	Clasificación	Fallback Clasif	Extracción	Resultado Extrac	Resultado Final
1	ExpectedType	N/A	Disabled	—	OK
2	ExpectedType	N/A	Provider	≥50% campos	OK
3	ExpectedType	N/A	Provider	<50% campos	OK (fallback GPT extracción)
4	ExpectedType	N/A	Provider	Error	ERROR
5	DI ≥0.85	NO	Disabled	—	OK
6	DI ≥0.85	NO	Provider	≥50% campos	OK
7	DI ≥0.85	NO	Provider	<50% campos	OK (fallback GPT extracción)
8	DI ≥0.85	NO	Provider	Error	ERROR
9	DI <0.85	GPT Sí	Disabled	—	OK
10	DI <0.85	GPT Sí	Provider	≥50% campos	OK
11	DI <0.85	GPT Sí	Provider	<50% campos	OK (fallback GPT extracción)
12	DI <0.85	GPT Sí	Provider	Error	ERROR
13	DI <0.85	GPT No	Disabled	—	OK (mantiene resultado DI)
14	DI <0.85	GPT No	Provider	≥50% campos	OK
15	DI <0.85	GPT No	Provider	<50% campos	OK (fallback GPT extracción)
16	DI error	GPT Sí	Provider	≥50% campos	OK
17	DI error	GPT Sí	Provider	<50% campos	OK (fallback GPT)
18	DI error	GPT Sí	Provider	Error	ERROR
19	Mock	N/A	Provider	≥50% campos	OK
20	DI error	GPT No	—	—	ERROR
21	DI = RESTO	GPT Sí	Provider	≥50% campos	OK
22	DI = RESTO	GPT No (Desconocido)	—	—	NO_CLASIFICADO

Resumen: 16 causísticas terminan en OK, 5 en ERROR, 1 en NO_CLASIFICADO.

10.2 Diagrama de flujo de casuísticas



10.3 Comportamiento especial: documento RESTO

Cuando Azure DI clasifica un documento como **RESTO**, indica que no lo reconoce en ninguna de las clases entrenadas. El fallback GPT es **obligatorio** e independiente del umbral configurado.

```
DI → "RESTO" (confianza: 0.40)
  → Fallback GPT obligatorio
    → GPT → "nota-simple" (confianza: 0.85) → OK con FallbackLLM=true
    → GPT → "Desconocido" (confianza: 0.15) → NO_CLASIFICADO (controlado)
```

10.4 Comportamiento especial: documento duplicado

```
SHA256 del documento coincide con ejecución anterior
  → skipDuplicateCheck=false, forceReprocess=false
    → Estado=DUPLICADO, reutilizadaPorDuplicado=true
    → Se devuelve el resultado de la ejecución anterior
  → skipDuplicateCheck=true
    → Ignora duplicado, procesa normalmente
  → forceReprocess=true
    → Procesa de nuevo aunque sea duplicado (sin reutilizar)
```

11. Errores Frecuentes y Soluciones

11.1 Tabla de errores y soluciones

Error / Situación	Causa	Solución
Estado = NO_CLASIFICADO	GPT no pudo identificar el tipo	Revisar el documento; si es un tipo conocido, usar expectedType
Estado = ERROR + mensajeError = "KeyNotFoundException"	expectedType no existe en el registro	Verificar la familia/versión en TipologiaVersionResolver
Estado = ERROR + error en plugin refCatExcel	El plugin de prioridad 1 falló	Verificar disponibilidad del servicio en localhost:8082 ; desactivar plugin si no está disponible
EstadoCalidad = REVISION	Confianza global entre 0.70 y 0.85	Revisar manualmente los datos extraídos
EstadoCalidad = ERROR	Confianza global < 0.70	Revisión humana obligatoria; considerar extracción manual
400 Bad Request	Body inválido o campos fuera de rango	Verificar que base64 y objectIdGDC no coexisten; revisar longitudes de prompts (≤ 5000 chars)
confianzaClasificacion = 0	NO_CLASIFICADO	Ver causística #22
FallbackLLM = true con confianza < 0.85	GPT clasificó pero con baja confianza	EstadoCalidad será REVISION; revisar tipología detectada
Proceso en Running > 120 s	Timeout en Azure DI o GPT	El proceso fallará en timeout; verificar conectividad y cuotas de los servicios AI
runtimeStatus = "Failed" (sin output)	Error no controlado en el orquestador	Revisar logs de Application Insights con el instanceId

11.2 Interpretar el campo detalleEjecucion.clasificacion

```
// Clasificación exitosa sin fallback
{
  "clasificacion": {
    "tipologiaDetectada": "nota.simple.1_4",
    "clasificador": "DocumentAICC_v0",
    "confianza": 0.95,
    "fallbackLLM": false,
    "fallbackRazon": null
  }
}

// Clasificación con fallback GPT (confianza baja de DI)
{
  "clasificacion": {
    "tipologiaDetectada": "nota.simple.1_4",
    "clasificador": "gpt-4o-mini",
    "confianza": 0.82,
    "fallbackLLM": true,
    "fallbackRazon": "low_confidence:0.65"
  }
}

// Clasificación con fallback GPT (DI = RESTO)
{
  "clasificacion": {
    "tipologiaDetectada": "tasacion",
    "clasificador": "gpt-4o-mini",
    "confianza": 0.78,
    "fallbackLLM": true,
    "fallbackRazon": "resto_classification:0.45"
  }
}

// No clasificado
{
  "clasificacion": {
    "tipologiaDetectada": "Desconocido",
    "clasificador": "gpt-4o-mini",
    "confianza": 0,
    "fallbackLLM": true,
    "fallbackRazon": "fallback_unclassified"
  }
}
```

12. Añadir una Nueva Tipología

12.1 Pasos



12.2 Plantilla mínima de validation.json

```

{
  "tipologiaId": "mi-nueva-tipologia",
  "tipologiaNombre": "Mi Nueva Tipología",
  "version": "1.0",
  "isDefault": true,
  "skipGDCUpload": false,
  "gptDescripcion": "Descripción del tipo de documento para el LLM de clasificación/fallback.",

  "extraction": {
    "enabled": false,
    "provider": "mock",
    "modelKey": "unused",
    "autoMapUnmappedFields": true,
    "fieldMappings": []
  },

  "promptConfig": {
    "enabled": false,
    "modelKey": "default.gpt4o-mini",
    "systemPrompt": "",
    "userPromptTemplate": "",
    "maxTokens": 1200,
    "temperature": 0.0,
    "contentMode": "markdown"
  },

  "confidenceConfig": {
    "clasifUmbralFallback": 0.85,
    "umbralOK": 0.85,
    "umbralRevision": 0.70
  },

  "fields": [
    {
      "name": "CampoObligatorio",
      "type": "string",
      "required": true,
      "rules": [
        { "ruleType": "minLength", "severity": "Error", "parameters": { "value": 1 } },
        { "ruleType": "maxLength", "severity": "Error", "parameters": { "value": 100 } }
      ]
    }
  ]
}

```


12.3 Verificación tras crear la tipología

```
# Probar con clasificación forzada antes de entrenar el modelo DI
$body = @{
    instrucciones = @{
        expectedType = "mi-nueva-tipologia"
        skipGDCUpload = $true
        skipDuplicateCheck = $true
    }
    documento = @{
        name = "prueba.pdf"
        content = @{ base64 = "<BASE64_DOCUMENTO_PRUEBA>" }
    }
    trazabilidad = @{
        correlationId = "TEST-NUEVA-TIPOLOGIA-001"
        submittedBy = "developer"
    }
} | ConvertTo-Json -Depth 5

$r = Invoke-RestMethod -Method POST `
    -Uri "http://localhost:7071/api/IngestDocument" `
    -ContentType "application/json" -Body $body

Write-Host "InstanceId: $($r.instanceId)"
# Luego hacer polling para verificar resultado
```

Anexo A: Diagrama de Arquitectura del Sistema



Anexo B: Glosario

Término	Definición
Tipología	Tipo de documento con su configuración de extracción, validación y comportamiento
ExpectedType	Parámetro que fuerza la tipología sin clasificación IA
Azure DI	Azure AI Document Intelligence: servicio de IA de clasificación con modelo custom entrenado
Azure CU	Azure Content Understanding: servicio de extracción estructurada de campos de documentos
Fallback GPT	Mecanismo de reserva que usa GPT-4o-mini cuando Azure DI no puede clasificar con suficiente confianza
RESTO	Etiqueta que Azure DI asigna cuando no reconoce el documento. Siempre activa fallback GPT
Confianza	Puntuación numérica 0–1 que indica la certeza del sistema en cada etapa
EstadoCalidad	Semáforo de fiabilidad de los datos: OK, REVISION o ERROR
GDC	Gestor Documental Corporativo (SINTWS SOAP) donde se archivan los documentos
Durable Functions	Patrón de orquestación asíncrona de Azure que gestiona el pipeline de actividades
instanceld	Identificador único de una ejecución del orquestador para hacer polling del resultado
Plugin	Componente de integración (REST/SOAP/DLL) que enriquece los datos extraídos