

Manual de Deduplicación Interna — DocumentIA


1. Propósito

El sistema incluye un mecanismo de deduplicación basado en hash SHA256 del contenido del documento. Su objetivo es **evitar reprocesar el mismo documento dos veces** y reutilizar el resultado de la ejecución anterior, ahorrando tiempo de procesamiento y costes de llamadas a servicios IA.

Este mecanismo es **independiente** de la detección de duplicados en el GDC (Gestor Documental), que se describe en [ESPECIFICACION_CAPA_SERVICIO_GDC_SINTWS.md](#).

2. Cómo funciona

2.1 Flujo de decisión



2.2 Posición en el pipeline

La verificación ocurre después de normalizar (paso 1) y **antes** de subir el blob (paso 2.5), clasificar y extraer. Si se detecta duplicado, el pipeline se **corta early** sin llamar a ningún servicio IA.

3. Actividades implicadas

3.1 NormalizarActivity

Calcula los hashes del documento a partir del contenido Base64:

Hash	Uso principal
SHA256	Deduplicación interna (clave de búsqueda en BD).
MD5	Deduplicación en GDC (campo MD5 en SINTWS).
CRC32	Integridad (campo adicional en Integridad).

La normalización también extrae: TamañoBytes , NombreNormalizado , FechaNormalizacion .

3.2 VerificarDuplicadoActivity

Firma: Run([ActivityTrigger] string sha256) → bool

Consulta IDocumentoRepository.ExistsBySHA256Async(sha256) contra la base de datos interna. Devuelve:

- true → el documento ya existe en BD.
- false → no existe; continuar procesamiento normal.

3.3 ObtenerUltimaEjecucionDuplicadoActivity

Firma: Run([ActivityTrigger] string sha256) → ContratoSalida?

Cuando se detecta duplicado y ForceReprocess = false :

1. Busca el DocumentoEntity por SHA256 en IDocumentoRepository .
2. Obtiene todas las ejecuciones del documento desde IDocumentoEjecucionRepository .
3. Selecciona la **primera ejecución que tenga ContratoSalidaCompletoJson poblado** (la última en orden de inserción).
4. Deserializa el JSON y establece:
 - Resultado.ReutilizadaPorDuplicado = true
 - Resultado.MensajeReutilizacion = "Documento ya procesado previamente. Se reutiliza la última ejecución."
5. Devuelve la ContratoSalida reutilizada.

Si no hay ejecuciones serializadas disponibles, devuelve null .

4. Comportamiento según combinación de flags

SkipDuplicateCheck	ForceReprocess	Existe en BD	Comportamiento
false	false	No	Pipeline completo normal.
false	false	Sí, con salida previa	Short-circuit: devuelve salida previa. Estado = el de la ejecución previa. ReutilizadaPorDuplicado = true .
false	false	Sí, sin salida previa	Short-circuit: devuelve respuesta vacía. Estado = "DUPLICADO" . ReutilizadaPorDuplicado = true .
false	true	Sí	Reprocesa completamente, ignorando el duplicado.
true	—	—	Omite verificación. Pipeline completo.

5. Campos en la respuesta relativos a deduplicación

En ContratoSalida.Resultado :

Campo	Tipo	Descripción
resultado.estado	string	"DUPLICADO" cuando se detecta duplicado sin ejecución reutilizable. En reutilización con ejecución previa, el estado es el de dicha ejecución (normalmente "OK").
resultado.reutilizadaPorDuplicado	bool	true cuando se devuelve una ejecución anterior o cuando el estado es DUPLICADO .
resultado.mensajeReutilizacion	string?	Mensaje descriptivo del motivo de reutilización.

6. Casos de uso típicos

Reenvío accidental del mismo documento

El sistema detecta el SHA256 idéntico, recupera la ejecución anterior y devuelve ese resultado sin reprocesar. El cliente recibe `reutilizadaPorDuplicado = true` .

Forzar reprocesamiento (corrección de datos)

Si se ha actualizado la configuración de tipología o se requiere reextracción, enviar con `forceReprocess = true` . El documento se procesa completamente aunque ya exista.

Importación masiva con documentos potencialmente repetidos

Enviar `skipDuplicateCheck = false` (default) para que el sistema filtre automáticamente duplicados, ahorrando tiempo y coste en lote.

Entornos de prueba sin BD

Enviar `skipDuplicateCheck = true` para omitir la verificación y siempre procesar, independientemente del estado de la BD.

7. Persistencia en base de datos

La deduplicación se apoya en dos repositorios:

Repositorio	Entidad	Uso
IDocumentoRepositor y	DocumentoEntity	Índice de documentos únicos por SHA256. Consultado por VerificarDuplicadoActivity y ObtenerUltimaEjecucionDuplicadoActivity .
IDocumentoEjecucionRepository	DocumentoEjecucionEntity	Historial de ejecuciones con ContratoSalidaCompletoJson . Consultado por ObtenerUltimaEjecucionDuplicadoActivity .

Los documentos se persisten al final del pipeline por PersistirActivity . El SHA256 se registra en ese momento. Si la función se interrumpe antes de PersistirActivity , el documento no queda registrado y no se detectará como duplicado en futuras ejecuciones.

8. Diferencia con deduplicación en GDC

Aspecto	Deduplicación interna (BD)	Deduplicación en GDC (SINTWS)
Clave	SHA256 del contenido	id_expediente + checksum (MD5)
Momento	Paso 2 del pipeline (antes de clasificar)	Paso subida GDC (SubirGDCActivity)
Efecto en duplicado	Short-circuit completo del pipeline	Subida omitida; GDC.YaExistia = true
Control	SkipDuplicateCheck / ForceReprocess	No configurable desde el contrato de entrada
Documentado en	Este documento	ESPECIFICACION_CAPA_SERVICIO_GDC_SINTWS.md